

## یادگیری تقویتی عمیق برای تخصیص هوشمند منابع در شبکه‌های یکپارچه زمینی–غیرزمینی با سطح بازیکردنی فعال (Active RIS)

محمد احمد محسن<sup>۱</sup>، حسن رضوان<sup>۲</sup>، محمد جزیب<sup>۴</sup>، محمد اقبال<sup>۴</sup>، محمد بلال<sup>۵</sup>، تبنده اشرف<sup>۴</sup>، محمد فرحان خان<sup>۶</sup>، جن‌سی پان<sup>۴</sup>

دانشکده مهندسی برق، دانشگاه استنفورد، آمریکا

دانشکده مهندسی برق، دانشگاه کالیفرنیا، ریورساید، آمریکا

دانشکده مهندسی و علوم کاربردی پاکستان، پاکستان

دانشکده مهندسی ارتباطات، دانشگاه چونگ چونگ، چین

دانشکده مهندسی برق، دانشگاه کالیفرنیا، ارواین، آمریکا

دانشکده علوم کامپیوتو و فناوری اطلاعات، کالج دانشگاهی کورک، ایرلند

: {muahmed@stanford.edu, hrizw002@ucr.edu, iqbal.marjan@gmail.com}

سیستم‌های شامل RIS و پهپاد مورد استفاده قرار گرفته است، پژوهش‌های موجود عمدتاً بر فضاهای کش پیوسته یا گسته نموده شده‌اند.<sup>[8]</sup> برای دستیابی به عملکرد بهینه، یک رویکرد ترکیبی که هر دو فضای کش پیوسته و گسته را در بر گیرد، ضروری است. الگوریتم‌های DRL که قادر باشند به طور همزمان از هر دو نوع فضای کش استفاده کنند، می‌توانند راه حل‌های سیار امیدوارکننده‌ای برای مسائل پیوسته‌سازی ارائه دهند. علاوه بر این، پیوسته‌سازی متراپس تقویت RIS فعال با استفاده از DRL تاکنون مورد بررسی قرار گرفته است. با در نظر گرفتن این شکاف در ادبیات پژوهشی به عنوان انگزه اصلی، مشارکت‌های این مقاله به صورت سه گانه ارائه می‌شوند. در این کار، یک عامل پادگیری تقویتی عمیق ترکیبی با نام H-PPO برای پیوسته‌سازی شبکت‌های فار، مسیر حرکت پهپاد، ضرایب تخصیص توان و نوان ارسالی ایستگاه پایه به منظور دستیابی به پیشینه نخ مجموع تحت شرایط SNR پیوسته به کار گرفته شده است.

.II. مدل سیستم و صورت‌بندی مسئله

### A. توصیف سیستم

ما یک شبکه انتقال پایین دست (downlink) تک‌خروجی (SISO) هستی بر-CoMP با کمک RIS فعال و استقرار پهپاد را در نظر می‌گیریم. شبکه در قالب M ناحیه دایره‌ای توزیع شده است که در مرکز هر ناحیه، یک ایستگاه پایه تاکنته (BS) قرار دارد، به طوری که  $m \in \{1, 2, \dots, M\}$  هر ایستگاه در ناحیه  $m$  دو کاربر برای فراهم‌سازی کانال پایین دست برای کاربران مرکزی و کاربران لبه استفاده می‌کند. کاربران مرکزی درون شعاع ناجیه قرار دارند و توسط سرویس دهی  $BS_m$  در ناحیه  $m$  نمایش داده می‌شوند، که  $C = \{1, 2, \dots, C\}$  با  $U^m$  نمایش داده می‌شوند. در مقابل، کاربران لبه خارج از شعاع ناجیه قرار دارند و با  $U^m$  نمایش داده می‌شوند که توسط  $BS_m$  سرویس می‌گیرند، به طوری که  $e \in E = \{1, 2, \dots, E\}$  نمایانگر مجموعه کاربران مرکزی است. تمام کاربران موجود در سیستم را می‌توان به صورت  $U = C \cup E$  نشان داد، به طوری که هر کاربر  $U$  با یک کاربر مرکزی است با یک کاربر لبه. کل زمان پرواز پهپاد به  $t$  بازه زمانی تقسیم می‌شود، به طوری که  $\{1, 2, \dots, T\}$  است. که در آن  $\forall t \in \mathcal{T}$  زمان پرواز پهپاد است. علاوه بر این، پهپاد اجازه پرواز در نواحی ممنوعه موجود در مدل سیستم را ندارد که این نواحی به صورت دیسکه‌های دایره‌ای با شعاع  $d_{min}$  و محدود موضع مختلف مدل سازی می‌شوند، به طوری که  $0 = \{1, 2, \dots, 0\}$ . مدل سیستم شامل دو RIS فعال است: یکی روی یک ساختمان و در فاصله‌ای برابر از نهای شکاف با نمای نصب شده است و دیگری روی یک پهپاد متوجه برای نهاد قرار دارد که موقعیت خود را برای فراهم‌سازی پیشینه نخ مجموع کاربران شبکه تغییر می‌دهد. هر دو RIS به تمامی کاربران شبکه سرویس می‌دهند و توسط یک ریکنترول گر کنترل می‌شوند تا شیفت‌های فارا تغییر دهند. RIS فعال نهاد  $R \in R_G, R_U$  در مدل سیستم به  $K$  نصر بازتابنده مجهز است، به طوری که  $k \in \{1, 2, \dots, K\}$ . سیگنال‌هایی که جندين بار توسط RIS ها بازتاب می‌شوند، به دلیل لفقات شدید سیمیر، دارای توان ناچیز قرض می‌شوند؛ همان‌گونه که در محتیه‌های چند RIS در [9] در نظر گرفته شده است و این پژوهش نیز همین فرض را اتخاذ می‌کند. به طور خاص، برای  $0 \in O, u \in U, \forall m \in M$ ، موقعیت ایستگاه پایه  $BS_m$ ، کاربر  $U$  و مانع  $O_0$  به ترتیب به صورت زیر نمایش داده می‌شوند:

$$p_m = (x_m, y_m, H_B),$$

که در آن  $H_B$  و  $O_0$  به ترتیب ارتفاع ایستگاه‌های پایه و مانع هستند. موقعیت RIS هوایی در بازه زمانی به صورت  $p_R[t] = (x_{R_U}[t], y_{R_U}[t], H_{R_U})$  نمایش داده می‌شود و این RIS بر فزار یک ناحیه مشخص A شناور است. همان‌طور که پیشتر ذکر شد، پهپاد متوجه بوده و موقعیت افقی خود را در صفحه تغییر می‌دهد، در حالی که ارتفاع آن  $H_{R_U}$  ثابت باقی می‌ماند.

.B. مدل کانال

چکیده—این کار به بررسی به کارگیری سطوح هوشمند بازیکردنی بدین فعال (A-RIS) در شبکه‌های پیکارچه زمینی و غیرزمینی (TN-NTN) براساس مفهومی معرفی شده (Terrestrial and Non-Terrestrial Networks – TN-NTN) با استفاده از دسترسی چندگانه غیرمتعادم چند نقطه‌ای همراه با شده (Non-Orthogonal Multiple Access – CoMP-NOMA) که قادر باشد یک RIS مینتی بر پهپاد است که به صورت همراه با یک RIS زمینی عمل می‌کند و هدف آن تقویت سیگنال می‌باشد. هدف اصلی ما پیشنهاده سازی نخ مجموع برای تمامی کاربران موجود در شبکه با استفاده از یک الگوریتم سفارشی پیوسته‌سازی مجاموتویی سیاست مسیر حرکت پهپاد، ضرایب تخصیص توان از طریق پیوسته‌سازی مسیر حرکت پهپاد، ضرایب شیفت فاز است. ما کاربران ایستگاه پایه (Base Station – BS)، ضرایب تقویت RIS فعال و ماتریس شیفت فاز است. ماتریس ایجاد شده از زوج‌های NOMA داغم می‌کنیم تا بهینه نخ مجموعه این افر تجربه کلی کاربران ایه را بیش از پیش بیبورد بخشند. مقایسه‌های جامع و کسرت‌داده با شبکه‌های مجهز به RIS غیرفعال انجام شده است تا از این بروز RIS فعال از نظر پیروزی انرژی، احتمال قطعی و نخ مجموع شبکه به طور واضح نشان داده شود.

و ایگان کلیدی—RIS فعال، یادگیری تقویتی عمیق، NOMA، تخصیص منابع، TN-NTN

### I. مقدمه

گسترش روزافزون دستگاه‌های می‌سیم منجر به افزایش چشمگیر تقاضا برای منابع ارتباطی شده است. طرح‌های سنتی دسترسی چندگانه متعادم (OMA – Orthogonal Multiple Access) در آن‌ها به روش هایی ناکارآمد هستند. دسترسی چندگانه غیرمتعادم (Non-Orthogonal Multiple Access – NOMA) به عنوان یک فناوری نویدبخش مطرح شده است که با بهره‌گیری از کارکردی برهم‌بندی (Successive Interference Cancellation) و حذف تداخل متوالی (Superposition Coding) امکان اشتراک‌گذاری منابع زمانی فرانکانسی یکسان را برای چندین کاربر می‌کند. این ویژگی منجر به افزایش پیروزی طبقی سیستم می‌شود [1, 2]. با تخصیص توان به کاربران بر اساس شرایط کانال، NOMA قادر است عدالت را در سیستم بیبورد داده و کاربران بیشتری را در یک طیف فرانکانسی مشخص پیش‌بینی کند. در محیط‌های جنسی‌سالی، کاربران ایه سلول اغلب از تداخل شدید بین سلولی رنج می‌برند، زیرا این کاربران در نزدیکی مزدئی‌های سلول‌ها فرار دارند و بیشتر در معرض تداخل ناشی از سلول‌های مجاور هستند. به‌منظور کاهش این مشکل، از انتقال چند نقطه‌ای همراه‌گشته شده (CoMP) استفاده می‌شود که امکان آشکارسازی مشترک و انتقال مشترک همراه‌گشته میان چندین ایستگاه پایه را فراهم می‌سازد؛ اموی که می‌تواند عملکرد کاربران ایه سلول را به طور قابل توجیه بیبورد دهد [3]. RIS زمینی معمولاً در مناطق شهری با تراکم بالا که تقاضای کاربران پایدار است، مستقر می‌شود، در حالی که RIS فعال برای محیط‌های پیوایی به کار می‌رود که در آن‌ها تقاضای کاربران به مساحت تغییر می‌کند [4]. [5]. علاوه بر این، در مناطق شهری مواعنی برای پرواز پهپاد وجود دارد که نواحی بلا اسفلت ایجاد می‌کند و به عنوان مناطق ممنوعه پرواز برای پهپاد در نظر گرفته می‌شوند. بنابراین، پیوسته‌سازی مسیر حرکت پهپاد به منظور بیبورد نخ مجموع و تضمین اینه پهپاد امری ضروری است. برخی از پژوهش‌ها از پهپاد به عنوان ایستگاه پایه استفاده می‌کند که در مقایسه با RIS انتقال‌بینی که می‌تواند به صورت پویا بازیکردنی شوند تا ویژگی‌های یازتابی خود را بر اساس شرایط متغیر کانال تنظیم کرده و حتی پرتوها را به سمت کاربران هدایت کنند تا طرفت شبکه ایجاد شوند. به طور معمول، سیستم‌های ارتباطی مبتنی بر پهپاد از RIS های غیرفعال استفاده می‌کنند و ماتریس شیفت فاز آن‌ها را به منظور بیبورد توان عملیاتی سیستم پیوسته‌سازی می‌آینند. با این حال، استفاده از RIS فعال و پیوسته‌سازی ماتریس ضریب تقویت آن تأثیر قابل توجیه بر نخ مجموع کلی محیط خواهد داشت، زیرا مقایسه ایه شده در [7] نشان می‌دهد که فعال بر اثر تضعیف ضریب موجود در RIS غیرفعال غلبه کرده و در نهایت بیهوده نخ مجموع بازتابی را فراهم می‌کند. در حالی که یادگیری تقویتی عمیق (Deep Reinforcement Learning – DRL) به طور فرازینه‌ای برای پیوسته‌سازی

$$h_{m,u}[t] = \sqrt{\frac{\rho_0}{PL(d_{m,u})}} \left( \sqrt{\frac{K}{1+K}} g_{m,R}^{LoS} + \sqrt{\frac{1}{1+K}} g_{m,R}^{NLoS} \right), \quad (2)$$

که در آن  $K$  عامل رایسین است. بردار کاتال دید مستقیم  $g_{m,R}^{LoS} \in \mathbb{C}^{K \times 1}$  به صورت زیر تعریف می‌شود:

$$g_m^{LoS} = [1, \dots, e^{j(k-1)\pi \sin(\omega)}, \dots, e^{j(K-1)\pi \sin(\omega)}]^T, \quad (3)$$

که در آن  $\omega$  زاویه ورود مؤلفه دید مستقیم به RIS را نشان می‌دهد. مؤلفه بدون دید مستقیم  $g_m^{NLoS} \in \mathbb{C}^{K \times 1}$  از محوشگی رایلی پیروی می‌کند، همان‌گونه که در [3] توصیف شده است. در این پژوهش، برای جلوگیری از سرباره‌های غیرضروری، اطلاعات حالت کاتال کامل (Perfect CSI) فرض شده است.

### C. پیکربندی RIS فعال

RIS فعال موجود در شبکه، سیگنال ورودی را تقویت می‌کند که این امر ناشی از استفاده از تقویت‌کننده‌های نوع بازنایی در عنصر RIS فعال است که به یک منبع تغذیه متصل هستند. سیگنال خروجی RIS فعال با  $K$  عنصر بازنایی به صورت زیر بیان می‌شود:

$$y[t] = P[t]\Theta[t]x[t] + P[t]\Theta[t]v + n_u, \quad (4)$$

که در آن  $P[t] = diag(p_1[t], \dots, p_K[t]) \in \mathbb{R}^{K \times K}$  ماتریس تقویت RIS فعال در بازه زمانی  $t$  است. هر عنصر RIS فعال به صورت  $1 \leq p_k \leq S$  مدل‌سازی می‌شود، که در آن  $S$  بیشینه  $y[t] \in \mathbb{C}^k$ ،  $\Theta[t] = diag(a_1e^{j\theta_1[t]}, \dots, a_Ke^{j\theta_K[t]}) \in \mathbb{C}^{K \times 1}$  سیگنال خروجی RIS،  $x[t] \in \mathbb{C}^k$  ماتریس شیفت فاز RIS در بازه زمانی  $t$  است، که در آن  $a_k \in (0, 1]$  ضریب دامنه و  $\theta_k \in [-\pi, \pi]$  شیفت فاز عنصر  $K$ -ام RIS را نشان می‌دهد. عملگر  $\Theta(t)$  به عملیات قطری‌سازی اشاره دارد. عنصر RIS فعال برای تقویت سیگنال‌های بازنایی، توان اضافی مصرف کرده و نویز حرارتی تولید می‌کند که به دو بخش نویز پویا و نویز ایستا تقسیم می‌شود. در این کار، تنهای نویز پویا در نظر گرفته شده و نویز ایستا نادیده گفته می‌شود. زیرا طبقه [7] نشان می‌دهد که نویز ایستا نسبت به نویز پویا به طور قابل توجهی کوچکتر بوده و می‌توان از آن صرف نظر کرد. نویز پویا با تغییر  $\gamma$  نهایی داده شده و به صورت زیر مدل می‌شود:  $\gamma \sim \mathcal{CN}(0_K, \sigma^2 I_K)$  که در آن  $\gamma \sim \mathcal{CN}(\mu, \sum_{k=1}^K \sigma^2 I_K)$  توزیع گاووسی مختلط چندمتغیره با میانگین  $\mu$  و کوواریانس  $\Sigma$  را نشان می‌دهد. همچنین  $I_K$  ماتریس همانی  $K \times K$  و  $0_K$  بردار صفر  $1 \times K$  است.

را آشکارسازی کرده و آن را از سیگنال دریافتی حذف می‌کند تا بتواند سیگنال خود را در مگذشتایی تهابد: بنابراین، نخ دست‌یافتنی برای کاربر مرکزی جهت آشکارسازی سیگنال کاربر به صورت زیر است:

$$\mathcal{R}_{c \rightarrow e}[t] = \log \left( 1 + \frac{\lambda_m \gamma_m}{(1 - \lambda_m) \gamma_m + 1} \right), \quad (5)$$

که در آن  $\psi = p_e |h_{j,c}[t]|^2 + \sigma^2$  و  $\gamma_m = \frac{p_e |h_{m,u}[t]|^2}{\psi}$  در مقابل، نخ داده‌ای که کاربر مرکزی برای آشکارسازی سیگنال خود به دست می‌آورد به صورت زیر بیان می‌شود

$$\mathcal{R}_c[t] = \log (1 + (1 - \lambda_m) \gamma_m). \quad (6)$$

سیگنال دریافتی توسط کاربر لبه از طریق  $BS_m$  و RIS به صورت زیر بیان می‌شود

$$y_e = (h_{m,e}[t] + h_{R,e}^H[t]P[t]\Theta[t]h_{m,R}[t])x_m[t]p_t + (h_{j,e}[t] + h_{R,e}^H[t]P[t]\Theta[t]h_{j,R}[t])x_j[t]p_t + n_u, \quad (7)$$

که در آن  $h_{R,e}^H[t]$  ترانهاده مزدوج (Hermitian) کاتال بین RIS و کاربر لبه  $e$  را نشان می‌دهد. نخ داده قابل دستیابی برای کاربر لبه به صورت زیر تعریف می‌شود:

$$\mathcal{R}_e[t] = \log \left( 1 + \frac{\lambda_m \gamma_m + \lambda_j \gamma_j}{(1 - \lambda_m) \gamma_j + (1 - \lambda_j) \gamma_j + 1} \right) \quad (8)$$

پس از بدست آوردن نخ مجموع برای کاربر مرکزی در رابطه (6) و کاربر لبه در رابطه (8)، نخ مجموع کل سیستم به صورت زیر محاسبه می‌شود:

$$R_{\text{total}}[t] = \sum_{e \in \mathcal{C}} R_c[t] + \sum_{e \in \mathcal{E}} R_e[t]. \quad (9)$$

مدل در نظر گرفته شده شامل مسیرهای دید مستقیم (LoS) و بدون دید مستقیم (NLoS) است؛ ازین‌رو، از مدل‌های محوشگی رایلی (Rayleigh) و رایسین (Rician) استفاده می‌شود. به دلیل پراکندگی موجود در محیط، از مدل کاتال محوشگی رایلی برای شبیه‌سازی کاتال‌های بین استگاه‌های پایه و کاربران استفاده می‌شود.

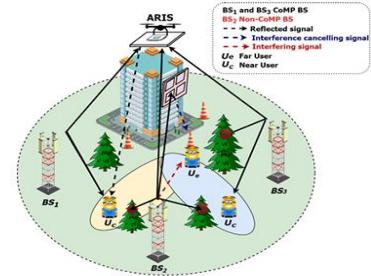


Fig. 1: RIS-assisted TN-NTN with coordinated NOMA pairing.

کاتال بین استگاه پایه  $BS_m$  و کاربر  $U_u$  با  $h_{m,u}$  نهایش داده می‌شود و برای بازه زمانی  $t$  به صورت زیر بیان می‌گردد:

$$h_{m,u}[t] = \sqrt{\frac{\rho_0}{PL(d_{m,u})}} v_{m,u}[t], \quad (1)$$

که در آن  $\rho_0$  تلفات مسیر مرجع در فاصله ۱ متر است و  $PL(d_{m,u}) = (d_{m,u})^\alpha$  مدل‌سازی می‌شود؛ در اینجا  $\alpha$  توان تلفات مسیر و  $v_{m,u} \sim \mathcal{R}(1)$  می‌باشد. همچنین، ضرب محوشگی رایلی مقیاس کوچک با  $BS_m$  نصب شده در اینجا که بین استگاه پایه و RIS نصب شده روی پیهاد و همچنین RIS نصب شده روی ساختمان، دید مستقیم وجود دارد، این کاتال با استفاده از محوشگی رایسین شبیه‌سازی می‌شود. کاتال بین  $BS_m$  و RIS با نمایش داده شده و برای بازه زمانی  $t$  به صورت زیر بیان می‌شود

### D. NOMA مدل

تمام استگاه‌های پایه یک کاربر مرکزی و یک کاربر لبه را سرویس دهی می‌کنند؛ بنابراین، مطابق با سنت NOMA دو کاربره، توان استگاه پایه بین دو کاربر نویز پویا می‌شود، که بطوری که توان پیشتری دریافت می‌کند [10]. [11]. سیگنال ارسالی توسط استگاه پایه  $BS_m$  به صورت زیر بیان می‌شود،  $x_{m,e}[t] = \sqrt{(1 - \lambda_m)p_e} x_{m,c}[t] + \sqrt{\lambda_m p_e} x_{m,e}[t]$  که در آن  $x_{m,c}[t]$  و  $x_{m,e}[t]$  به ترتیب سیگنال دریافتی برای کاربر مرکزی  $U_e$  و کاربر لبه  $U_e$  هستند. تمام استگاه‌های پایه در سیستم دارای توان ارسال پیمان  $p_e$  هستند و ضرب تخصیص توان کاربر لبه  $\lambda_m$  نمایش داده می‌شود. ضرب تخصیص توان  $\lambda_m$  باید قید نرخ را ارضاء کند،  $\lambda_m < 0.5$  زیرا کاربر لبه فاصله بیشتری از استگاه پایه دارد و نیازمند تخصیص توان بالاتری است [11].

هر کاربر مرکزی  $U_e$  یک سیگنال مستقیم از استگاه پایه، یک لینک غیرمستقیم بازنایی از RIS، تداخل ناشی از استگاه پایه دیگر که کاربر سلوو مجاور را سرویس می‌دهد، و همچنین نویز ذاتی RIS فعال را دریافت می‌کند. در نهایت، سیگنال دریافتی توسط کاربر مرکزی به صورت زیر بیان می‌شود:

$$y_e[t] = \underbrace{H_{m,c}[t]p_t x_m[t]}_{\text{desired signal}} + \underbrace{\sum_{j \neq m} H_{j,c}[t]p_t x_j[t]}_{\text{inter-user interference}} + \underbrace{h_{R,e}[t]P[t]\Theta[t]v + n_u}_{\text{active RIS noise}}, \quad (4)$$

که در آن  $n_u \sim \mathcal{N}(0, \sigma^2)$  مدل‌سازی می‌شود. کاتال بین  $BS_m$  و کاربر مرکزی  $U_e$  به صورت زیر تعریف می‌شود،  $H_{m,c}[t]P[t] \Theta[t]h_{m,R}[t] \oplus [t]h_{m,R}$  که شامل لینک مستقیم و لینک غیرمستقیم از طریق RIS است. تداخل بین کاربری (ICI) زمانی رخ می‌دهد که  $U_e$  سیگنال پخش شده از استگاه پایه  $BS$  را دریافت کند [12]. پس از به کارگیری حذف تداخل متواوال (SIC)، کاربر مرکزی ایندا سیگنال مربوط به کاربر لبه

بعد فضای حالت به صورت زیر بیان می‌شود  $. \dim(S_t) = 2 + M + K^2 + 2$

## C. فضای کنش

فضای کنش MDP شامل حرکت افقی پهپاد در صفحه، ضریب تقویت و شیفت‌های فاز RIS فعال، و ضرایب تخصیص توان استگاه‌های پایه است.

بهطور خاص، فضای کنش در بازه زمانی شامل کنش‌های حرکتی پهپاد است که بهترین بینگر حرکت به چپ، راست، پایین، بالا و حالت شناوری (hover) می‌باشد. شیفت‌های فاز با، ضرایب تخصیص توان با، و ماتریس تقویت RIS فعال با نمایش داده می‌شوند. بنابراین، فضای کنش به صورت زیر تعریف می‌شود:

$$a_t = \{a_R[t], a_\theta[t], a_\Lambda, a_p[t]\} \quad (13)$$

بعد فضای کنش برابر است با  $. \dim(a_t) = 2 + k + M + K^2$

**Algorithm 1** H-PPO Active RIS-Based Energy Optimization

```

1: Initialize: Parameters  $\alpha_d, \alpha_c, \zeta, \Psi$ 
2: for iteration  $l = 1, \dots, L$  do
3:   Receive initial state  $s_0$ 
4:   for time step  $t = 0, \dots, T$  do
5:     Choose continuous actions  $a_p$  and  $a_c$  using  $\pi_{\alpha_c}(s_t)$ 
6:     for each RIS element  $n$  do
7:       Energy optimization  $e_n = g(\psi_n, a_p, a_c)$ 
8:       Update the gain for the  $k$ -th RIS element based on
       channel conditions
9:     end for
10:    Execute actions  $a_t = \{a_R, \Psi, a_p, a_c\}$ 
11:    Observe reward  $r_t$  based on achieved sum rate and outage
       probability
12:    Store the transition  $(s_t, a_t, r_t, s_{t+1})$  in experience replay
       buffer
13:    Compute the advantage function estimate  $\hat{A}_t$ 
14:  end for
15: end for
16: for epoch  $m = 1, \dots, K$  do
17:   Sample mini-batch experiences  $E$  from the replay buffer
18:   Objective computation using clipped functions for both
       discrete and continuous actions:  $L_d^{\text{CLIP}}(\theta_d)$  and  $L_c^{\text{CLIP}}(\theta_c)$ 
19:   Optimize policy parameters  $\alpha_d$  and  $\alpha_c$ 
20: end for
21: Obtain previous policy parameters  $\alpha_d^{\text{old}} \leftarrow \alpha_d$  and  $\alpha_c^{\text{old}} \leftarrow \alpha_c$ 
22: Clear

```

## D. تابع پاداش

تابع پاداش به‌گونه‌ای طراحی شده است که ضمن بینه‌سازی نرخ مجموع، اینمی پهپاد و برآورده شدن الزامات کیفیت سرویس (QoS) را نیز تضمین کند. در صورتی که پهپاد از محدوده مجاز خارج شود (Out of Bounds)، نقص قیود با اعمال جرمیه در تابع پاداش لحاظ می‌شود. تابع پاداش به صورت زیر تعریف می‌شود:

$$R(s_t, a_t) = R_{\text{sum}}[t] + \xi_{\text{dist}} \left( \frac{C}{d_{R_U, U}[t]} \right) \zeta - \xi_{\text{OOB}} \cdot \mathbb{I}(\text{OOB}), \quad (14)$$

که در آن تابع شاخصی است که برای تشویق پهپاد به نزدیک ماندن به کاربران به کار می‌رود. همچنین، جرمیه‌ای است که در صورت خروج RIS هوایی از محدوده مجاز به عامل اعمال می‌شود، که توسط تابع شاخص مشخص می‌گردد. در نهایت، و به عنوان ضرایب تابع در این رابطه در نظر گرفته می‌شوند.

## E. الگوریتم H-PPO

برای مدیریت فضای کنش ترکیبی در شبکه، از الگوریتم بینه‌سازی سیاست مجاورتی ترکیبی (Hybrid Proximal Policy Optimization – H-PPO) استفاده می‌شود. این الگوریتم شامل کنش‌های گسته و کنش‌های پیوسته، و است. تابع ارزش برای بدست آوردن تخمین تابع مزیت با واریانس کاهش‌یافته جهت بینه‌سازی سیاست مورد استفاده قرار می‌گیرد. بر اساس جزئیات پیاده‌سازی ارائه شده در [13]، سیاست برای بازه زمانی اجرا شده و به صورت زیر محاصله می‌شود:

$$\hat{A}_t = \sum_{k=0}^{T-1} \mathbb{D}^k r_{t+k} + \mathbb{D}^T \hat{V}(s_{t+T}) - V(s_t), \quad (15)$$

که در آن به طور قابل توجیهی کوچکتر از طول ایزوود است. برای تولید سیاست تصادفی کنش‌های گسته، شبکه بازیگر (Actor) گسته تعداد لاجست خروجی تولید می‌کند که سبیس از تابع softmax معمور داده می‌شوند تا توزیع احتمال روی کنش‌های گسته حاصل شود. در مقابل، شبکه

پهلوی از روی NOMA-CoMP مبتنی بر RIS فعال، موازن میان عملکرد شبکه و هزینه‌های انرژی را بر جسته می‌کند که به صورت زیر تعریف می‌شود:

$$\eta_E = \frac{R_{\text{total}}[t]}{P_{\text{total}}}. \quad (10)$$

که در آن  $R_{\text{total}}[t]$  نرخ مجموع سیستم در بازه زمانی  $t$  بوده و  $P_{\text{total}}$  کل مصرفی شبکه را نشان می‌دهد. توان کل مصرفی شبکه شامل توان مصرفی ایستگاه‌های پایه، RIS فعال و پهپاد است. با توجه به اینکه نرخ مجموع کل سیستم در رابطه (9) بیان شده است، توان کل مصرفی شبکه را می‌توان به صورت زیر نوشت:

$$P_{\text{total}} = \underbrace{P_{\text{BS}}}_{\text{BS power}} + \underbrace{\sum_{i=1}^2 \sum_{k=1}^K (\eta_{R_i} |P_{R_{i,k}} \Theta_{R_{i,k}} x_{R_{i,k}}|^2 + P_{c,R_{i,k}})}_{\text{RIS power}} + \underbrace{P_{\text{UAV}}}_{\text{UAV power}}, \quad (11)$$

که در آن  $P_{\text{BS}}$  نشان‌دهنده توان ایستگاه پایه است؛ توان مصرفی RIS شامل  $\eta_{R_i}$  به عنوان بازده تقویت  $P_{R_{i,k}}$ ،  $R_i$  RIS ورودی و عنصر  $\Theta$ ،  $x_{R_{i,k}}$  شیفت فاز اعمال شده توسط عنصر  $A_m$ ،  $R_i$  RIS سیگنال ورودی به عنصر  $A_m$ ، و  $P_{c,R_{i,k}}$  توان مصرفی مدار عنصر  $A_m$  RIS می‌باشد؛ در نهایت،  $P_{\text{UAV}}$  توان مصرفی پهپاد برای شناوری و حرکت آن را نشان می‌دهد.

## F. صورت‌بندی مسئله

در این پژوهش، هدف اصلی ما بینه‌سازی نرخ مجموع حاصل شده در طول بازه‌های زمانی  $t$  است. برای دستیابی به این هدف، چهار متغیر کنترلی کلیدی به صورت همزمان بینه‌سازی می‌شوند. مسیر حرکت پهپاد  $P$  می‌باشد؛ در نهایت،  $\mathcal{P} \triangleq \{p_k[t], \forall k\}$  و  $\mathcal{A} \triangleq \{\lambda_m, \forall m\}$  و  $\Theta \triangleq \{\Theta[t], \forall t\}$  و  $\mathcal{T} \triangleq \{T[t], \forall t\}$  مسئله پیشنهادی به صورت زیر معرفی می‌شود:

$$\max_{\mathbf{P}, \Theta, \Lambda, \mathbf{T}} \sum_{t \in \mathcal{T}} R_{\text{sum}}[t], \quad (10a)$$

به طوری که قیود زیر برقرار باشند:

$$x_R[t], y_R[t] \in A, \quad \forall t \in \mathcal{T}, \quad (10b)$$

$$\|\mathbf{p}_R[t] - \mathbf{p}_o\| \geq d_{\min}, \quad \forall o \in \mathcal{O}, t \in \mathcal{T}, \quad (10c)$$

$$\theta_k[t] \in [-\pi, \pi], \quad \forall k \in K, t \in \mathcal{T}, \quad (10d)$$

$$R_c[t] \geq R_c^{\min}, \quad \forall m \in M, t \in \mathcal{T}, \quad (10e)$$

$$R_e[t] \geq R_e^{\min}, \quad \forall e \in \mathcal{E}, t \in \mathcal{T}, \quad (10f)$$

$$\lambda_m \in (0.5, 1), \quad \forall m \in M, t \in \mathcal{T}, \quad (10g)$$

$$p_k[t] \in [1, S], \quad \forall k \in K, t \in \mathcal{T}, \quad (10h)$$

## III. راهکار پیشنهادی مبنی بر یادگیری قویی عمقی

## A. صورت‌بندی MDP

فرآیند تضمیم‌گیری مارکوف (MDP) با استفاده از پنج تابعی تعریف می‌شود، که در آن و به ترتیب فضای حالت و فضای کنش را نشان می‌دهند. نماد پاداشی است که عامل در ازای اعمال خود دریافت می‌کند و عامل تنزیل (discount factor) برای ایجاد توازن میان پاداش‌های آنی و آینده است. در نهایت، احتمال انتقال حالت را نشان می‌دهد، یعنی احتمال انتقال از یک حالت به حالت دیگر در نتیجه انجام یک کنش. در هر بازه زمانی، عامل حالت جاری را مشاهده می‌کند، بر اساس سیاست خود یک کنش را انتخاب می‌نماید و به حالت جدید منتقل می‌شود، در حالی که پاداش منتظر را دریافت می‌کند.

## B. فضای حالت

فضای حالت در بازه زمانی شامل موقعیت فعلی پهپاد، ضرایب تخصیص توان استگاه پایه، ماتریس تقویت RIS فعال و نرخ‌های مجموع قابل دستیابی است که به ترتیب با  $R[t] = R_c[t], \zeta, \varrho[t], \lambda[t]$  و  $R_e[t], R_r[t], \forall c, e$  نمایش داده می‌شوند. در نهایت، فضای حالت به صورت زیر تعریف می‌شود:

$$s_t = \{\varrho[t], \zeta, \vartheta[t], \mathbf{R}[t]\}. \quad (12)$$

در این مقاله، یک جارجوب تخصیص منابع مبنی بر یادگیری تقویتی عمیق برای شبکه‌های یکارچه زمینی-غیرزمینی (TN-NTN) با کیک RIS فعال و استفاده از CoMP-NOMA ارائه شد. سیستم پیشنهادی RIS فعال که با CoMP-NOMA یکارچه شده است، در مقایسه با RIS غیرفعال سنتی و پیکربندی‌های مبنی بر OMA، نرخ مجموع و بهره‌وری انرژی به مرائب بالاتری را محقق می‌کند. نتایج شبیه‌سازی نشان می‌دهند که ترکیب RIS فعال با CoMP-NOMA کلی می‌سیستم محسوب می‌شود. این یک گزینه بسیار کارآمد برای تخصیص منابع و بهبود عملکرد شبکه‌های عمیق می‌شود. این پیهودها به طور مشخص در معابرایی نظر نرخ مجموع، بهره‌وری انرژی، احتمال قطعی و عدالت میان کاربران قابل مشاهده هستند. در نهایت، این نتایج نشان می‌دهند که استفاده از RIS فعال در کار CoMP-NOMA و الگوریتم‌های DRL می‌تواند راهکاری مؤثر برای ارتقای عملکرد شبکه‌های نسل آینده باشد. به عنوان مسیرهای پژوهشی آینده، من توان ادغام فناوری‌های پرواذن انرژی با RIS فعال، یا استفاده از ارتباطات موج میلی‌متری (mmWave) و تراوهر را برای گشودن افق‌های جدید تحقیقاتی مورد بررسی قرار داد.

## ۶. قدردانی

این پژوهش به صورت جزئی توسط شورای ملی علوم و فناوری تایوان (National Science and Technology Council – NSTC)، جمهوری چین (R.O.C.)، تحت گرنت‌های NSTC 113-2622-E-194-003 و NSTC 113-2218-E-194-0112 حمایت شده است.

همچنین، این کار تا حدی توسط مؤسسه پیشرفت تولید با نوآوری‌های فناورانه (AIM-HI) در قالب برنامه مرکز پژوهشی حوزه‌های منتخب، در جارجوب پروژه ارتقای آموزش عالی (Higher Education) و پژوهش و تحقیقات و وزارت آموزش تایوان (MOE) پشتیبانی شده است.

بازیگر پیوسته، کشندهای پیوسته و را با نمونه‌برداری از توزیع‌های کاووسی که با میانگین و انحراف معبار خروجی شبکه پارامتردهی شده‌اند، تولید می‌کند؛ مطابق با سیاست تصادفی هر دو سیاست و به طور مستقل و با استفاده از توابع هدف کلیپ‌شده مربوطه بهینه‌سازی می‌شوند. تابع هدف برای کشندهای گسته به صورت زیر تعریف می‌شود:

$$L_{d}^{\text{CLIP}}(\theta_d) = \hat{\mathbb{E}}_t \left[ \min \left( r_t^d(\theta_d) \hat{A}_t, \mathcal{N}(r_t^d, \theta_d, \epsilon) \hat{A}_t \right) \right] \quad (16)$$

که در آن نسبت نمونه‌برداری اهمیت است و پارامتر کلیپ‌سازی می‌باشد. اهداف بهینه‌سازی سیاست‌های گسته و پیوسته از یکدیگر جدا هستند؛ بدین معنا که به عنوان توزیع‌های مستقل در فرآیند بهینه‌سازی سیاست در نظر گرفته می‌شوند، نه یک توزیع مشترک شامل هر دو فضای کشنده. خلاصه الگوریتم H-PPO در الگوریتم ۱ ارائه شده است.

## ۷. نتایج شبیه‌سازی

## ۷.۱. تنظیمات شبیه‌سازی

به منظور ارزیابی اثربخشی جارجوب پیشنهادی RIS فعال در یک شبکه، CoMP-NOMA، یک نمایش مجازی از یک محیط شهری ایجاد می‌شود که شامل ایستگاه پایه،  $c=3$  کاربر،  $L=0$  آمی باشد. موقعیت اولیه پیچاد برای  $b$  با  $[30, 30, 20], [20, 30, 20], [0, 40, -5]$  متر می‌باشد. هر ایستگاه پایه با یک سطح توان منحصر به فرد می‌کند که با برای هر ایستگاه پایه تفاوت دارد که شود، به طوری که سایر اجرای سیستم، شامل کاربران، به صورت تصادفی در محیط توزیع شده‌اند. شبکه در فرکانس حامل  $B=10$  MHz و  $f=2.4$  GHz می‌باشد. توان نویز به صورت زیر تعریف می‌شود  $\sigma^2 = 174 + \log_{10}(B) dBm$ . برای در نظر گرفتن اثرات تضعیف، توان‌های تلفات مسیر به صورت زیر انتخاب شده‌اند  $\beta_n = 3.7$ ،  $\beta_s = 2.2$ ،  $\beta_o = 3.0$ ،  $\beta_k = 3.3$ ،  $\beta_r = 3.7$ . تحقیق مستقل از موقعیت کاربران هستند تا معابرایی عملکرد قابل اعتمادی به دست آید.

## ۷.۲. نتایج عددی

در شکل ۲(a)، رابطه بین توان ارسال ایستگاه پایه، که در بازه قرار دارد، و نرخ مجموع مورد بررسی قرار گرفته است. در این تحلیل، مقایسه‌ای بین پیکربندی‌های مختلف H-PPO-RIS فعال را بر حسب نتایج تقویت RIS در مقادیر نرخ  $7 bps/Hz$  و  $H-PPO A-RIS$ ،  $PPO P-RIS$ ،  $H-PPO P-RIS$ ،  $H-PPO A-RIS$ ،  $PPO P-RIS$ ،  $H-PPO P-RIS$  به ترتیب به  $15$  و  $20$   $bps/Hz$  می‌رسد. زمانی که  $25$  dBm باشد. این امر نشان دهنده بهبود  $33\%$  در نرخ مجموع است که توانایی تقویت RIS فعال، در ترکیب با هر نمایش مجازی و عملکردی بهتر از پیکربندی‌های غیرفعال ارائه می‌دهد. بررسی ما همچنین به کاربری الگوریتم یادگیری برای بهینه‌سازی انرژی گشترش یافته است. در شکل ۲(b)، روند تغییرات پاداش در طول چندین کام آموزشی نشان داده شده است. پیکربندی H-PPO-NOMA رشد تندتری را از مقدار ۰.۲ تا ۱.۰ نشان می‌دهد که بیانگر کارایی بالاتر یادگیری و مدیریت بهینه‌تر انرژی در NOMA است. علاوه بر این، احتمال قطعی  $(Outage Probability)$  پیکربندی‌های مختلف نیز مورد ارزیابی قرار گرفته است. در شکل ۲(c)، برای مقادیر  $p_i$  در بازه  $-30$  تا  $-10$  dBm، تا  $1$ -احتمال قطعی تمامی پیکربندی‌ها برای بدترین نرخ کاربران تقریباً یکسان باقی می‌ماند. پیکربندی H-PPO A-RIS NOMA در مقدار کمترین احتمال قطعی برای بازتاب  $0.20$  را نشان می‌دهد. که بیانگر افزایش نرخ بدترین کاربر تا می‌باشد و از تهابی پیکربندی‌های دیگر عملکرد بهتری دارد. در شکل ۳(a)، رابطه بین بهره‌وری انرژی و بهره‌وری طیفی برای پیکربندی‌های مختلف نشان داده شده است. پیکربندی H-PPO A-RIS NOMA با بالاترین عملکرد را ارائه می‌دهد و به حداقل بهره‌وری انرژی  $/J$  ۱۱,۵۰۰ bit/۱۱,۵۰۰ bits/s/Hz این بهبود ناشی از توانایی RIS فعال در تنظیم پویای بازتاب‌ها بوده و با راهبرد NOMA تقویت شده است، که در مجموع  $20\%$  بهبود نسبت به پیکربندی‌های RIS غیرفعال را نشان می‌دهد. در شکل ۳(b)، نرخ مجموع برای پیکربندی‌های مختلف بایز افزایش تعداد عناصر RIS بررسی شده است. تعداد عناصر RIS از ۳۰۰ تا K افزایش می‌باید که نشان می‌دهد افزودن عناصر بیشتر به RIS، توانایی سیستم را در بهینه‌سازی بازتاب‌ها افزایش می‌دهد. در تهابی مقادیر K، پیکربندی H-PPO A-RIS NOM بیشترین مقدار  $R_K$  را نشان می‌دهد که مزیت استفاده از RIS فعال همراه با NOMA را برجسته می‌کند. در نهایت، شکل ۳(c) رابطه بین توان ارسال هر ایستگاه پایه و نرخ مجموع را برای پیکربندی‌های مختلف RIS، در حالاتی با عدالت و بدون عدالت، نشان می‌دهد. با افزایش از  $-5$  dBm تا  $-25$  dBm نرخ مجموع برای تهابی پیکربندی‌های افزایش می‌باشد. در حالتی که توزیع توان به صورت بکواخت بین کاربران مركب و لبه انجام شود، اعمال عدالت منجر به کاهش جزوی نرخ مجموع می‌شود. با این حال، پیکربندی H-PPO A-RIS NOMA در حالت همراه با عدالت، همچنان بهترین عملکرد را در میان تهابی پیکربندی‌ها ارائه می‌دهد.

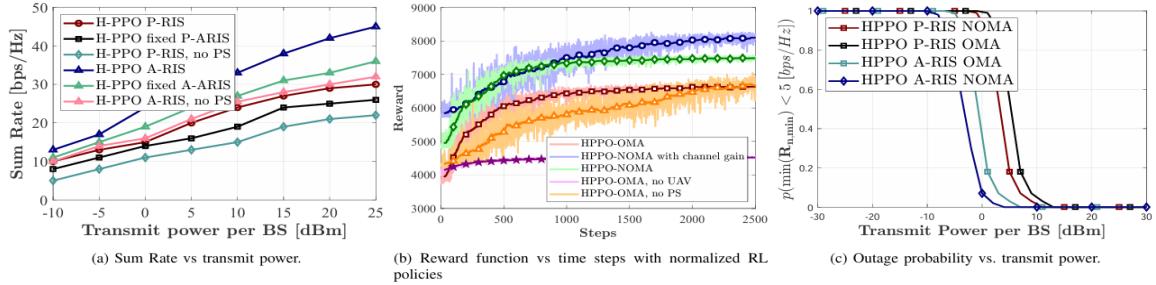


Fig. 2: (a) Sum rate performance for baseline methods [OMA, Brute Force and RL-NOMA] varying transmit power, (b) Training convergence of reward functions for various RL configurations over timesteps, (c) Outage probability comparison against transmit power per base station for NOMA and OMA base.

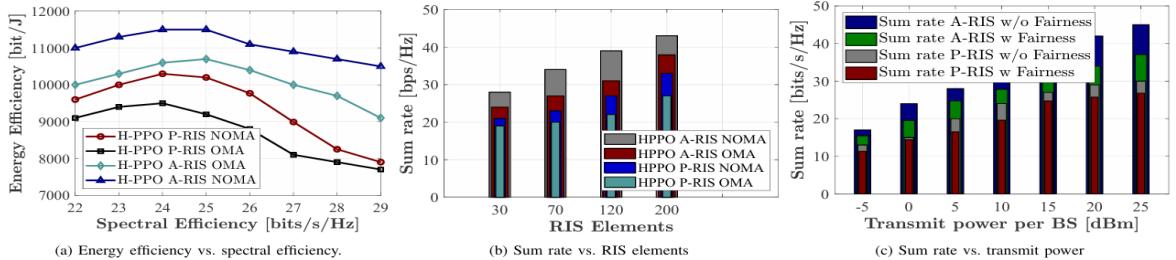


Fig. 3: (a) Energy efficiency comparison against spectral efficiency between different RIS configuration , (b) Sum rate comparison with RIS elements n belong to [30,70,120,200] for different RIS configuration (c) Sum rate comparison against baseline methods [DRL NOMA (w and w/o fairness), OMA].

inGLOBECOM2022- 2022 IEEE Global Communications Conference, 2022, pp. 1618–1624.

[8] S. Ammar, C. P. Lau, and B. Shihada, “An in-depth survey on virtualization technologies in 6G integrated terrestrial and non-terrestrial networks,” IEEE Open Journal of the Communications Society, 2024.

[9] M. Bilal, S. F. Zahra, H. Rizwan, T. Umar, S. A. Hassan, H. Jung, and K. Dev, “Single versus double IRS-assisted networks: A comparative analysis using practical phase shifting,” in 2024 IEEE Wireless Communications and Networking Conference (WCNC), 2024, pp. 1–5.

[10] M. Elhattab, M. A. Arfaoui, C. Assi, and A. Ghayeb, “RIS-assisted joint transmission in two-cell downlink NOMA cellular system,” IEEE Journal on Selected Areas in Communications, vol. 40, no. 4, pp. 1270–1286, 2022.

[11] M. Obeed, H. Dahirouj, A. M. Salhab, S. A. Zummo, and M.-S. Alouini, “User pairing, link selection, and power allocation for cooperative NOMA hybrid VLC/RF systems,” IEEE Transactions on Wireless Communications, vol. 20, no. 3, pp. 1785–1800, 2021.

[12] Z. Shi, H. Lu, X. Xie, H. Yang, C. Huang, J. Cai, and Z. Ding, “Active RIS-aided EH-NOMA networks: A deep reinforcement learning approach,” IEEE Transactions on Communications, vol. 71, no. 10, pp. 5846–5861, 2023.

[13] V. Mnih, A. P. Badia, M. Mirza, A. Graves, T. Lillicrap, T. Harley, D. Silver, and K. Kavukcuoglu, “Asynchronous methods for deep reinforcement learning,” in Proceedings of The 33rd International Conference on Machine Learning, M. F. Balcan and K. Q. Weinberger, Eds., vol. 48, 2016, pp. 1928–1937.

[1] M. Harounabadi and T. Heyn, “Toward integration of 6G-NTN to terrestrial mobile networks: Research and standardization aspects,” IEEE Wireless Communications, vol. 30, no. 6, pp. 20–26, 2023.

[2] Y. Liu, X. Mu, X. Liu, M. Di Renzo, Z. Ding, and R. Schober, “Reconfigurable intelligent surface-aided multi-user networks: Interplay between NOMA and RIS,” IEEE Wireless Communications, vol. 29, no. 2, pp. 169–176, 2022.

[3] M. Umer, M. A. Mohsin, S. A. Hassan, H. Jung, and H. Pervaiz, “Performance analysis of STAR-RIS enhanced CoMP-NOMA multi-cell networks,” in 2023 IEEE Globecom Workshops (GC Wkshps), 2023, pp. 2000–2005.

[4] Y. Ge and J. Fan, “Active reconfigurable intelligent surface assisted secure and robust cooperative beamforming for cognitive satellite terrestrial networks,” IEEE Transactions on Vehicular Technology, vol. 72, no. 3, pp. 4108–4113, 2022.

[5] R. H. Ratul, M. Iqbal, T. Ashraf, J.-Y. Pan, Y.-H. Wang, and S.-Y. Lien, “Adaptive three layer hybrid reconfigurable intelligent surface for 6G wireless communication: Trade-offs and performance,” in 2023 IEEE Asia-Pacific Conference on Wireless and Mobile (APWiMob), 2023, pp. 232–236.

[6] H. Mei, K. Yang, Q. Liu, and K. Wang, “3D-Trajectory and Phase Shift Design for RIS-Assisted UAV Systems Using Deep Reinforcement Learning,” IEEE Transactions on Vehicular Technology, vol. 71, no. 3, pp. 3020–3029, 2022.

[7] Z. Zhang, L. Dai, X. Chen, C. Liu, F. Yang, R. Schober, and H. V. Poor, “Active RISs: Signal modeling, asymptotic analysis, and beamforming design,”

