

یادگیری فدره‌ای برای نسل ششم (G6): پارادایم‌ها، طبقه‌بندی، پیشرفت‌های اخیر و دیدگاه‌ها

Maryam Ben Driss*, Student Member, IEEE, Essaid Sabir*, Senior Member, IEEE, Halima Elbiaze, Senior Member, IEEE, Walid Saad*, Fellow Member, IEEE, °Department of Computer Science, University of Quebec at Montreal (UQAM), Montreal, H2L 2C4, Canada *WirelessVT, Bradley Department of Electrical and Computer Engineering, Virginia Tech, Arlington, VA, USA

• نیاز به ارتباط بیشتر: سیستم‌های هوش مصنوعی با توانایی پردازش حجم عظیمی از داده‌ها و یادگیری از تعاملات، به‌طور قابل توجهی به دسترس‌پذیرتر، کارآمدتر، و شخصی‌تر شدن ارتباطات کمک می‌کند تا نیازهای متنوع و روبه‌رشد کاربران و کاربردهای مدرن برآورده شود.

تحقیقات اخیر بسیاری بر بررسی مسائل اصلی شبکه‌های بی‌سیم متمرکز بوده‌اند که با استفاده از تکنیک‌های مختلف یادگیری ماشین مورد توجه قرار گرفته‌اند؛ مانند مدیریت و اشتراک طیف، تخصیص منابع، پیش‌بینی کانال‌های محوشده، و پیش‌بینی ترافیک. با این حال، به‌کارگیری طرح‌های سنتی یادگیری ماشین در سیستم‌های بزرگ‌مقیاس همچنان چالش‌برانگیز است، به دلایل زیر (فهرست غیرجامع):

• مقیاس‌پذیری: سیستم‌های بزرگ‌مقیاس معمولاً حجم عظیمی از داده‌ها را مدیریت می‌کنند و به محاسبات پیچیده نیاز دارند. در رویکرد متمرکز، همه داده‌ها در یک سرور جمع‌آوری و پردازش می‌شوند که منجر به گلوگاه عملکرد و افزایش زمان پردازش می‌گردد.

• بار اضافی ارتباطی: در طرح متمرکز، داده‌ها از منابع مختلف باید به سرور مرکزی منتقل شوند تا پردازش شوند. این امر منجر به بار ارتباطی قابل توجهی می‌شود، به‌ویژه زمانی که با منابع داده‌ای پراکنده جغرافیایی سروکار داریم.

• نقطه شکست واحد: سیستم‌های متمرکز یک نقطه شکست واحد دارند. هرگونه خرابی در سرور کل فرآیند یادگیری ماشین را تحت تأثیر قرار می‌دهد. این آسیب‌پذیری برای کاربردهای بلندرنج یا مأموریت‌حیاتی که نیازمند عملکرد مداوم و قابل اعتماد هستند، بسیار بحرانی است.

• نگرانی‌های حریم خصوصی و امنیت: یادگیری ماشین متمرکز شامل جمع‌آوری و ذخیره داده‌ها از منابع متعدد در یک مکان مرکزی است. این موضوع نگرانی‌های جدی درباره حریم خصوصی و امنیت ایجاد می‌کند، زیرا داده‌های حساس بدون اقدامات امنیتی مناسب در معرض خطر قرار می‌گیرند.

• تأخیر و نیازهای بلندرنج: برای کاربردهای بلندرنج یا کم‌تأخیر، رویکرد متمرکز قابل اجرا نیست، زیرا پردازش و انتقال داده به سرور مرکزی زمان زیادی می‌برد.

• هزینه و زیرساخت: ساخت و نگهداری زیرساخت یادگیری ماشین متمرکز برای سیستم‌های بزرگ‌مقیاس پرهزینه است. این کار نیازمند توان محاسباتی قابل توجه، فضای ذخیره‌سازی، و منابع شبکه برای مدیریت حجم داده‌ها و محاسبات مربوطه می‌باشد.

برای رفع این محدودیت‌ها، مفهوم یادگیری فدره‌ای (FL) اخیراً پیشنهاد شده است؛ رویکردی مؤثر برای آموزش مدل یادگیری ماشین به‌صورت توزیع‌شده. FL به چندین دستگاه یا گره اجازه می‌دهد تا بدون اشتراک‌گذاری داده‌های محلی، به‌طور مشترک یک مدل جهانی را آموزش دهند. در یادگیری ماشین سنتی، داده‌ها از منابع مختلف جمع‌آوری شده، به سرور مرکزی ارسال می‌شوند، و سپس برای آموزش مدل جهانی استفاده می‌گردند. اما در FL، فرآیند آموزش مستقیماً روی دستگاه‌ها یا گره‌های منفرد انجام می‌شود، بدون اشتراک‌گذاری داده‌های خام. چارچوب FL رویکردی نویدبخش برای سیستم‌های بی‌سیم آینده است، زیرا مزایای پردازش توزیع‌شده، حفظ حریم خصوصی، مقیاس‌پذیری، و سازگاری را ترکیب می‌کند. این چارچوب تکامل ارتباطات بی‌سیم را توانمند می‌سازد و توسعه برنامه‌های نوآورانه و داده‌محور را به‌صورت کارآمدتر و امن‌تر ممکن می‌سازد. با این حال، به‌دلیل ماهیت توزیع‌شده و پویا در شبکه‌های بی‌سیم، محدودیت‌هایی برای پیاده‌سازی FL وجود دارد. برخی از چالش‌های کلیدی عبارتند از:

چکیده - هوش مصنوعی (AI) انتظار می‌رود نقش اساسی در نسل بعدی سیستم‌های بی‌سیم، مانند شبکه‌های موبایل نسل ششم (G6)، ایفا کند. با این حال، حجم عظیم داده‌ها، مصرف انرژی، پیچیدگی آموزش، و حفاظت از داده‌های حساس در سیستم‌های بی‌سیم، همگی چالش‌های حیاتی هستند که باید برای آموزش مدل‌های هوش مصنوعی و جمع‌آوری دانش و اطلاعات از دستگاه‌های توزیع‌شده برطرف شوند. یادگیری فدره‌ای (FL) یک چارچوب جدید است که به‌عنوان رویکردی نویدبخش مطرح شده تا چندین عامل یادگیرنده بتوانند بدون اشتراک‌گذاری داده‌های خام، مدل‌های یادگیری ماشین دقیق و مقاوم بسازند. با فراهم کردن امکان یادگیری مشترک یک مدل جهانی توسط گوشی‌های همراه و دستگاه‌ها، بدون اشتراک مستقیم داده‌های آموزشی، FL سطح بالایی از حفظ حریم خصوصی و بهره‌برداری کارآمد از طیف فرکانسی را نشان می‌دهد. اگرچه مقالات مروری زیادی به بررسی پارادایم‌های FL و کاربرد آن در حفظ حریم خصوصی در G6 پرداخته‌اند، هیچ‌کدام به‌طور شفاف توضیح نداده‌اند که FL چگونه می‌تواند برای بهبود پشته پروتکل و عملیات بی‌سیم استفاده شود. هدف اصلی این مرور، ارائه یک دیدگاه جامع درباره قابلیت استفاده FL برای ارتقای خدمات موبایل و ایجاد اکوسیستم‌های هوشمند جهت پشتیبانی از کاربردهای نوین است. این مقاله ارزش افزوده‌ی پیاده‌سازی FL در تمامی سطوح پشته پروتکل را بررسی می‌کند. همچنین کاربردهای مهم FL را معرفی کرده، موضوعات داغ را مطرح می‌نماید، پیش‌های ارزشمند و راهنمایی‌های صریح برای تحقیقات و توسعه‌های آینده ارائه می‌دهد. نتیجه‌گیری ما بر آن است که هم‌افزایی بین FL و G6 آینده را تقویت کرده و پتانسیل FL برای متحول کردن صنعت بی‌سیم و پشتیبانی از توسعه خدمات موبایل پیشرفته را برجسته سازد.

واژگان کلیدی - هوش مصنوعی؛ یادگیری فدره‌ای؛ یادگیری ماشین غیرمتمرکز؛ حریم خصوصی؛ لایه فیزیکی؛ لایه MAC؛ لایه شبکه؛ لایه انتقال؛ لایه کاربرد؛ شبکه‌های سلولی؛ G6

I. مقدمه

A. هوش مصنوعی برای شبکه‌های بی‌سیم

هوش مصنوعی (AI) انتظار می‌رود نقش برجسته‌ای در سیستم‌های بی‌سیم کنونی و آینده، مانند نسل پنجم (G5) و نسل ششم (G6)، ایفا کند. در واقع، سیستم‌های G6 به‌عنوان سیستم‌های AI-native تصور می‌شوند؛ یعنی نوعی از هوش مصنوعی در سراسر پشته پروتکل برای خودکارسازی پیاده‌سازی خواهد شد. به‌عنوان نمونه، انتظار می‌رود هوش مصنوعی چارچوب‌های جدیدی برای بهبود شاخص‌های عملکرد شبکه‌های بی‌سیم فراهم کند، از جمله: ظرفیت، تأخیر، کارایی، توان، فرکانس طیف، انعطاف‌پذیری، سازگاری، و کیفیت تجربه کاربر. تکنیک‌های هوش مصنوعی بر سیستم‌های شبکه نسل بعدی تأثیر خواهند گذاشت، به دو دلیل کلیدی:

• نیاز به خودمختاری بیشتر: تکنیک‌های یادگیری ماشین (ML) برای مجهز کردن سیستم‌های بی‌سیم به خودمختاری و استقلال ضروری هستند. این کار با تحلیل داده‌های بلندرنج مانند الگوهای ترافیک، رفتار کاربران، و عوامل محیطی انجام می‌شود تا تصمیمات هوشمندانه‌ای برای بهینه‌سازی منابع شبکه، مسیریابی، و بالانس بار گرفته شود. این سطح از مدیریت پویا به سیستم‌های بی‌سیم اجازه می‌دهد بدون دخالت دستی با شرایط متغیر سازگار شوند.

Section VI : Federated learning at APP/Transport layers

- A. Transport performance
- B. Cooperative and distributed computing
- C. Crowdsourcing and crowdsensing
- D. Quality of experience
- E. Cybersecurity

Section VII : Federated learning verticals and applications

- A. Autonomous driving
- B. Anomaly detection
- C. Industrial operations
- D. Ultra reliable low latency communications
- E. Tactile internet
- F. Virtual/Augmented/Extended reality and Metaverse
- G. Smart healthcare
- H. Recommendation system

Section VIII : Insights and open problems

- A. Lessons learned
- B. Federated learning challenges
- C. Wireless challenges for federated learning
- D. Hot topics and insights

Section IX : Conclusion

1. ارائه یک پیش‌زمینه جامع درباره پارادایم‌های اخیر یادگیری فدرال (FL)، طبقه‌بندی و تکنیک‌های اصلی؛

2. مقایسه یادگیری ماشینی متمرکز، یادگیری ماشینی توزیع‌شده، و FL در زمینه محیط‌های عظیم و حساس، همراه با برجسته‌سازی ویژگی‌ها و مسائل مرتبط با هر رویکرد؛

3. بررسی جدیدترین طرح‌های FL که هدفشان حل مسائل عمده در لایه فیزیکی (PHY)، کنترل دسترسی به رسانه (MAC)، شبکه (NET)، انتقال (Transport)، و کاربرد (APP) است، در حالی که دقت بالا، کارایی ارتباطی بهبود یافته و مصرف انرژی پایین را محقق می‌سازند. همچنین تحلیل دقیقی از مزایا و معایب هر کاربرد/راه‌حل ارائه می‌دهیم؛

4. بحث درباره بینش‌های مرتبط و مسائل باز مربوط به کاربرد FL در G6 و شبکه‌های موبایل آینده.

برای تجربه خواندن بهتر، این مرور همان‌طور که در شکل 1 نشان داده شده سازمان‌دهی شده است. بخش II معماری‌های یادگیری ماشینی و چالش‌های آن‌ها را در زمینه سیستم‌های بی‌سیم ارائه می‌کند. در بخش III، مرور جامعی از اصول FL، ویژگی‌ها، طبقه‌بندی، چارچوب‌ها، مزایا و مسائل آن ارائه می‌دهیم. سپس در بخش IV، V و VI به بررسی FL در عملیات بی‌سیم می‌پردازیم، با تمرکز بر لایه‌های PHY/MAC، NET و Transport/APP. در ادامه، بخش VII کاربردها و حوزه‌های عمودی اخیر FL را معرفی می‌کند. سپس بخش VIII درس‌های آموخته‌شده را خلاصه کرده و بحث دقیقی درباره مسائل باز FL بی‌سیم که باید برای ادغام موفق در G6 و سیستم‌های آینده برطرف شوند ارائه می‌دهد. در نهایت، برخی مسیرهای نویدبخش برای تحقیقات آینده به‌سوی شبکه‌سازی کارآمد و AI-native را برجسته می‌کنیم.

II. معماری‌های یادگیری ماشینی

در اینجا، مروری بر معماری‌های یادگیری ماشینی شامل یادگیری متمرکز سنتی، یادگیری توزیع‌شده و FL ارائه می‌دهیم.

A. یادگیری ماشینی متمرکز

یادگیری ماشینی علمی است که به رایانه‌ها امکان می‌دهد بدون برنامه‌نویسی صریح یاد بگیرند. این شاخه از هوش مصنوعی به سیستم‌ها اجازه می‌دهد الگوها را در داده‌ها شناسایی کنند، تصمیم‌گیری کنند، و نتایج آینده را پیش‌بینی نمایند. تکنیک‌های استاندارد یادگیری ماشینی نیاز دارند داده‌ها روی یک ماشین منفرد ذخیره شوند تا پردازش و آموزش مدل انجام شود (شکل 2.1). امروزه، برنامه‌های اینترنت اشیا (IoT) از یادگیری ماشینی سنتی استفاده می‌کنند، به

• پهنای باند محدود: انتقال به‌روزرسانی‌های مدل بین سرور مرکزی و دستگاه‌های لبه منابع زیادی مصرف می‌کند و منجر به افزایش بار ارتباطی می‌شود.

• اتصال غیرقابل اعتماد: مدیریت مشارکت دستگاه‌هایی با سطح اتصال و قابلیت‌های متفاوت نیازمند مکانیزم‌های مقاوم برای همگام‌سازی و ارتباط است.

• محدودیت‌های محاسباتی: کلانیت‌های مشارکت‌کننده معمولاً توان محاسباتی محدودی دارند که می‌تواند بر سرعت همگرایی و عملکرد کلی مدل تأثیر بگذارد.

• عدم توازن و داده‌های غیر IID: در شبکه‌های بی‌سیم، داده‌های جمع‌آوری‌شده توسط دستگاه‌های لبه معمولاً نامتوازن یا غیرمستقل و غیرهم‌توزیع (non-IID) هستند، که چالش‌هایی برای همگرایی و تعمیم مدل ایجاد می‌کند.

رفع این چالش‌ها نیازمند ترکیبی دقیق از پیشرفت‌های الگوریتمی، تکنیک‌های بهینه‌سازی، و طراحی معماری است تا FL در محیط‌های بی‌سیم قابل اجرا و مؤثر باشد. با تکامل این حوزه، پژوهشگران همچنان در تلاش‌اند تا بر این چالش‌ها غلبه کنند و پیاده‌سازی‌های عملی و امن را در شبکه‌های بی‌سیم آینده ممکن سازند.

B. مروری مرتبط و سهم ما

اگرچه مقالات مروری زیادی درباره FL و شبکه‌های بی‌سیم وجود دارد، همان‌طور که در جدول I خلاصه شده است، اما هیچ‌کدام به‌طور کامل به کاربرد آن در سراسر پشته پروتکل نپرداخته‌اند یا بررسی دقیقی از کاربردهای FL در هر لایه مدل OSI ارائه نداده‌اند. این مرور قصد دارد این شکاف را پر کند، با ارائه یک دیدگاه عمیق درباره چگونگی پیاده‌سازی FL در کل پشته پروتکل. همچنین مزایای مرتبط را برجسته کرده و چالش‌های ناشی از آن را مورد بحث قرار می‌دهد. مشارکت‌های پیشرفته‌ای که از طرح‌های یادگیری ماشینی فدرال برای حل مشکلات در ارتباطات بی‌سیم استفاده کرده‌اند، گردآوری و بررسی شده‌اند. مشارکت‌های اصلی ما شامل موارد زیر است:

Section I : Introduction

- A. Artificial intelligence for wireless
- B. Relevant surveys and our contribution

Section II : Background on machine learning architectures

- A. Centralized machine learning
- B. Decentralized machine learning
- C. Federated machine learning

Section III : Federated learning fundamentals

- A. Federated learning life cycle
- B. Different flavors of federated learning
- C. Federated learning algorithms

Section IV : Federated learning at PHY/MAC layers

- A. Symbol and signal detection
- B. Channel estimation
- C. Channel state information
- D. Beamforming
- E. Reconfigurable intelligent surfaces
- F. Channel access
- G. Spectrum sharing

Section V : Federated learning at NET layer

- A. Traffic classification
- B. Resource management
- C. Radio access network
- D. User mobility/location prediction
- E. Network slicing
- F. Routing optimization
- G. Unmanned aerial vehicle
- H. Underwater networks
- I. Cloud and fog computing

شایان ذکر است که رویکردهای غیرمتمرکز، مانند یادگیری لبه‌ای (Edge ML)، طراحی شده‌اند تا برخی از چالش‌های تکنیک‌های یادگیری ماشینی متمرکز را برطرف کنند.

B. یادگیری ماشینی غیرمتمرکز

مفهوم یادگیری ماشینی غیرمتمرکز به عنوان یک راه‌حل مؤثر برای رفع چالش‌های کلیدی ذکر شده در بخش II.A پیشنهاد شد. همان‌طور که در شکل 2.2 نشان داده شده، رویکرد یادگیری غیرمتمرکز وظایف محاسباتی و پردازش داده را در میان چندین دستگاه غیرمتمرکز توزیع می‌کند، به جای آنکه به یک سرور مرکزی متکی باشد. این رویکرد چندین مزیت دارد، از جمله:

- ساده‌سازی یادگیری: هر دستگاه تنها به مجموعه داده خودش نیاز دارد و اطلاعات بسیار کمی با شرکت‌کنندگان خارجی به اشتراک می‌گذارد.
- سازگاری با تغییرات در طول زمان: یادگیری بدون محدودیت اتصال اینترنت یا وابستگی به یک دستگاه مرکزی امکان‌پذیر می‌شود.
- حفظ داده‌های حساس در محل: داده‌های حساس روی دستگاه‌های محلی یا سرورهای لبه باقی می‌مانند و به مکان مرکزی منتقل نمی‌شوند. این امر حریم خصوصی و امنیت داده‌ها را افزایش می‌دهد.

به‌طور کلی، یادگیری لبه‌ای سیستم‌های ارتباطی بی‌سیم را توانمند می‌سازد تا داده‌ها را به‌طور کارآمد مدیریت کنند، زمان پاسخ را بهبود دهند، حریم خصوصی را ارتقا دهند، و برنامه‌های مقاوم‌تر و مقیاس‌پذیرتر ایجاد کنند. این ویژگی‌ها یادگیری لبه‌ای را به فناوری ارزشمندی برای اکوسیستم‌های در حال رشد اینترنت اشیاء (IoT) و 5G تبدیل می‌کند.

با این وجود، چالش‌های مختلفی وجود دارد که مانع می‌شوند مدل‌های محلی تولید شده بتوانند از داده‌های هم‌تایان خود بهره‌مند شوند و از تجربیات خارجی یاد بگیرند، مانند:

- ناهمگونی داده‌ها: در محیط‌های بزرگ‌مقیاس، داده‌های جمع‌آوری شده از منابع مختلف توزیع‌های متنوعی دارند، که ترکیب و تجمیع مؤثر مدل‌ها را دشوار می‌سازد.
- بار اضافی ارتباطی: تبادل به‌روزرسانی‌های مدل میان گره‌های توزیع شده بار ارتباطی ایجاد می‌کند، به‌ویژه در شبکه‌هایی که محدودیت پهنای باند دارند.

این صورت که داده‌ها از حسگرهای IoT به فضای ابری بارگذاری می‌شوند. سرور ابری یک مدل جهانی را با استفاده از داده‌های چندین دستگاه آموزش می‌دهد و امکان تعامل فوری با سایر شرکت‌کنندگان را فراهم می‌سازد. با این حال، یادگیری ماشینی متمرکز از مشکلات متعددی رنج می‌برد، به‌ویژه در محیط‌های بی‌سیم. در ادامه، فهرستی غیرجامع از این محدودیت‌ها ارائه می‌شود:

• مشکلات حریم خصوصی: یادگیری متمرکز شامل جمع‌آوری و ذخیره داده‌های حساس از منابع مختلف است، که نگرانی‌های جدی درباره حریم خصوصی ایجاد می‌کند و به عنوان هدفی بالقوه برای دسترسی غیرمجاز مطرح می‌شود.

• مشکلات تأخیر: در یادگیری متمرکز، داده‌ها از دستگاه‌های منفرد به سرور مرکزی منتقل می‌شوند. این انتقال داده باعث ایجاد تأخیر می‌شود، که در کاربردهایی مانند ارتباطات بلادرنگ، وسایل نقلیه خودران، یا اتوماسیون صنعتی بسیار نامطلوب است.

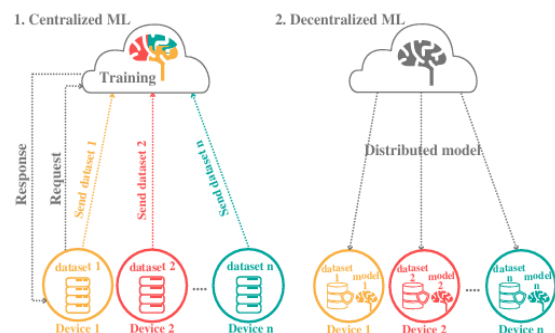


Fig. 2. Centralized ML has to store data in one data center. Decentralized ML distributes the model across connected devices.

وسایل نقلیه یا اتوماسیون صنعتی، جایی که تأخیر پایین حیاتی است.

• هزینه‌ها: نگهداری و بهره‌برداری از سرورهای متمرکز با توان محاسباتی و ظرفیت ذخیره‌سازی موردنیاز برای یادگیری ماشینی در مقیاس بزرگ، برای اپراتورهای شبکه بسیار پرهزینه است.

Ref	Year	Target application	Basics	PHY Layer	NET layer	Transport Layer	APP Layer	Challenges
[32]	2020	FL in mobile edge networks	✓	✓		✓		✓
[33]	2020	FL for wireless communications	✓	✓				✓
[34]	2020	Distributed ML for communication networks	✓	✓			✓	✓
[35]	2020	FL and wireless communications	✓				✓	✓
[36]	2021	ML and FL for handover management in 5G	✓		✓			✓
[37]	2021	Federated machine learning for 6G	✓	✓			✓	
[38]	2021	FL for physical layer	✓	✓				
[39]	2021	FL in networking systems	✓		✓			✓
[40]	2021	Federated learning for IoT	✓		✓		✓	✓
[41]	2021	Recent advances of FL for IoT networks	✓	✓			✓	✓
[42]	2021	Federated ML for big data	✓				✓	✓
[43]	2021	Intelligence for 6G using FL	✓	✓			✓	✓
[44]	2021	The internet of federated things	✓				✓	✓
[45]	2022	From distributed ML to FL	✓					
[46]	2022	FL and next-generation communications	✓	✓	✓			✓
[47]	2022	FL attacks and threats	✓					✓
[48]	2022	Federated learning fundamentals	✓					✓
[49]	2022	FL for intrusion detection	✓				✓	✓
[50]	2022	FL for IoT and cybersecurity	✓				✓	✓
[51]	2022	The application of FL in smart cities	✓					✓
[52]	2023	FL challenges and applications	✓					✓
[53]	2023	Trends and challenges of FL for 6G	✓				✓	✓
[54]	2023	Communication efficiency in FL	✓	✓				✓
Our work	2023	Multilayered survey on FL for B5G and 6G	✓	✓	✓	✓	✓	✓

TABLE I
RELATED EXISTING SURVEY PAPERS ON FL FOR NETWORK COMMUNICATIONS.

Goal	Distributed model training without centralized data collection and with privacy guarantees
Setting	K devices, out of which C are selected ($C \leq K$)
Parameters	<ul style="list-style-type: none"> Batch size Number of clients Local iterations
Orchestration	A central orchestration server or service organizes the training but never sees raw data.
Advantages	<ul style="list-style-type: none"> Respecting user's privacy Minimum hardware required Saving user's resources Working offline Computing in real-time Decreasing training complexity

TABLE II
FL CONCEPTS.

در حالی که از هوش جمعی موجودیت‌های غیرمتمرکز برای بهبود عملکرد مدل و مقیاس‌پذیری بهره‌برداری می‌شود.

III. اصول یادگیری فدرال

پیش از بررسی کاربردهای FL در سیستم‌های بی‌سیم، لازم است مرور کوتاهی بر مفاهیم، طبقه‌بندی و تکنیک‌های FL ارائه شود. مفاهیم اصلی FL در جدول II خلاصه شده‌اند.

A. چرخه زندگی یادگیری فدرال

فرآیند FL معمولاً توسط یک مهندس که مدلی برای یک کاربرد خاص توسعه می‌دهد هدایت می‌شود. همان‌طور که در شکل 5 نشان داده شده، جریان کاری FL به‌طور کلی شامل چهار مرحله متوالی است:

- انتخاب مدل: مدل جهانی و پارامترها روی یک سرور مرکزی آغاز می‌شوند و با همه شرکت‌کنندگان به اشتراک گذاشته می‌شوند.
- آموزش مدل محلی: کلاینت‌ها مدل را به‌صورت محلی با استفاده از داده‌های خود آموزش می‌دهند، بدون آنکه داده‌ها را با سرور مرکزی یا سایر کلاینت‌ها به اشتراک بگذارند.
- تجمع مدل‌های محلی: به‌روزرسانی‌ها به سرور مرکزی ارسال می‌شوند تا پارامترهای دریافت‌شده تجمع شده و یک مدل جهانی جدید ساخته شود.
- توزیع مدل جهانی: مدل جهانی جدید میان شرکت‌کنندگان توزیع می‌شود تا چرخه بعدی آغاز گردد.

B. انواع مختلف یادگیری فدرال

چارجوب‌های FL بر اساس توزیع نمونه‌های داده و ویژگی‌ها به سه نوع تقسیم می‌شوند: افقی، عمودی، و یادگیری انتقالی فدرال.

(1) یادگیری فدرال افقی (HFL یا Horizontal FL): این نوع FL در سناریوهایی به‌کار می‌رود که مجموعه داده‌ها فضای ویژگی مشابهی دارند اما در نمونه‌ها متفاوت هستند. به عبارت دیگر، دستگاه‌های کلاینت شرکت‌کننده ویژگی‌های مشابهی دارند اما جمعیت‌های متفاوتی را هدف قرار می‌دهند. برای مثال، دو بانک در یک کشور را در نظر بگیرید؛ مشتریان این دو بانک همپوشانی ندارند، اما داده‌های آن‌ها احتمالاً فضای ویژگی مشابهی دارد چون هر دو کسب‌وکار مشابهی دارند و در یک کشور فعالیت می‌کنند. تقسیم‌بندی بر اساس نمونه‌ها معمولاً زمانی کاربرد دارد که یک شرکت به دلیل محدودیت‌های قانونی نمی‌تواند داده‌های خود را متمرکز کند

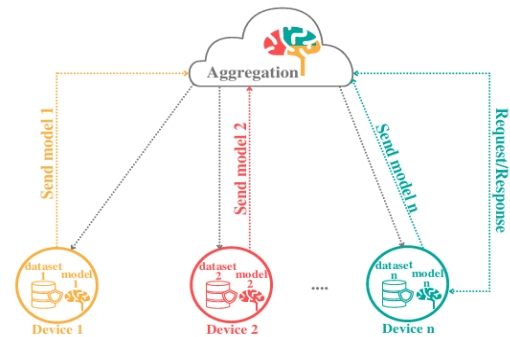


Fig. 3. FL: Collaborative ML without centralized training data.

- همگام‌سازی: هماهنگ‌سازی زمان به‌روزرسانی مدل‌ها در میان گره‌های توزیع‌شده پیچیده است و منجر به مشکلات همگام‌سازی و ناسازگاری‌های احتمالی می‌شود.

یادگیری فدرال (FL) رویکردی حفظ‌کننده حریم خصوصی، مقیاس‌پذیر و کارآمد ارائه می‌دهد که بسیاری از چالش‌های مرتبط با یادگیری ماشینی متمرکز و غیرمتمرکز سنتی را برطرف می‌کند و آن را به راه‌حلی ارزشمند در عصر حریم خصوصی داده و تمرکززدایی تبدیل می‌سازد. این رویکرد به‌ویژه برای کاربردهایی که شامل داده‌های حساس، محاسبات لبه‌ای، و محیط‌های توزیع‌شده هستند بسیار مناسب است.

C. یادگیری ماشینی فدرال

یادگیری فدرال (FL) اخیراً توسط گوگل به‌عنوان رویکردی نویدبخش برای انجام وظایف یادگیری ماشینی توزیع‌شده بدون اتکا به یک مرکز داده متمرکز پیشنهاد شد. نویسندگان در [66] FL را به‌عنوان یک محیط یادگیری ماشینی تعریف کردند که در آن چندین موجودیت (کلاینت‌ها) تحت هماهنگی یک سرور مرکزی یا ارائه‌دهنده خدمات، با هم برای حل یک مسئله یادگیری ماشینی کار می‌کنند. در این رویکرد، داده‌های شخصی به‌صورت محلی ذخیره می‌شوند و بین کلاینت‌ها مبادله یا منتقل نمی‌گردند. در عوض، به‌روزرسانی‌های مدل که برای تجمع طراحی شده‌اند، برای دستیابی به هدف یادگیری استفاده می‌شوند. این فرآیند امکان آموزش امن را فراهم می‌کند و در عین حال از دانش جمعی موجودیت‌های توزیع‌شده بهره می‌گیرد. FL بر پایه‌ی ایده‌ی آموزش مدل به‌صورت محلی در منبع داده بنا شده است. دستگاه‌ها مدل‌های خود را با ترکیب نتایج جزئی آموزش به یک «ابرمدل» جدید منتقل می‌کنند، که سپس به همه دستگاه‌ها بازگردانده می‌شود. این مکانیزم به‌طور راهبردی طراحی شده تا حریم خصوصی را حفظ کرده و امنیت داده‌ها را افزایش دهد. شکل 4 نشان می‌دهد که FL به همکاری میان یادگیری ماشینی، حریم خصوصی، و تخصص سیستم‌های توزیع‌شده وابسته است؛ که این همکاری برای مقابله با چالش‌های ناشی از داده‌های توزیع‌شده و نگرانی‌های مربوط به حریم خصوصی بنیادی محسوب می‌شود.




Fig. 4. FL encompasses three synergistic research areas: ML, privacy, and distributed systems.

Fig. 5. FL Life Cycle.

یا سازمان‌هایی با اهداف مشابه می‌خواهند مدل‌های خود را به‌طور مشترک بهبود دهند. یک نمونه کاربردی رایج، تشخیص کلمه بیداربخش (Wake-word recognition) مانند «Hey Siri» یا «OK Google» است، چون هر کاربر همان جمله را با لهجه متفاوت بیان می‌کند.

2) یادگیری فدرال عمودی (VFL یا Vertical FL): این نوع FL در سناریوهایی کاربرد دارد که دو مجموعه داده فضای نمونه مشابهی دارند اما در فضای ویژگی متفاوت هستند. برای مثال، دو شرکت در یک شهر را در نظر بگیرید: یکی بانک و دیگری فروشگاه تجارت الکترونیک. اگرچه پایگاه کاربران آن‌ها همپوشانی دارد، اما داده‌های جمع‌آوری شده متفاوت است. بانک اطلاعاتی مانند فروش‌ها، فعالیت‌های هزینه‌ای و امتیازات اعتباری را ثبت می‌کند، در حالی که فروشگاه تجارت الکترونیک تاریخچه جستجو و خرید کاربران را ذخیره می‌کند. هدف این است که مدلی برای پیش‌بینی خرید محصولات بر اساس ویژگی‌های کاربر آموزش داده شود. در این حالت، VFL راه‌حل ایده‌آل است تا ویژگی‌های اضافی جمع‌آوری شده و یک مدل جامع با استفاده از داده‌های هر دو شرکت ساخته شود.

3) یادگیری انتقالی فدرال (FTL یا Federated Transfer Learning): این نوع FL زمانی مناسب است که دو مجموعه داده هم در نمونه‌ها و هم در فضای ویژگی‌ها متفاوت باشند. برای مثال، دو شرکت در دو کشور مختلف را در نظر بگیرید که کاربران و فضای ویژگی آن‌ها همپوشانی کمی دارد. در این سناریو، FTL از نمونه‌های مشترک میان این فضاها با استفاده از مجموعه‌های نمونه استاندارد محدود یاد می‌گیرد. دانش به‌دست‌آمده سپس برای پیش‌بینی نمونه‌هایی که فقط ویژگی‌های یک‌طرفه دارند به‌کار می‌رود. در سیستم‌های بی‌سیم، این رویکرد به دستگاه‌ها امکان می‌دهد آنچه خودشان یاد گرفته‌اند و آنچه سایر دستگاه‌ها یاد گرفته‌اند را به‌خاطر بسپارند، و این در مواردی کاربرد دارد که چندین دستگاه بی‌سیم در محیط‌های مختلف تصمیم‌گیری می‌کنند.

4) دسته‌بندی‌های دیگر: معماری‌های دیگری برای FL وجود دارند، فراتر از HFL، VFL و FTL. برای مثال:

- MMVFL (یادگیری فدرال عمودی چندشرکت‌کننده و چندکلاسه): در [75] پیشنهاد شد تا مدیریت تعداد زیادی کاربر ممکن شود. این روش امکان توزیع برجسب‌ها به‌صورت حفظ‌کننده‌ی حریم خصوصی از مالک به سایر شرکت‌کنندگان را فراهم می‌کند.

- FEDF: چارچوبی که در [76] معرفی شد تا مدل‌های یادگیری ماشینی را روی چندین مجموعه داده آموزشی توزیع‌شده جغرافیایی متعلق به مالکان مختلف آموزش دهد.

- PerFit: چارچوب دیگری که در [77] توسعه یافت تا عملکرد دستگاه‌ها در کاربردهای اینترنت اشیا (IoT) را بهبود دهد. این کار با یادگیری یک مدل مشترک از طریق تجمع به‌روزرسانی‌های محلی از دستگاه‌های توزیع‌شده و بهره‌گیری از مزایای محاسبات لبه‌ای انجام می‌شود. این رویکرد شخصی‌سازی و عملکرد بهتر برای دستگاه‌های IoT را امکان‌پذیر می‌سازد. به‌طور کلی، معماری‌های مختلفی برای FL وجود دارند که بسته به ویژگی‌های توزیع داده طراحی می‌شوند (به‌عنوان مثال جدول III). علاوه بر این، رویکرد HFCL (یادگیری فدرال متمرکز ترکیبی) که در [79] پیشنهاد شد، به فرآیند یادگیری با مجموعه داده‌های خود کمک می‌کند. در مواردی که برخی دستگاه‌ها لبه توان محاسباتی کافی برای محاسبه گرادینان‌ها در طول آموزش مدل ندارند، HFCL ارزشمند است زیرا تنها دستگاه‌های فعال با توان محاسباتی کافی را قادر می‌سازد تا محاسبات گرادینان را روی داده‌های محلی خود انجام دهند و در آموزش مشترک مدل مشارکت کنند. در مقابل، دستگاه‌های منفعل باقی‌مانده مجموعه داده‌های محلی خود را به سرور پارامتر ارسال می‌کنند. در [80] نویسندگان مفهوم جدیدی از یادگیری فدرال مشارکتی (Collaborative FL یا CFL) را پیشنهاد کردند، که در آن دستگاه‌ها بدون اتکا به یک سرور پارامتر مرکزی از تکنیک‌های FL بهره می‌گیرند. این کار معماری و چالش‌های پارادایم CFL را نشان می‌دهد.

C. الگوریتم‌های یادگیری فدرال

در FL، یک مدل یادگیری ماشینی به‌صورت تکراری با مراحل زیر آموزش داده می‌شود:

1. سرور مجموعه‌ای از کاربران را برای محاسبه مدل به‌روزشده انتخاب می‌کند.

2. هر کلاینت یک مدل محلی را با داده‌های خود آموزش می‌دهد.

3. به‌روزرسانی‌ها به سرور منتقل می‌شوند.

4. سرور این به‌روزرسانی‌های محلی را تجمع کرده و یک مدل جهانی می‌سازد.

محاسبات روی دستگاه‌های کاربران و تجمع‌کننده مرکزی انجام می‌شود، در حالی که ارتباط میان آن‌ها برقرار است. هدف محاسبات آماده‌سازی مدل است و ارتباط معمولاً برای اشتراک پارامترهای مدل انجام می‌شود.

در این بخش، الگوریتم‌های مهم FL معرفی می‌شوند (جدول IV):

- FedAvg: الگوریتم میانگین‌گیری فدرال که فرآیند میانگین‌گیری تکراری را برای آموزش مدل جهانی به‌کار می‌برد. داده‌ها به چندین زیرمجموعه غیرهمپوشان تقسیم می‌شوند و هر کلاینت یک مدل محلی روی زیرمجموعه خود آموزش می‌دهد. سپس مدل‌های محلی به سرور ارسال می‌شوند و پارامترهای آن‌ها میانگین گرفته می‌شود تا مدل جهانی جدید ساخته شود. این فرآیند برای تعداد ثابتی از دورها تکرار می‌شود تا مدل جهانی همگرا شود. مراحل FedAvg تقریباً مشابه تکنیک‌های سنتی یادگیری ماشینی و یادگیری عمیق با سرور پارامتر و کارگران است.

- FedSGD: الگوریتم گرادینان کاهشی تصادفی فدرال مشابه FedAvg است. دستگاه‌ها از SGD برای به‌روزرسانی مدل‌ها به‌صورت محلی استفاده می‌کنند و هر دستگاه نرخ یادگیری خود را تنظیم می‌کند، که امکان همگرایی بهتر برای دستگاه‌هایی با توزیع داده متفاوت را فراهم می‌سازد.

- FedProx: در شبکه‌های ناهمگن، بهینه‌سازی فدرال یک جمله مجاورتی (proximal term) را برای پیوند مدل‌های محلی و جهانی وارد می‌کند تا انحراف بیش‌ازحد در طول فرآیند بهینه‌سازی کاهش یابد. FedProx الگوریتم FedAvg را اصلاح می‌کند و اجازه می‌دهد بخشی از کار بر اساس محدودیت‌های سیستم زیربنایی روی دستگاه‌ها انجام شود و با استفاده از جمله مجاورتی این کار به‌طور امن در مدل لحاظ گردد.

- FedATT: الگوریتم فدرال توجهی که اهمیت نسبی مدل‌های محلی را بررسی کرده و آن‌ها را با استفاده از مکانیزم توجه نرم لایه‌به‌لایه میان مدل‌های محلی و جهانی تجمع می‌کند. این روش تجمع توجهی فاصله وزنی میان مدل‌های سرور و کلاینت را در مجموعه داده‌های غیر IID کاهش می‌دهد.

- SimFL: یادگیری فدرال مبتنی بر شباهت که نیازی به سرور مورد اعتماد ندارد. شامل چهار مرحله اصلی است:

1. طرف‌ها ابتدا گرادینان‌های داده‌های محلی خود را به‌روزرسانی می‌کنند.

2. گرادینان‌ها به یک طرف انتخاب‌شده ارسال می‌شوند.

3. طرف انتخاب‌شده از داده‌های محلی و گرادینان‌ها برای به‌روزرسانی مدل استفاده می‌کند.

4. مدل به سایر طرف‌ها ارسال می‌شود.

برای ارتقای عدالت و بهره‌برداری مؤثر از داده‌های چندین طرف، هر شرکت‌کننده برای تعداد مشابهی از دورها انتخاب می‌شود تا مدل را به‌روزرسانی کند و خروجی نهایی مدل تولید شود.

چارچوب‌های FL

چارچوب‌های مختلفی برای تسهیل پیاده‌سازی و مدیریت فرآیند FL طراحی شده‌اند. این چارچوب‌ها ابزارها، کتابخانه‌ها و API‌هایی فراهم می‌کنند که توسعه‌دهندگان را قادر می‌سازد الگوریتم‌های FL را ایجاد و اجرا کنند:

• FATE: پلتفرم متن باز Federated AI Technology Enabler که هدف آن ایجاد محیط محاسباتی امن برای اکوسیستم هوش مصنوعی فدره‌ای است.

• IBM FL: چارچوب FL مبتنی بر پایتون که توسط IBM برای محیط‌های سازمانی پیشنهاد شد و زیرساختی ضروری برای افزودن قابلیت‌های پیشرفته فراهم می‌کند.

• FedML: کتابخانه تحقیقاتی متن باز برای پشتیبانی از توسعه الگوریتم‌های FL و مقایسه منصفانه عملکرد. این چارچوب سه پارادایم محاسباتی ارائه می‌دهد: آموزش روی دستگاه‌های لبه، محاسبات توزیع شده، و شبیه‌سازی تک‌ماشین.

• TFF: چارچوب متن باز TensorFlow Federated برای یادگیری ماشینی و سایر محاسبات روی داده‌های غیرمتمرکز.

• PySyft: چارچوب FL حفظ‌کننده حریم خصوصی مبتنی بر PyTorch که طراحی آن بر زنجیره‌ای از تنسورها میان کارگران محلی و راه‌دور متکی است.

• LEAF: چارچوبی ماژولار برای یادگیری در محیط‌های فدره‌ای یا اکوسیستم‌هایی با شبکه‌های بسیار توزیع شده از دستگاه‌ها.

• Paddle FL: چارچوب متن باز طراحی شده عمدتاً برای کاربردهای صنعتی که چندین الگوریتم FL را برای خوشه‌های توزیع شده بزرگ مقیاس بازتولید می‌کند.

Ref	Architecture	Focuses	Benefits	Drawbacks
[69]	HFL	Security	Independence	Need to provide more security
[69]	VFL	Privacy	Encryption	Handling only two participants
[73]	FTL	Avoiding accuracy loss	High precision	Expensive computation
[75]	MMVFL	Data leakage	Multiple participants	Need to handle stragglers effectively
[76]	FEDF	Parallel training	Accelerating training	Enormous data exchange
[77]	PerFit	IOT applicability	Cloud based	Data augmentation step is required
[78]	StarFL	Urban computing	Security	System efficiency

TABLE III
FL ARCHITECTURES: FOCUSES, BENEFITS AND DRAWBACKS.

Algorithm	Benefits	Drawbacks
FedAvg	- Simplicity - Communication-efficiency - Privacy-preserving	- Slow convergence speed - Privacy risks - Data heterogeneity
FedSGD	- High convergence speed - Handling data heterogeneity - Localized Adaptation	- Hyper-parameter complexity - Communication overhead - Impact of imbalanced data
FedProx	- High convergence speed - Handling non-IID data - Regularization	- Hyper-parameter tuning - Increased communication overhead - Centralized aggregator
FedATT	- Fast learning - Communication efficiency - Handling non-IID data	- Privacy risks - Data heterogeneity
SimFL	- Good accuracy - Fast computation - Security	- Communication overhead - Impact of imbalanced data

TABLE IV
FL ALGORITHMS: BENEFITS AND DRAWBACKS.

A. تشخیص نهاد/سیگنال

گیرنده در یک سیستم ارتباطی دیجیتال باید نهاد‌های ارسال شده را از خروجی مشاهده شده کانال به درستی شناسایی کند. این وظیفه به عنوان تشخیص نهاد شناخته می‌شود. مزیت کلیدی استفاده از تکنیک‌های ML و DL برای تشخیص نهاد این است که یک نگاشت داده‌محور برای مدل سازی ویژگی‌های کانال فراهم می‌کند؛ چیزی که روش‌های مبتنی بر مدل به طور مؤثر قادر به مدیریت آن نیستند. علاوه بر این، از آنجا که مدل مستقیماً با نهاد‌های خراب شده دریافت شده تغذیه می‌شود، یادگیری انتها-به-انتها به مدل اجازه می‌دهد نهاد‌ها را بدون نیاز به مرحله تخمین کانال به درستی تشخیص دهد. استفاده از یادگیری متمرکز برای این نقش باعث ایجاد بار ارتباطی بالا و مشکلات حریم خصوصی می‌شود، همچنین محدودیت‌هایی در ذخیره و انتقال حجم عظیم داده دارد. برای غلبه بر این چالش‌ها، در [97] یک گیرنده مبتنی بر FL با نام FedRec برای تشخیص نهاد در کانال‌های محوشده‌ی Downlink طراحی شد. این گیرنده برای یادگیری نگاشت‌های خود از تعداد محدودی پایلوت استفاده می‌کند. این رویکرد با استفاده از همکاری کاربران در آموزش از طریق FL، امکان آموزش یک شبکه عصبی واحد بر روی

در این بخش، ما یک طبقه‌بندی از اصول اساسی یادگیری فدره‌ای (FL) ارائه دادیم، شامل تعریف مختصر FL، دسته‌بندی‌های مختلف آن، و الگوریتم‌های مرتبط. در ادامه، به کاربردهای FL پرداخته و بررسی خواهیم کرد که چگونه از آن برای ارتقای قابلیت‌های نسل پنجم (G5) و نسل ششم (G6) شبکه‌های موبایل استفاده می‌شود.

IV. یادگیری فدره‌ای در لایه‌های PHY/MAC

با توجه به عملکرد نویدبخش یادگیری ماشینی (ML) در ارتباطات بی‌سیم، افزایش چشمگیری در استفاده از ML برای لایه فیزیکی شبکه‌های بی‌سیم رخ داده است. FL نسبت به یادگیری ماشینی سنتی کارآمدتر از نظر ارتباطی و حفظ‌کننده‌تر حریم خصوصی است، و بنابراین پتانسیل بالایی برای حل مسائل در پایین‌ترین لایه‌های مدل OSI دارد. این بخش مروری بر پیشرفت‌های اخیر در معماری لایه فیزیکی مبتنی بر FL ارائه می‌دهد، شامل: تشخیص نهاد و سیگنال، تخمین کانال، اطلاعات وضعیت کانال، بیم‌فورمینگ، سطوح هوشمند قابل‌بیکربندی، دسترسی به کانال، و اشتراک طیف.

مجموعه داده متنوع را بدون نیاز به پایلوت‌های اضافی فراهم می‌سازد. با وجود نیاز به تبادل پارامترها در چندین تکرار با ایستگاه پایه (BS)، FedRec یک آشکارساز نهاد کارآمد ارائه می‌دهد که عملکردی نزدیک به آشکارساز MAP دارد. این روش نسبت به راه‌حل مبتنی بر مدل، به‌ویژه زمانی که دانش دقیقی از توزیع محوشدگی وجود ندارد، بهتر عمل می‌کند. علاوه بر این، FedRec بار ارتباطی بسیار کمتری نسبت به آموزش یک آشکارساز نهاد مبتنی بر شبکه عصبی در طرح متمرکز ایجاد می‌کند. FedRec استفاده از شبکه‌های عصبی کوچک را تسهیل می‌کند، زیرا نیازی به لایه‌های استخراج ویژگی ندارد و می‌تواند با مجموعه داده‌های نسبتاً کوچک آموزش داده شود. در حالی که هر مجموعه داده محلی تنها تعداد محدودی از تحقیقاتی کانال محوشده را شامل می‌شود، تنوع میان این مجموعه داده‌ها در دستگاه‌های مختلف برای به‌دست آوردن یک مدل واحد برای همه دستگاه‌ها از طریق آموزش فدرال مورد استفاده قرار می‌گیرد. مزیت FL در این است که می‌تواند مدولاسیون سیگنال را شناسایی کند در حالی که داده‌های خصوصی را محافظت می‌نماید. بنابراین، در [98] به جای انتقال داده‌های خام بین سرور مرکزی و همه دستگاه‌ها، تنها به جای انتقال داده‌های خام، تنها به‌روزرسانی‌های مدل شبکه عصبی کانولوشنی (CNN) به اشتراک گذاشته می‌شوند. نتایج نشان می‌دهد که رویکرد طراحی شده به نرخ تشخیص بیش از 70٪ دست یافته است، در حالی که حفاظت از حریم خصوصی و امنیت داده‌ها نیز رعایت شده است.

نویسندگان [99] یک چارچوب FL برای طبقه‌بندی خودکار مدولاسیون با نام FedeAMC ارائه کردند؛ تحت شرایط عدم توازن کلاسی و تغییرات نویز، داده‌ها و آموزش در هر کلاینت محلی انجام می‌شود، در حالی که تنها دانش با سرور به اشتراک گذاشته می‌شود. فرآیند FL شامل شش مرحله اصلی است: انتخاب و انتشار مدل و پارامترها، محاسبه گرادین محلی، بارگذاری اطلاعات کلیدی، تجمع اطلاعات کلیدی، دانلود اطلاعات تجمع‌شده، و در نهایت به‌روزرسانی مدل محلی. رویکرد پیشنهادی خطر نشت داده را کاهش می‌دهد بدون آنکه افت عملکرد شدیدی ایجاد کند.

B. تخمین کانال

در ارتباطات بی‌سیم، برخی اثرات نامطلوب روی سیگنال‌های منتقل شده توسط خواص فیزیکی کانال ایجاد می‌شوند. در نتیجه، سیگنال‌هایی که به گیرنده می‌رسند همواره تضعیف شده، مخدوش، با تأخیر و تغییر فاز هستند. بنابراین، نیاز به تخمین دقیق و به‌روز کانال وجود دارد تا این اثرات جبران شوند و مدولاسیون، هم‌ترازی و کدگذاری سیگنال در سمت گیرنده به‌درستی انجام گیرد. تخمین کانال با استفاده از ML نیازمند آموزش مدل روی مجموعه داده‌ای به‌صورت متمرکز است، که معمولاً شامل سیگنال‌های پایلوت دریافتی به‌عنوان ورودی و داده‌های کانال به‌عنوان خروجی می‌باشد. با این حال، این روش بار ارتباطی قابل‌توجهی هنگام جمع‌آوری داده‌های کاربران ایجاد می‌کند. برای حل این مشکل، در [103] از FL برای بهبود عملکرد تخمین کانال استفاده شد؛ به جای ارسال کل مجموعه داده، تنها به‌روزرسانی‌های مدل بین کلاینت‌ها و سرور منتقل می‌شوند، که تخمین کانال خوبی را حفظ کرده و خطای تخمین را کاهش می‌دهد، همچنین بار انتقال را تقریباً 16 برابر کمتر از یادگیری متمرکز می‌کند. نویسندگان یک شبکه عصبی کانولوشنی در ایستگاه پایه (BS) طراحی کرده و آن را روی مجموعه داده‌های محلی آموزش دادند.

رویکرد پیشنهادی سه مرحله دارد:

1. جمع‌آوری داده: هر کاربر مجموعه داده آموزشی محلی خود را ایجاد می‌کند که شامل ورودی (سیگنال‌های پایلوت) و خروجی (ماتریس کانال) برای آموزش مدل است.
2. آموزش: هر کاربر با مجموعه داده محلی خود کار می‌کند، تغییرات مدل را محاسبه کرده و به BS ارسال می‌کند، جایی که آن‌ها تجمع شده و یک مدل جهانی آموزش داده می‌شود.
3. پیش‌بینی: هر کاربر کانال محلی خود را با وارد کردن داده‌های پایلوت به مدل آموزش‌دیده تخمین می‌زند.

مزیت مهم این روش آن است که هر کلاینت به مدل واجد شرایط برای تخمین کانال دسترسی دارد. نویسندگان [104] از FL برای ایجاد یک طرح پیش‌بینی کانال استفاده کردند تا پیش‌جبران

کانال در یک سیستم ارتباطی نوری فضای آزاد کم‌هزینه حاصل شود. این رویکرد در ساده‌سازی هزینه‌های ساختاری و عملیاتی سیستم مؤثر است. برای بهره‌برداری کامل از معماری سطوح هوشمند قابل‌پیکربندی (RIS)، همه فناوری‌های کارآمد باید بر اطلاعات وضعیت کانال (CSI) دقیق بین BS و RIS و همچنین بین RIS و کاربران تکیه کنند. با این حال، در سیستم‌های تقویت‌شده با RIS، تخمین CSI صحیح زمانی که حسگرها یا زنجیره‌های RF روی RIS نصب نشده باشند، امکان‌پذیر نیست. بنابراین، استفاده از FL برای تشخیص CSI در ارتباطات بی‌سیم مبتنی بر RIS منطقی است. در واقع، برای برخی ایستگاه‌های پایه سلولی کوچک، مقدار کمی داده آموزشی برای تولید یک مدل عمومی‌شده برای پیش‌بینی CSI کافی نیست. تکنیک‌های یادگیری متمرکز همه داده‌ها را برای پردازش و آموزش ترکیب می‌کنند، که منجر به بار ارتباطی می‌شود. نویسندگان [107] یک رویکرد غیرمتمرکز برای غلبه بر این چالش‌ها معرفی کردند. آن‌ها یک چارچوب مبتنی بر FL برای پیش‌بینی CSI با استفاده از شبکه‌های عصبی کانولوشنی سه‌بعدی پیشنهاد کردند. مدل جهانی در ایستگاه‌های پایه ماکرو (MBs) با جمع‌آوری همه مجموعه داده‌های محلی از ایستگاه‌های پایه لبه آموزش داده می‌شود. برای رفع شکاف عملکرد بین یادگیری متمرکز (CL) و FL، آن‌ها الگوریتم FED-WG (وزن‌ها و گرادین‌های فدرال) را طراحی کردند که به این صورت عمل می‌کند:

1. MBها وزن‌ها و گرادین‌های مدل محلی مرتبط را از BSها دریافت می‌کنند.

2. FED-WG دو دور متوالی از به‌روزرسانی پارامترها را برای مدل جهانی اجرا می‌کند.

چارچوب پیشنهادی FED-WG به‌طور مؤثر شکاف عملکرد بین FL و CL را کاهش می‌دهد، در حالی که بار انتقال را به‌طور قابل‌توجهی کم می‌کند. فرآیند کلی رویکردهای FL معمولاً فرض می‌کند که دانش کامل CSI در طول مرحله آموزش وجود دارد، که برای کانال‌های محوشده سریع چالش‌برانگیز است. علاوه بر این، در ادبیات تعداد ثابتی از کلاینت‌ها برای مشارکت در آموزش مدل فدرال استفاده می‌شود. کار [108] تلاش کرد این شکاف‌ها را پر کند، با پیشنهاد یک رویکرد FL که در آن همه کلاینت‌ها از نرخ جهانی ثابت برای تکمیل دوره‌های آموزشی استفاده می‌کنند. این کار به‌طور مداوم منجر به همگرایی سریع‌تر می‌شود، حتی زمانی که CSI ناقص باشد.

D. بیم‌فورمینگ

بیم‌فورمینگ و سیستم‌های MIMO عظیم (ورودی-خروجی چندگانه) هدفشان تطبیق الگوی تابش آرایه آنتن با سناریوهای خاص است. این فناوری‌ها بخش حیاتی از رادیوی جدید G5 و G6 هستند. استفاده از طرح یادگیری متمرکز برای بیم‌فورمینگ ترکیبی به‌طور گسترده مطالعه شده است. ادغام FL در بیم‌فورمینگ و سیستم‌های MIMO عظیم پتانسیل ارتقای کارایی شبکه، مقاومت و مقیاس‌پذیری را دارد. همان‌طور که فناوری‌های G5 و G6 به تکامل خود ادامه می‌دهند، ادغام تکنیک‌های یادگیری پیشرفته نقش محوری در شکل‌دادن آینده ارتباطات بی‌سیم ایفا می‌کند. نویسندگان [110] یک چارچوب مبتنی بر FL ارائه کردند تا کانال‌های موج میلی‌متری (mmWave) را در بیم‌فورمرهای آنالوگ در یک شبکه Downlink چندکاربره نگاشت کنند. آن‌ها یک معماری CNN در BS ساختند، جایی که مدل روی لبه تنها با گرادین‌های ارائه‌شده توسط کاربران مختلف آموزش داده می‌شود. رویکرد [110] به این صورت ادامه می‌یابد:

1. مدل CNN ماتریس کانال را به‌عنوان ورودی و بیم‌فورمر RF را به‌عنوان خروجی می‌گیرد. شبکه عصبی عمیق سپس با استفاده از داده‌های گرادین جمع‌آوری‌شده از کاربران آموزش داده می‌شود.
2. هر کاربر اطلاعات گرادین را با داده‌های آموزشی موجود خود (یک جفت ماتریس کانال و شاخص بیم‌فورمر متناظر) محاسبه کرده و سپس آن را به ایستگاه پایه (BS) ارسال می‌کند.
3. BS همه داده‌های گرادین را از کاربران دریافت کرده و به‌روزرسانی پارامترها را برای مدل CNN انجام می‌دهد که شامل 11 لایه با دو لایه کانولوشنی و یک لایه کاملاً متصل است. در نتیجه، شاخص‌های بیم‌فورمر خروجی CNN خواهند بود.

استراتژی FL برای بیم‌فورمینگ ترکیبی عملکرد بیم‌فورمینگ مقاوم‌تری ارائه می‌دهد در حالی که بار انتقال بسیار کمتری دارد. این چارچوب نیازمند ماتریس‌های کانال mmWave به‌عنوان ورودی است، که تخمین آن‌ها چالش‌برانگیز بوده و نیازمند سربار آموزشی قابل‌توجهی است. نویسندگان [111] یک طرح بیم‌فورمینگ پیشنهاد کردند که تنها بر تخمین وضعیت کانال در زیر-6GHz متکی است، که با فناوری‌های فعلی بسیار در دسترس‌تر از تخمین کانال mmWave است. هدف آن‌ها پیش‌بینی بردارهای بیم‌فورمینگ mmWave با بهره‌گیری از کانال‌های زیر-6GHz در یک شبکه شامل چندین لینک کاربر—نقطه دسترسی است، جایی که شبکه عصبی عمیق کانال‌های زیر-6GHz را به‌عنوان ورودی گرفته و مستقیماً بردار بیم‌فورمینگ mmWave متناظر را خروجی می‌دهد.

علاوه بر این، نویسندگان یک طرح FL توزیع‌شده پیشنهاد کردند تا بردارهای بیم‌فورمینگ به‌صورت محلی در هر کاربر پیش‌بینی شوند بدون آنکه داده‌های محلی به سرور مرکزی بارگذاری شوند. سه مزیت اصلی این چارچوب عبارتند از:

- بار محاسباتی به لبه شبکه منتقل می‌شود، برخلاف رویکرد متمرکز مبتنی بر ابر؛

- کاربران تنها پارامترهای شبکه عصبی خود را به اشتراک می‌گذارند و نه داده‌هایشان، که بار سیگنال‌دهی را به‌شدت کاهش داده و داده‌های کاربران را محافظت می‌کند؛

- کاربران همچنان دانش کسب‌شده از محیط را به اشتراک می‌گذارند تا کیفیت پیش‌بینی‌هایشان بهبود یابد.

سیستم‌های ارتباطی mmWave-MIMO به‌طور قابل‌توجهی توان عملیاتی را در شبکه‌های G5 بهبود می‌دهند. با این حال، این راه‌حل‌ها در صورت تعداد کم زنجیره‌های RF بهره‌وری چندگانه را کاهش می‌دهند. کار [113] تکنیک مدولاسیون شاخص مسیر فضایی (SPIM) را معرفی کرد، روشی برای بهبود بهره با استفاده از بیت‌های سیگنال دیگر که توسط شاخص‌های مسیر فضایی مدوله می‌شوند.

نویسندگان چارچوب‌های مبتنی بر مدل و بدون مدل برای طراحی بیم‌فورمر در سیستم‌های SPIM-MIMO چندکاربره پیشنهاد کردند؛ ابتدا بیم‌فورمرها را از طریق الگوریتم بهینه‌سازی منبوقد مبتنی بر مدل طراحی کردند. سپس، یک مدل CNN را روی مجموعه‌داده محلی با استفاده از FL و یادگیری Dropout آموزش دادند تا بیش‌برازش کاهش یابد. به‌روزرسانی‌های مدل سپس در BS جمع‌آوری شده و برای مرحله پیش‌بینی به کاربران بازگردانده می‌شوند، جایی که مدل بیم‌فورمرها را با تغذیه داده‌های کانال آن‌ها تخمین می‌زند.

مزایای استفاده از یادگیری Dropout در FL شامل موارد زیر است:

A. دستیابی به حدود 10 برابر سربار کمتر نسبت به یادگیری متمرکز.

B. کاهش هزینه ارتباطی در طول آموزش.

C. دستیابی به کارایی طیفی برتر نسبت به SPIM مبتنی بر مدل و MIMO-mmWave متداول.

E. سطوح هوشمند قابل‌پیکربندی (RIS)

سطوح هوشمند قابل‌پیکربندی (RIS) به‌عنوان رقیبی قدرتمند در مقایسه با MIMO عظیم مطرح شده‌اند. این فناوری توجه پژوهشی قابل‌توجهی را به خود جلب کرده است، به‌ویژه در بهره‌گیری از تکنیک‌های یادگیری ماشینی اخیر، به‌خصوص FL، برای امکان‌پذیر کردن تنظیمات قابل‌پیکربندی انتشار در قابلیت‌های ارتباطی بی‌سیم. ادغام RIS بهره بیم‌فورمینگ را در ارتباطات Uplink در یک سیستم MIMO عظیم افزایش می‌دهد. با این حال، این رویکرد چالش‌هایی مانند نادیده گرفتن حریم خصوصی کاربران و ایجاد بار ارتباطی بالا را به همراه دارد. برای غلبه بر این چالش‌ها، مطالعه [115] یک طراحی بیم‌فورمر مبتنی بر FL برای سناریوی IRS-assisted معرفی کرد. این شامل الگوریتمی با عنوان «بازتاب بهینه بیم مبتنی بر FL» است که هدف آن ارتقای ارتباطات پرسرعت با اطلاعات وضعیت کانال (CSI) پراکنده از طریق بهبود نرخ داده و حفاظت از حریم خصوصی است. الگوریتم استاندارد FL برای آموزش یک پرسپترون

چندلایه رگرسیون با انتقال مدل به‌کار گرفته شد؛ چارچوب پیشنهادی به‌طور مؤثر به مقداری نظری دست یافت که بیش از 90٪ آن چیزی است که توسط یادگیری ماشینی متمرکز حاصل می‌شود، در حالی که حفاظت از حریم خصوصی کاربران نیز تضمین شده است. با این حال، لینک RIS-کاربر تنها کانالی است که طراحی شده، در حالی که لینک BS-RIS ثابت فرض می‌شود. در یک حالت عملی، کانال mmWave بسیار پیچیده بوده و با طول کانال محدود مشخص می‌شود، عمدتاً به‌دلیل نوسانات محیطی. بنابراین، راه‌حل [103] هر دو کانال مستقیم (BS-کاربر) و آشناری (BS-RIS-کاربر) را در یک سناریوی RIS-assisted تخمین می‌زند، جایی که داده‌های ورودی و خروجی برای هر لینک ارتباطی ترکیب شده و تنها یک معماری CNN طراحی می‌شود به‌جای چندین شبکه عصبی مختلف. یک پارادایم حفظ‌کننده حریم خصوصی که FL را با RIS در سیستم‌های ارتباطی mmWave ترکیب می‌کند در [116] طراحی شد. ابتدا داده‌های خصوصی روی هر دستگاه محلی مدل‌های محلی را آموزش داده و رمزگذاری می‌کنند. سپس، در سرور مرکزی یک مدل جهانی با تجميع آن‌ها ساخته می‌شود. در حالی که محرمانگی داده‌های کاربران تضمین می‌شود، تکنیک پیشنهادی به‌طور موفقیّت‌آمیز به مقدار نظری نزدیک شده و بیش از 95٪ آنچه توسط ML متمرکز ایجاد می‌شود را محقق می‌سازد.

F. دسترسی به کانال

تکنیک‌های ML و DL طراحی لایه MAC را به‌طور قابل‌توجهی ارتقا داده‌اند و همچنین به بهبود عملکرد دسترسی به کانال کمک کرده‌اند، از طریق خودکارسازی تنظیم پارامترهای پروتکل و ارزیابی پروتکل‌های شبکه. این پیشرفت‌ها مسائل حیاتی مرتبط با توان محدود دستگاه‌های بی‌سیم و نگرانی‌های حریم خصوصی را برطرف می‌کنند. FL به‌دلیل قابلیت‌های ذاتی موزایی‌سازی و پتانسیل آن برای کارایی بیشتر نسبت به روش‌های متمرکز از نظر ذخیره‌سازی و حریم خصوصی، توجه قابل‌توجهی را به خود جلب کرده است. نویسندگان [120] یک رویکرد ارتباطی آنالوگ جایگزین پیشنهاد کردند که در آن دستگاه‌ها برآوردهای گرادین محلی خود را مستقیماً روی کانال بی‌سیم ارسال می‌کنند.

فرآیند یادگیری با یک استراتژی FL هدایت می‌شود، جایی که دستگاه‌ها مجموعه‌داده‌های محلی خود را دارند. آن‌ها با سرور پارامتر از طریق MAC بی‌سیم ارتباط برقرار می‌کنند. در اینجا، سرور پارامتر به بردارهای گرادین فردی علاقه‌مند نیست بلکه به میانگین آن‌ها توجه دارد، و MAC بی‌سیم به‌طور خودکار مجموع گرادین‌ها را در اختیار سرور قرار می‌دهد.

فناوری دسترسی چندگانه غیرارتوگونال (NOMA) به‌عنوان یک بلوک سازنده برای شبکه‌های G5 و فراتر از آن در نظر گرفته می‌شود. مطالعه [121] سازمان‌دهی دستگاه‌های نوع ماشینی (MTD) را در خوشه‌ها برای سیستم‌های مبتنی بر NOMA بررسی می‌کند. تمرکز بر تخصیص منابع است، و نویسندگان رویکردی شامل تخمین مدل ترافیک از طریق FL ارائه کردند. در این روش، MTD به‌طور مستقل پارامترهای مدل ترافیک خود را تخمین زده و آن‌ها را به BS ارسال می‌کند، که سپس مدل ترافیک را تجميع کرده، بلوک‌های منبع مناسب را تخصیص داده و توان را به هر MTD منتقل می‌کند.

نویسندگان [122] یک مدل شبکه بی‌سیم تقویت‌شده با NOMA پیشنهاد کردند تا شرایط کانال مطلوب NOMA را فراهم کرده و کیفیت مصرف‌کننده را افزایش دهند، با استفاده از مفهوم FL که به چندین عامل اجازه می‌دهد به‌طور همزمان محیط‌های مشابه را بررسی کرده و تجربیات خود را مبادله کنند.

G. اشتراک طیف

کارایی طیف یکی از شاخص‌های کلیدی عملکرد در شبکه‌های ارتباطی G5 و حتی فراتر از آن است. تکنیک‌های پیشرفته اشتراک طیف مانند ML و DL معمولاً برای مقابله با چالش‌های رایج و افزایش کارایی استفاده می‌شوند. با این حال، به‌کارگیری تکنیک‌های ML برای کاربردهای طیفی با چالش‌های محدودیت منابع داده و نگرانی‌های حریم خصوصی مواجه است. بنابراین، طرح FL این چالش‌های حریم خصوصی را مدیریت کرده و نتایج جالبی در مقایسه با یادگیری متمرکز به‌دست می‌آورد. در [123] نویسندگان یک سیستم حس‌کردن طیف غیرهمدوس مبتنی بر ML با نام FairR پیشنهاد کردند، که از یک چارچوب یادگیری توزیع‌شده کارآمد از نظر ارتباطی (FL) برای همکاری حسگرهای محیطی و آموزش یک مدل ML داده‌محور

برای تشخیص کاربران موجود تحت حداقل پهنای باند ارتباطی استفاده می‌کند. نتایج اولیه نشان می‌دهد که الگوریتم‌های طبقه‌بندی طیف پیشرفته در محیط FL بهتر از تکنیک‌های سنتی عمل می‌کنند. در [124] نویسندگان مسئله اشتراک طیف در شبکه‌های خودرویی با تحرک بالا را با استفاده از روش FTL بررسی کردند. آن‌ها ابتدا اشتراک منابع را به عنوان یک مسئله یادگیری تقویتی چندعاملی مدل‌سازی کردند، که سپس با استفاده از روش شبکه Q عمیق مبتنی بر اثرانگشت حل شد، روشی که برای پیاده‌سازی توزیع‌شده مناسب است. نتایج نشان می‌دهد که با یک سیستم پاداش و فرایند آموزشی طراحی‌شده مناسب، فرستنده‌های خودرو به خودرو از تعاملات خود با محیط ارتباطی یاد می‌گیرند. نویسندگان یک استراتژی مؤثر برای همکاری به صورت توزیع‌شده توسعه دادند، و بدین ترتیب عملکرد سطح سیستم را با استفاده از اطلاعات محلی بهینه کردند.

H. خلاصه

در این بخش، طرح‌های مبتنی بر FL موجود که کیفیت ارتباط و شاخص‌های کلیدی عملکرد (KPIs) را برای لایه‌های فیزیکی و MAC در سیستم‌های ارتباطی بی‌سیم بهبود می‌دهند بررسی کردیم. درس‌های آموخته‌شده از این بخش عبارتند از:

- ادغام FL در لایه‌های PHY و MAC از قابلیت‌های منحصر به فرد FL برای بهینه‌سازی فرآیندهای ارتباط بی‌سیم بهره می‌گیرد، و کارایی، قابلیت اعتماد و عملکرد را ارتقا می‌دهد.

- FL رویکردی نوآورانه است که نحوه عملکرد شبکه‌های بی‌سیم را در سطح بنیادی بازتعریف می‌کند، مانند تشخیص سیگنال، تخمین کانال، بیم‌فورمینگ، بهینه‌سازی RIS، دسترسی به کانال، و اشتراک طیف؛ در حالی که برخی معایب مانند پیچیدگی مدل/داده/سخت‌افزار، کارایی ارتباطی، و دقت یادگیری را نیز به همراه دارد.

جدول V خلاصه‌ای از مشارکت‌های اصلی و مزایا و معایب آن‌ها را نشان می‌دهد.

V. یادگیری فدرال در لایه شبکه (NET Layer)

استفاده از FL در لایه شبکه رویکردی حفظ‌کننده حریم خصوصی، کارآمد و مقیاس‌پذیر برای ML ارائه می‌دهد. این رویکرد چالش‌های ناشی از داده‌های توزیع‌شده و حساس را برطرف می‌کند، در حالی که نیازهای تأخیر کم و تحمل خطا در سیستم‌های شبکه‌ای را نیز پوشش می‌دهد. FL در چندین وظیفه به کار گرفته می‌شود، مانند مدیریت منابع، پیش‌بینی رفتار

کاربر، برش شبکه (Network Slicing)، بهینه‌سازی مسیریابی، و رایانش ابری، که در ادامه توضیح داده می‌شوند.

A. طبقه‌بندی ترافیک

طبقه‌بندی ترافیک (TC) در سال‌های اخیر توجه فزاینده‌ای را به خود جلب کرده است. هدف آن ارائه توانایی شناسایی خودکار برنامه‌ای است که یک جریان بسته خاص را تولید کرده، از طریق مشاهده مستقیم و غیرفعال بسته‌های منفردی که در شبکه جریان دارند. به دلیل موفقیت FL در حفاظت از حریم خصوصی داده‌ها، این روش حتی در طبقه‌بندی ترافیک اینترنت نیز به کار گرفته می‌شود تا دقت انتقال بسته‌ها را در حالی که داده‌های خصوصی حفظ می‌شوند، بهبود دهد.

- کار [128] یک چارچوب طبقه‌بندی ترافیک مبتنی بر FL با نام FLIC پیشنهاد کرد که برنامه‌های جدید را به صورت بلادرنگ طبقه‌بندی می‌کند، زمانی که یک کلاینت با یک برنامه جدید به فرایند یادگیری می‌پیوندد. پروتکل طراحی‌شده دقتی مشابه طرح متمرکز برای شناسایی برنامه‌های اینترنتی به دست می‌آورد، با تضمین حریم خصوصی.

- کار [129] یک مدل فدرال افقی بین‌سازمانی برای TC با استفاده از ویژگی‌های زمانی مبتنی بر جریان ساخت. چارچوب FL پیشنهادی عملکردی مشابه یک مدل DL متمرکز برای شناسایی برنامه‌های اینترنتی دارد، بدون نشت حریم خصوصی.

- در [130] یک رویکرد نوآورانه با استفاده از یادگیری نیمه‌نظارتی فدرال برای طبقه‌بندی ترافیک شبکه طراحی شد. سرورهای فدرال و چندین کلاینت با هم برای آموزش یک مدل طبقه‌بندی جهانی کار می‌کنند، جایی که داده‌های بدون برچسب در کلاینت و داده‌های برچسب‌خورده در سرور استفاده می‌شوند. نتایج نشان می‌دهد که این روش حریم خصوصی کاربران را بدون نیاز به اشتراک حجم زیادی از داده‌های برچسب‌خورده حفظ کرده و دقت خوبی به دست می‌آورد.

B. مدیریت منابع

تخصیص توان و منابع همچنان چالش‌های حیاتی بی‌سیم باقی مانده‌اند، به دلیل نیاز به منابع بیشتر. بهینه‌سازی یک...

Ref	Application	Benefits	Drawbacks
[97]–[99]	Symbol / Signal Detection	Learning collaboratively to clear the received symbols, without the need for channel estimation stage or gathering raw data	Need deep ML models for better performance
[103], [104]	Channel Estimation	Ability of each user to estimate its channel with less transmission overhead	Heavy computation resources due to the labeling phase of the channel data
[110], [111], [113]	Beamforming	Dynamic beamforming and antenna configurations for optimal signal transmission, improving coverage and reducing interference	Sub-optimum performance and complex labeling
[103], [115], [116]	RIS	Achieving high speed convergence in high dimension and complex environment	Only RIS beamforming is performed
[107], [108]	CSI prediction	Estimating the accurate CSI when the RF chains or sensors are not equipped on the RIS while preserving users' privacy	Need to maximize the training performance and the heterogeneous data should be taken into consideration
[120]–[122]	Channel Access	Tuning automatically individual protocol parameters while improving the convergence speed and communication delay	The impact of CSI estimation error on the performance needs to be studied.
[123], [124]	Spectrum Sharing	Improving spectrum sharing efficiency by learning in a distributed way from local information, without requiring the entire data	Need to collect more real data to analyze the true potential of FL in spectrum sharing

TABLE V
SUMMARY OF FL-BASED CONTRIBUTIONS AT PHY/MAC LAYERS.

[132] و [133] از الگوریتم‌های یادگیری ماشینی برای حل مسائل بهینه‌سازی منابع مرتبط با رایانش لبه‌ای موبایل (MEC) استفاده کردند.

با این حال، ارسال تمام اطلاعات محلی به یک کنترل‌کننده مرکزی در شبکه‌های بالون ارتفاع بالا (HAB) مجهز به MEC غیرعملی است، زیرا انتقال مجموعه داده‌های محلی منجر به مصرف

کارایی طیفی و اتصال در شبکه‌های چندسولولی به طور اجتناب‌ناپذیر منجر به مسائل تخصیص منابع غیرمحدب می‌شود، که معمولاً با روش‌های پایه‌ای مانند تقریب متوالی محدب و نظریه تطبیق مدیریت می‌شوند. برای رفع پیچیدگی بالا و غیرعملی بودن رویکردهای سنتی، نویسندگان

انرژی قابل توجهی می شود. در این راستا، FL به دستگاه های پراکنده اجازه می دهد تا به طور مشترک یک مدل ML را با اشتراک پارامترهای آموزش دیده با سایر دستگاه ها آموزش دهند، به جای ارسال مجموعه داده های عظیم.

نویسندگان [134] این مشکل را با استفاده از یک FL مبتنی بر ماشین بردار پشتیبان (SVM) برای تعیین ارتباط کاربر به صورت پیش دستانه حل کردند. روش پیشنهادی به هر HAB اجازه می دهد تا به طور مشترک یک مدل SVM بسازد تا همه ارتباطات کاربران را بدون انتقال وظایف محاسباتی یا ارتباطات تاریخی کاربران به سایر HAB ها تعیین کند. مدل SVM رابطه بین ارتباط کاربر آینده و اندازه داده و وظیفه ای که هر کاربر باید در بازه زمانی جاری پردازش کند را تحلیل می کند تا ارتباط کاربر را به صورت پیش دستانه تعیین کند. با پیش بینی ارتباط بهینه کاربر، توالی خدمات و تخصیص وظیفه هر کاربر بهینه سازی می شود تا مجموع وزنی مصرف انرژی و زمان کاهش یابد. این رویکرد مجموع وزنی مصرف انرژی و زمان همه کاربران را تا 16.1٪ نسبت به روش متمرکز سنتی کاهش می دهد.

در [135] نویسندگان تخصیص توان توزیع شده برای کاربران لبه در شبکه های بی سیم غیرمتمرکز را بررسی کردند. مدل پیشنهادی (FL-CA) هدف دارد مصرف توان را به حداقل برساند در حالی که نیاز کیفیت خدمات (QoS) کاربران را برآورده کرده و حریم خصوصی آن ها را حفظ کند. در چارچوب FL، دستگاه های لبه تصمیمات تخصیص توان را به صورت محلی با آموزش یک مدل بازیگر-منتقد محلی اتخاذ کرده و سپس گرادین ها و وزن های تولید شده توسط شبکه بازیگر را در فواصل منظم به BS برای تجمع اطلاعات ارسال می کنند. علاوه بر این، نویسندگان الگوریتم افزایش فدره ای را اتخاذ کردند که از شبکه مولد تخصصی Wasserstein (WGAN) برای افزایش داده استفاده می کند تا مشکل بیش برآزش ناشی از نشت داده ها برطرف شود. این الگوریتم به هر دستگاه امکان می دهد با استفاده از یک مدل مولد WGAN بافر داده را تکمیل کند تا به یک مجموعه داده آموزشی i.i.d. برسد، که بار ارتباطی را نسبت به تبادل مستقیم نمونه های داده کاهش می دهد.

در [136] نویسندگان یک چارچوب تخصیص منابع کانال مبتنی بر یادگیری تقویتی فدره ای (FRL) برای شبکه های بی سیم فوق متراکم G5 و B5G پیشنهاد کردند و تخمین های یادگیری مشارکتی را برای همگرایی سریع تر مطرح نمودند. نتایج نشان می دهد که مدل FRL طراحی شده برتر از یادگیری تقویتی غیر فدره ای است.

C. شبکه دسترسی رادیویی (RAN)

شبکه دسترسی رادیویی (RAN) بخش بنیادی یک سیستم مخابراتی موبایل است که داده های کاربران در آن حساس بوده و مشمول مقررات سخت گیرانه حریم خصوصی هستند. رویکردهای ML متمرکز نگرانی های حریم خصوصی را به دلیل تجمع داده ها ایجاد می کنند. FL امکان آموزش مدل محلی روی دستگاه ها را بدون اشتراک داده های خام فراهم می کند، و در عین حال حریم خصوصی کاربران را حفظ کرده و به روزرسانی های مدل جمعی را ممکن می سازد.

یادگیری تقویتی عمیق در [140] و چالش های مرتبط در محیط چند اپراتور شبکه مجازی موبایل (MVNOs) مورد بحث قرار گرفت. نویسندگان یک مکانیزم یادگیری تقویتی عمیق فدره ای روی معماری O-RAN طراحی کردند تا عملیات تخصیص منابع رادیویی MVNO ها را بهبود دهند و از طریق شبیه سازی های گسترده نشان دادند که مکانیزم برش RAN پیشنهادی تخصیص بهتر منابع رادیویی مورد نیاز را برای برآورده سازی الزامات QoS کاربران از نظر تأخیر و نرخ داده امکان پذیر می سازد.

کار [141] یک چارچوب نوآورانه ی تخلیه محتوای پیش دستانه آگاه از تحرک و تقاضا (MDPCO) مبتنی بر FL پیشنهاد کرد که از راهبردهای یادگیری توزیع شده بهره می گیرد و از اطلاعات تحرک و تقاضای کاربران برای تخلیه محتوای پیش دستانه استفاده می کند. کارایی MDPCO عملکرد بهتری نسبت به مدل های محلی و مبتنی بر ابر نشان می دهد. نویسندگان [142] یک الگوریتم یادگیری تقویتی عمیق فدره ای طراحی کردند تا چندین xAPP مستقل را در O-RAN برای Network Slicing هماهنگ کنند. آن ها دو xAPP توسعه دادند: یکی برای کنترل توان و دیگری برای تخصیص منابع مبتنی بر Slice، تا کارایی یادگیری را افزایش داده و عملکرد شبکه را بهبود دهند.

D. پیش بینی تحرک/مکان کاربر

به دلیل نیازهای متنوع کیفیت خدمات (QoS)، رفتار کاربر و عملکرد شبکه بی سیم برای توسعه و ارزیابی برنامه ها و فرصت های خدماتی جدید حیاتی شده اند. استراتژی FL در چندین موقعیت برای پیش بینی رفتار کاربران و به حداکثر رساندن کیفیت تجربه (QoE) نویدبخش است.

بر اساس پیش بینی های تحرک، اطلاعات بیشتری درباره شبکه فراهم می شود: کاربران به طور پویا یک زیرکانال برای آپلود داده در Uplink انتخاب می کنند، BS به طور پویا چندین زیرکانال را به چندین کاربر در Downlink تخصیص می دهد، و چندین کاربر که یک زیرکانال مشترک دارند از NOMA یا Full-Duplex استفاده می کنند.

به دلیل ماهیت حساس به حریم خصوصی فعالیت های کاربران، رویکردهای موجود پیش بینی مکان [143]–[145] بر ذخیره سازی متمرکز داده های تحرک کاربران برای آموزش مدل تکیه دارند، که نگرانی ها و خطرات حریم خصوصی ایجاد می کند. FL پتانسیل آن را دارد که ویژگی های پیش بینی را روی گوشی های هوشمند فعال کند بدون آنکه QoE کاهش یابد یا اطلاعات خصوصی نشت کند.

• نویسندگان [146] یک مدل FL تطبیقی به عنوان روشی غیرمتمرکز برای پیش بینی تحرک ارائه کردند. آن ها یک مدل FL شخصی سازی شده را با شبکه توجه ترکیب کردند تا مکان کاربر را به صورت امن پیش بینی کنند. این رویکرد از اطلاعات رفتاری کاربران انبوه برای آموزش مدل های دقیق پیش بینی تحرک استفاده می کند و نیاز به ذخیره سازی متمرکز را حذف می نماید.

• کار [147] چارچوبی برای پیش بینی مسیر حرکت انسان با حفظ حریم خصوصی ارائه کرد تا عملکرد پیش بینی امیدوارکننده ای به دست آورد در حالی که داده های شخصی روی دستگاه های محلی باقی می ماند. بر اساس مدل تحرک DL، هیچ داده خصوصی به سرور مرکزی بارگذاری نمی شود؛ تنها پارامترهای مدل به روزرسانی شده ارسال می شوند که شکستن آن ها دشوار بوده و امنیت بیشتری دارند.

• نویسندگان [148] نشان دادند که FL برای وظایف تشخیص فعالیت انسانی (HAR) مدل هایی تولید می کند که کمی دقت پایین تر اما قابل قبول نسبت به تکنیک های متمرکز دارند. اخیراً از آن در چندین کار و در شبکه های خودرویی mmWave برای تحرک پیش دستانه استفاده شده تا اطلاعات موقعیت کاربر حفظ شود، بار ارتباطی کاهش یابد و فرکانس کمتر شود.

• نویسندگان [149] رویکرد FL شخصی سازی شده سلسله مراتبی (HPFL) را به عنوان یک چارچوب معماری کلاینت-سرور نوآورانه پیشنهاد کردند تا FL را در مدل سازی کاربران با کلاینت های ناسازگار به کار گیرند. FL سنتی مدل های کامل کاربران را بدون تبعیض تجمع و به روزرسانی می کند، اما HPFL تلاش می کند اجزای مختلف مدل های ناهمگون را به طور مستقل تقسیم و پردازش کند.

اطلاعات مکانی یک توانمندساز خدمات برای طراحی، عملیات و بهینه سازی شبکه های ارتباطی است [150]. FedLoc یک چارچوب جدید برای مکان یابی مشارکتی و پردازش داده های مکانی است که در [151] پیشنهاد شد. این رویکرد مسئله حریم خصوصی در مکان یابی هدف و پردازش داده های مکانی را در همکاری با بسیاری از کاربران موبایل به خوبی حل می کند.

مزایای رویکرد فدره ای عبارتند از:

- کارایی در مدیریت مسئله حریم خصوصی داده ها، که به کاربران موبایل اجازه می دهد اطلاعات مرتبط با مکان را به طور ایمن مبادله کنند.
- همکاری میان کاربران موبایل تلاش های کالیبراسیون را تسهیل می کند.
- تلفن های همراه به پلتفرم هایی توانمند برای انجام محاسبات پیچیده تبدیل می شوند.

کار [152] رویکرد دیگری مبتنی بر FL برای بهبود دقت مکان یابی مبتنی بر اثرانگشت قدرت سیگنال دریافتی ارائه کرد، در حالی که حریم خصوصی شرکت کنندگان Crowdsourcing

حفظ می‌شود. ایده اصلی این روش نوآورانه آن است که داده‌های محلی در همان‌جا که تولید می‌شوند باقی بمانند و تنها مدل‌های محلی در طول فرآیند یادگیری منتقل شوند. هنگامی که به‌عنوان تقویت‌کننده برای یادگیری متمرکز استفاده شد، رویکرد پیشنهادی دقت مکان‌یابی را به میزان 1.8 متر بهبود داد و هنگامی که به‌تنهایی استفاده شد، دقت مکان‌یابی رضایت‌بخشی به‌دست آورد.

نویسندگان [153] از FL برای تشخیص فعالیت انسانی (HAR) استفاده کردند که به هر کاربر اجازه می‌دهد وظیفه تشخیص فعالیت خود را به‌صورت ایمن و جمعی مدیریت کند. آن‌ها یک شبکه استخراج ادراکی (PEN) طراحی کردند به‌عنوان استخراج‌کننده ویژگی برای هر کاربر تا ویژگی‌های کافی از داده‌های HAR را ثبت کند. PEN شامل یک شبکه ویژگی برای کشف ویژگی‌های محلی و یک شبکه رابطه (ترکیبی از LSTM و مکانیزم توجه) است که مسئول استخراج روابط جهانی پنهان در داده‌ها می‌باشد.

E. برش شبکه (Network Slicing)

برش شبکه امکان تغییر از یک شبکه به‌عنوان پیکربندی زیرساخت به یک شبکه به‌عنوان سرویس را فراهم می‌کند تا طیف وسیعی از خدمات هوشمند G5 و G6 با نیازهای مختلف پشتیبانی شوند. با ادغام FL در برش شبکه، ارائه‌دهندگان مخابرات و اپراتورهای خدمات پتانسیل خدمات شخصی‌سازی‌شده را آزاد می‌کنند، در حالی که حریم خصوصی داده‌ها و عملکرد شبکه حفظ می‌شود. با افزایش تقاضا برای خدمات قابل‌سفارشی‌سازی و امن، ترکیب FL و برش شبکه احتمالاً نقش مهمی در آینده مخابرات ایفا خواهد کرد.

- نویسندگان [158] ادغام یک چارچوب FL با سیستم‌های لبه موبایل را پیشنهاد کردند تا عامل‌های یادگیری Q-دوگانه عمیق را در لبه شبکه برای تصمیمات کشینگ و تخلیه محاسبات آموزش دهند، در حالی که حریم خصوصی کاربران حفظ می‌شود. سیستم «In-Edge AI» ارزیابی شد و نشان داد که توانایی دستیابی به عملکرد نزدیک به بهینه با سربر یادگیری نسبتاً کم را دارد، در حالی که سیستم شناختی و سازگار با شبکه‌های ارتباطی موبایل باقی می‌ماند.

- در [159] نویسندگان یک رویکرد مبتنی بر FL برای بهبود راهبرد تخصیص منابع در اینترنت اشیا صنعتی چندگانه توسعه دادند.

این پیشنهاد نوآورانه‌ی یادگیری Q فدره‌ای عمیق شامل تخصیص منابع برش‌های اینترنت اشیا (IoT) از نظر توان انتقال و فاکتور گسترش بر اساس الزامات QoS برش‌ها است.

نویسندگان [160] از FL برای پیش‌بینی شاخص‌های کلیدی عملکرد (KPIs) خدمات‌محور برش‌ها استفاده کردند، به‌گونه‌ای که داده‌های خام در محل تولید باقی می‌مانند و تنها مدل‌های محلی کاربران به موجودیت مرکزی برای جمع‌آوری ارسال می‌شوند. نتایج به‌دست‌آمده کارایی رویکرد طراحی‌شده را در دستیابی به دقت پیش‌بینی خوب در حالی که مسائل حریم خصوصی رعایت می‌شوند نشان داد.

با هدف بهبود توان عملیاتی شبکه و کاهش هزینه جابجایی (Hand-off)، نویسندگان [161] یک طرح کارآمد برای ارتباط دستگاه‌ها در RAN Slicing طراحی کردند، با بهره‌گیری از یک چارچوب ترکیبی FRL. دو سطح جمع‌آوری برای مسئله ارتباط دستگاه‌ها پیشنهاد شد:

- یکی شامل همان نوع خدمات برای جمع‌آوری مدل‌های پارامتر محلی به‌منظور اشتراک نمونه‌های مشابه؛

- دیگری مربوط به انواع مختلف خدمات برای جمع‌آوری ویژگی‌های دسترسی و اتخاذ تصمیم جهانی بهینه درباره برش شبکه و انتخاب BS.

نویسندگان [162] برش شبکه توزیع‌شده برای G5 را بررسی کردند. آن‌ها یک چارچوب نوآورانه حول یک هماهنگ‌کننده فدره‌ای در صفحه کنترل معرفی کردند. این موجودیت مسئول هماهنگی منابع طیف و محاسبات است، بدون نیاز به تبادل داده‌های شخصی یا اطلاعات منابع از BS محلی. این چارچوب زمان پاسخ خدمات را برای هر دو سرویس پشتیبانی‌شده به‌طور قابل‌توجهی کاهش می‌دهد، به‌ویژه در مقایسه با برش شبکه‌ای که تنها یک منبع دارد.

F. بهینه‌سازی مسیریابی

مسیریابی پیش‌بینانه از قدرت هوش مصنوعی برای ارزیابی مداوم داده‌های بلادرنگ و پیش‌بینی نتایج استفاده می‌کند. بیشتر تکنیک‌های ML موجود برای هدایت انتخاب‌های مسیریابی و کنترل ترافیک ضروری هستند، اما به‌ندرت بر شبکه‌های چالش‌برانگیز تمرکز می‌کنند، شبکه‌هایی که با شرایط متغیر دائمی و حجم قابل‌توجهی از ترافیک تولیدشده توسط دستگاه‌های لبه مشخص می‌شوند. چندین سیستم FL برای حل این مشکلات و بهینه‌سازی تصمیمات مسیریابی در سناریوهای چالش‌برانگیز پیشنهاد شده‌اند.

برای افزایش عملکرد و تسهیل مقیاس‌پذیری برنامه‌های داده‌محور، نویسندگان [165] یک معماری فدره‌ای برای مسیریابی بسته‌ها در داخل یک شبکه لبه توزیع‌شده طراحی کردند. آن‌ها یک مدل انتخاب مسیر نوآورانه برای پیش‌بینی بهترین مسیر با استفاده از LSTM پیشنهاد کردند. هنگامی که بار اوج پیش‌بینی می‌شود، کنترل‌کننده از این اطلاعات برای تنظیمات مسیریابی استفاده می‌کند. با به‌کارگیری FL، همه کنترل‌کننده‌ها دید جهانی از زیرساخت به‌دست می‌آورند در حالی که اطلاعات نسبتاً کمی مبادله می‌شود، که به سازمان‌ها کمک می‌کند پهنای‌بند را برای ترافیک برنامه حفظ کنند.

نویسندگان [166] راهبردهای مسیریابی و کشینگ آگاه از تحرک برای شبکه‌های سلولی کوچک متراکم بر اساس چارچوب FL توسعه دادند تا جای‌گذاری کش را بهینه کرده و هزینه شبکه را به حداقل برسانند. آن‌ها ابتدا کل منطقه جغرافیایی را به بخش‌های کوچک تقسیم کردند، هر بخش با یک BS کوچک (SBS) و بسیاری از کاربران متحرک (MUs). آن‌ها یک راهبرد فدره‌ای برای مسیریابی و یادگیری محبوبیت پیشنهاد کردند که در آن SBSها به‌طور مشترک مسیریابی و ترجیحات MUs خود را یاد می‌گیرند و تصمیمات کشینگ اتخاذ می‌کنند.

در [167] نویسندگان یک برنامه مسیریابی غیرمتمرکز روی شبکه‌های حمل‌ونقل وابسته به زمان با استفاده از FL ایجاد کردند تا مدل‌های پیش‌بینی مشترک را به‌صورت آنلاین یاد بگیرند. همه مسیریابی در لبه شبکه در داخل یک شبکه مبه‌محاسباتی کنار جاده خصوصی انجام می‌شود، جایی که دسترسی به خدمات ابری خارجی متناوب فرض می‌شود. این سیستم از انتقال پهنای‌بند داده‌های خام بین فرآیندها جلوگیری می‌کند.

G. پهپاد (UAV)

ترکیب هوش مصنوعی و وسایل هوایی بدون سرنشین (UAVs)، که معمولاً به‌عنوان پهپاد شناخته می‌شوند، نوید قابل‌توجهی برای صنایع و کاربردهای مختلف دارد. با این حال، چالش‌هایی مرتبط با مقررات، ایمنی، حریم خصوصی، امنیت و پیچیدگی ایجاد می‌کند. FL یک کاربرد نوظهور و نویدبخش است که حفظ حریم خصوصی، تأخیر کم، سربر ارتباطی پایین، و یادگیری بلادرنگ را با قابلیت‌های UAVها ترکیب می‌کند.

- کار [169] یک مدل احراز هویت پهپاد مبتنی بر FL با ویژگی‌های RF پهپادها در شبکه‌های IoT ارائه کرد. معماری شبکه عصبی عمیق (DNN) استفاده شد، با بهینه‌سازی گرادین کاهشی تصادفی که به‌صورت محلی روی پهپادها انجام می‌شود. نتایج نشان داد که مدل احراز هویت فدره‌ای پهپاد نرخ مثبت واقعی بالایی در طول احراز هویت پهپاد به‌دست می‌آورد و عملکرد بهتری نسبت به سایر سیستم‌های ML دارد.

- مطالعه [170] از FL برای تسهیل حس‌کردن حفظ‌کننده‌ی حریم خصوصی و یادگیری مشارکتی در خدمات UAV استفاده کرد. این کار طراحی تطبیق قرارداد چندبعدی را پیشنهاد کرد که هدف آن تطبیق UAV بهینه با هر زیرمنطقه حس‌کردن است، در حالی که ناهمگنی UAVها در نظر گرفته می‌شود.

- نویسندگان [171] یک FL شخصی‌سازی‌شده سلسله‌مراتبی تو در تو پیشنهاد کردند، یک چارچوب جامع ML توزیع‌شده برای آموزش مدل شخصی‌سازی‌شده در سراسر سلسله‌مراتب شبکه هسته رهبر-کارگر. این روش از اشتراک داده‌ها در میان خوشه‌های دستگاه برای ایجاد مدل‌های محلی متناسب استفاده کرد.

• در [172] یک چارچوب FL امن برای MCS کهک گرفته از UAV ارائه شد. ابتدا سه حمله پیشنهاد شد و اقدامات مقابله‌ای مرتبط برای ایمن‌سازی یادگیری مشارکتی UAV بررسی شد. سپس، یک رویکرد FL با استفاده از شبکه بلاک‌چین توسعه یافت تا مشارکت‌های UAV به‌طور ایمن ذخیره و ردیابی شوند، در حالی که تبادل مدل محلی میان UAVها محافظت شود. در نهایت، یک مکانیزم اشتراک مدل محلی حفظ‌کننده حریم خصوصی توسعه یافت تا UAVها با دقت تجمع بالا محافظت شوند.

• نویسندگان [173] یک معماری نوآورانه برای پیاده‌سازی الگوریتم‌های یادگیری توزیع‌شده در داخل یک دسته UAV پیشنهاد کردند که شامل یک UAV رهبر و چندین UAV پیرو است.

هر UAV یک مدل FL محلی را بر اساس داده‌های جمع‌آوری‌شده خود آموزش داده و سپس آن را به UAV رهبر ارسال می‌کند؛ UAV رهبر مدل‌های دریافت‌شده را تجمع کرده، یک مدل فدره‌ای جهانی تولید می‌کند و دانش را از طریق شبکه درون‌دسته‌ای به پیروان منتقل می‌کند.

• در [174] نویسندگان سیستم‌های چند-UAV کهک گرفته از FL را برای طبقه‌بندی وظایف در سناریوهای اکتشافی پیشنهاد کردند. ابتدا آموزش محلی توسط هر UAV با تکیه بر تصاویر جمع‌آوری‌شده محلی انجام می‌شود؛ مدل توسعه‌یافته از آموزش محلی سپس منتقل می‌شود به

Ref	Application	Benefits	Drawbacks
[128]–[130], [168]	Traffic Classification	Safely classifying internet traffic as well improving the accuracy of packet transmission	More improvements are needed to deal with complex data and information security
[134]–[136]	Resource management	FL facilitates adaptive resource allocation, distributing bandwidth, power, and other resources intelligently across network nodes	Need more evaluations by considering for practical applications
[140]–[142]	Radio access network	Satisfy users' QoS requirements in terms of delay and data rate	Need more enhancement privacy beyond what FL inherently promotes
[146]–[149], [151]–[153]	User mobility/location prediction	Enabling predictive features on smartphones without diminishing the QoE or leaking private information	Mobile terminals should be able to process a modest amount of data and perform analysis with FL frameworks
[158]–[162]	Network slicing	Offering significant improvement on service latency performance for all supported services	Updating local models with high frequency increases the network overhead and consumes network and computing resources
[165]–[167]	Routing optimization	Optimizing routing for challenging scenarios while avoiding costly transfer of raw traffic data and reducing bandwidth stress	Need more travel time improvement and grid prediction models to mitigate the impact of errors on user trips
[169]–[175]	UAV flying networks	Handling target challenges in UAV systems as well as operating at a considerably lower communication cost	Need to accelerate the strategy-making process and the resource allocation should be optimized
[176], [177]	Underwater Networks	Enhancing underwater communication systems performance with high transmit power and secure underwater scenarios	The learning process should be more accelerated and applied in real scenarios
[178]–[183]	Cloud/Fog computing	Achieving less energy consumption to make full use of the big data in both cloud and fog computing	The training efficiency has to be enhanced as well as optimizing some critical parameters

TABLE VI
SUMMARY OF FL-BASED CONTRIBUTIONS AT NET LAYER.

نویسندگان [176] یک الگوریتم نوآورانه یادگیری تقویتی عمیق چندعاملی پیشنهاد کردند تا تغییرات غیرمنتظره محیط هوشمند اقیانوس و عدم‌اعتمادپذیری کانال را حذف کنند. ابتدا هر دستگاه آموزش DL توزیع‌شده را با داده‌های شخصی خود انجام می‌دهد و خروجی را در یک ایستگاه مرکزی تجمع می‌کند. سپس، ماشین مرکزی راه‌حل‌های بهینه جهانی را محاسبه کرده و نتایج را به شرکت‌کنندگان مرتبط توزیع می‌کند.

برای Ocean of Things، نویسندگان [177] یک چارچوب همکاری رادیویی اکوستیک تقویت‌شده با متا-یادگیری فدره‌ای توسعه دادند که از داده‌های توزیع‌شده در میان گروه‌های سطحی برای آموزش گیرنده DL در زمینه شبکه‌های بی‌سیم با زمان‌بندی تصادفی استفاده می‌کند. این رویکرد امکان سازگاری یادگیری انتقالی توزیع‌شده با مجموعه‌داده‌های جدید را فراهم می‌سازد.

I. رایانش ابری/مه (Cloud/Fog Computing)

اگرچه رایانش ابری در بسیاری از کاربردها یک پلتفرم قدرتمند محاسباتی محسوب می‌شود، اما در سناریوهایی با الزامات سخت‌گیرانه مانند پهپادها و خودروهای خودران که نیازمند تأخیر کم و حفظ حریم خصوصی هستند با مشکلاتی مواجه می‌شود. FL برای آموزش مدل‌های ML روی دستگاه‌های موبایل نویدبخش است، در حالی که محدودیت‌های محاسباتی، ذخیره‌سازی، انرژی و پهنای‌بند رعایت می‌شوند.

در نهایت، یک مدل جهانی در GFC روی کانال‌های محوشده ساخته شده و به هر UAV برای به‌روزرسانی مدل محلی بعدی ارسال می‌شود. این چارچوب با هزینه ارتباطی به‌طور قابل‌توجهی کمتر نسبت به ML سنتی عمل می‌کند. کارایی آموزش باید افزایش یابد و برخی پارامترهای حیاتی بهینه شوند؛ این رویکرد عملکرد توان عملیاتی را در سناریوهای زیرآبی به‌طور مؤثر ارتقا می‌دهد.

FL یک راه‌حل نویدبخش برای شبکه‌های ادهاک پروازی (FANET) است. نویسندگان [175] یک معماری امنیتی مبتنی بر FL برای تشخیص حملات جینگ در دستگاه‌ها طراحی کردند. آن‌ها یک تکنیک اولویت‌بندی گروه کلاینت‌ها با استفاده از نظریه Dempster–Shafer اضافه کردند، که به گره تجمع‌کننده اجازه می‌دهد گروه‌های کلاینت بهتر را برای محاسبه به‌روزرسانی جهانی شناسایی کند.

H. شبکه‌های زیرآبی

ارتباطات بی‌سیم زیرآبی نوع دیگری از ارتباطات بی‌سیم است که در آن سیگنال‌های اکوستیک از طریق کانال زیرآبی اطلاعات دیجیتال را ارسال می‌کنند. تلاش‌های زیادی برای ارتقای عملکرد سیستم‌های ارتباطی زیرآبی با استفاده از ML، DL و تکنیک‌های یادگیری انتقالی انجام شده است. با این حال، راه‌اندازی شبکه‌های زیرآبی چالش‌برانگیز است، زیرا تأخیر انتشار بالا و توان انتقال زیاد نسبت به شبکه‌های بی‌سیم فضای آزاد هوایی دارد. مکانیزم FL به‌عنوان روشی امن برای آموزش جمعی مدل‌های ارتباطی زیرآبی نویدبخش است.

در [178] نویسندگان یک چارچوب FL بسیار کارآمد با حفظ حریم خصوصی قوی در رایانش ابری ارائه کردند. به جای روش‌های تریق نویز، یک پروتکل رمزنگاری سبک‌وزن به کار گرفته شد که هم حریم خصوصی اثبات شده و هم کارایی مطلوب مدل را فراهم می‌کند. این رویکرد آموزش امن را برای یادگیری از همه داده‌های موجود فراهم می‌سازد.

رویکردهای موجود FL برای کاربردهای AIoT مبتنی بر ابر به نتایج پیش‌بینی دقیق‌تر نیاز دارند. نویسندگان [179] یک معماری مشارکتی ارائه کردند که مدل‌های DNN را در میان ابر و دستگاه‌های AIoT مستقر می‌کند. آن‌ها طرح‌های آموزش دو مرحله‌ای و هم‌استنتاجی طراحی کردند تا دقت پیش‌بینی دستگاه‌های AIoT منفرد را با استفاده از داده‌های اندک بهبود دهند.

شاخه‌های بزرگ در ابر مستقر شده‌اند و زمان استنتاج متوسط را کاهش می‌دهند. یک سیستم سلسله‌مراتبی کلانت-لبه-ابر مبتنی بر الگوریتم HierFAVG در [180] ارائه شد که به چندین سرور لبه اجازه می‌دهد تا جمع جزئی مدل را انجام دهند. این چارچوب به‌طور همزمان زمان آموزش مدل و مصرف انرژی دستگاه‌های انتهایی را نسبت به FL سنتی مبتنی بر ابر کاهش می‌دهد.

برای بهره‌برداری کامل از رایانش مه و هوش مصنوعی [192]، یک پارادایم جدید از شبکه‌های دسترسی رادیویی مه هوشمند مجهز به FL در [181] پیشنهاد شد. این چارچوب پردازش هوشمند سیگنال و مدیریت شبکه را با هزینه ارتباطی پایین و کارایی بالا پشتیبانی می‌کند و رویکردی عملی برای پیاده‌سازی هوش لبه شبکه فراهم می‌سازد.

نویسندگان [182] از FL برای پیش‌بینی محبوبیت محتوا در شبکه‌های دسترسی رادیویی مه استفاده کردند و پیچیدگی محاسباتی را کاهش دادند. ورودی‌های مدل پیش‌بینی امتیازهای محبوبیت میانگین شده برای محتوای کاربران خوشه‌بندی شده هستند، سپس مدل به‌طور خودکار با آموزش الگوریتم بر اساس محبوبیت تاریخی و ورودی‌های پیش‌پردازش شده یاد گرفته می‌شود.

برای رفع شکاف حریم خصوصی در رایانش مه، نویسندگان [183] یک سیستم FL مبتنی بر بلاک‌چین ایجاد کردند که یادگیری ماشینی خودکار را بدون هیچ مرجع مرکزی برای نگهداری مدل جهانی و هماهنگی با استفاده از بلاک‌چین امکان‌پذیر می‌سازد. عملکرد تأخیر نرخ تولید بلوک بهینه را با در نظر گرفتن ارتباطات، تأخیر اجماع، و هزینه‌های محاسباتی استخراج می‌کند.

ج. خلاصه

این بخش یافته‌های اخیر درباره کاربرد مکانیزم‌های FL در لایه شبکه را پوشش می‌دهد. این پارادایم نوظهور نتایج نزدیک به تکنیک‌های ML متمرکز به‌دست می‌آورد، در حالی که الزامات G5 و G6 مانند حریم خصوصی کاربر، تأخیر، محدودیت محاسبات، انرژی و پهنای‌بند را تضمین می‌کند.

درس‌های آموخته‌شده از این بخش عبارتند از:

- کاربرد FL در لایه شبکه نحوه مدیریت، بهینه‌سازی و تکامل شبکه‌ها را بازتعریف می‌کند. با بهره‌گیری از رویکرد یادگیری غیرمتمرکز FL، لایه شبکه توانایی ارتقای عملکرد، پاسخگویی و هوشمندی خود را به‌دست می‌آورد، در حالی که چالش‌های حیاتی (مانند حریم خصوصی) را برطرف می‌کند.

- در حالی که کاربردهای FL در لایه شبکه مزایای زیادی نوید می‌دهند، چالش‌هایی مانند بار ارتباطی، همگام‌سازی، امنیت و مقیاس‌پذیری نیز وجود دارند.

جدول VI خلاصه‌ای از مشارکت‌های مبتنی بر FL که معماری لایه شبکه را ارتقا می‌دهند نشان می‌دهد.

VI. یادگیری فدرال در لایه‌های کاربرد/انتقال

لایه‌های کاربرد و انتقال آخرین اجزای مدل OSI هستند که پروتکل‌های مشترک و روش‌های رابط مورد استفاده میزبان‌ها در یک شبکه ارتباطی را مشخص می‌کنند. FL به‌طور قابل‌توجهی مدیریت چالش‌های لایه کاربرد در شبکه‌های ارتباطی بی‌سیم را بهبود می‌دهد. در این بخش، بررسی عمیقی از مشارکت‌های اخیر FL در زمینه لایه‌های کاربرد و انتقال ارائه می‌کنیم.

FL برای ارتقای عملکرد و کارایی پروتکل انتقال داده و پروتکل کنترل انتقال (TCP) که برای انتقال داده قابل‌اعتماد روی اینترنت استفاده می‌شوند، به کار گرفته می‌شود. این رویکرد چندین مزیت دارد، از جمله بهبود کنترل ازدحام، مدیریت شبکه، و بهینه‌سازی پروتکل [193].

برای ارتقای عملکرد اینترنت خودروها، نویسندگان [194] یک چارچوب FL حفظ‌کننده حریم خصوصی پیشنهاد کردند که اتصال فراگیر میان خودروها را تضمین می‌کند و یک مکانیزم محلی برای برآورده‌سازی الزامات قابلیت اعتماد و تأخیر ارائه داد. این کار یک چارچوب ریاضی معرفی کرد که احتمال از دست رفتن بسته TCP و تأخیر را برای خودروها زمانی که کانال‌های بی‌سیم دچار سطوح مختلف از دست رفتن و تأخیر انتقال می‌شوند، به‌طور دقیق تخمین می‌زند.

نویسندگان [195] از FL برای مطالعه عملکرد جریان‌های TCP مرکب بلندمدت (C-TCP) روی زیرساخت WiFi صنعت 4.0 استفاده کردند. آن‌ها یک مدل تحلیلی نوآورانه توسعه دادند تا اثرات برخورد‌ها، از دست رفتن‌های بی‌سیم، و از دست رفتن‌های بافر AP را روی C-TCP در WiFi با جریان‌های دوطرفه بررسی کنند. نتایج نشان می‌دهد که رادیوی شناختی FL عملکرد سناریوهای صنعتی متعدد را به‌طور قابل‌توجهی ارتقا می‌دهند.

B. محاسبات توزیع شده و مشارکتی

محاسبات توزیع شده پارادایمی است که در آن عناصر یک سیستم نرم‌افزاری در میان چندین رایانه توزیع می‌شوند، اما به‌طور جمعی به‌عنوان یک سیستم یکپارچه عمل می‌کنند. این راهبرد برای ارتقای کارایی و عملکرد به کار گرفته می‌شود. ترکیب AI و محاسبات توزیع شده چالش‌هایی در مدیریت داده و ارتباط میان گره‌ها ایجاد می‌کند. پارادایم FL برای مدیریت این سیستم‌های محاسبات توزیع شده استفاده می‌شود، با آموزش یک مدل مشترک به‌صورت مشارکتی در حالی که همه داده‌ها روی دستگاه‌های خود باقی می‌مانند.

در [196] نویسندگان یک چارچوب دفاعی محاسبات توزیع شده برای جامعه پایدار طراحی کردند، با ترکیب FL و بلاک‌چین برای حفظ حریم خصوصی و آزادسازی پتانسیل کامل ML در محیط‌های محاسبات توزیع شده. نتایج در مقایسه با رویکردهای سنتی از نظر دقت و خطا امیدوارکننده هستند.

اخیراً، محاسبات مشارکتی به‌عنوان یک پارادایم نوظهور در حوزه راهبردهای توزیع شده مطرح شده است. این رویکرد حول همکاری و هم‌افزایی میان گره‌های محاسباتی مختلف برای دستیابی به عملکرد و کارایی سیستم ارتقا یافته می‌چرخد. این رویکرد از هوش جمعی و منابع اجزای منفرد بهره می‌گیرد و راه را برای راه‌حل‌های نوآورانه‌ای که چالش‌های پیچیده را برطرف می‌کنند هموار می‌سازد.

در [197] نویسندگان یک چارچوب FL نوآورانه معرفی کردند که از همکاری دستگاه‌هایی که عملیات داده را در داخل شبکه انجام می‌دهند بهره می‌گیرد، با تکرار محاسبات محلی و تعاملات متقابل از طریق روش‌های مبتنی بر اجماع. این روش راه را برای ادغام FL در G5 و فراتر از آن هموار می‌کند، که با اتصال و محاسبات غیرمتمرکز مشخص می‌شود.

C. جمع‌سپاری / حس‌سپاری

جمع‌سپاری پتانسیل بالایی برای انجام وظایف محاسباتی دارد، به دلیل توانایی آن در جمع‌آوری سریع اطلاعات [198]. FL برای پیاده‌سازی این جمع‌سپاری استفاده می‌شود. محاسبات جمع‌سپاری شامل آموزش مدل‌های ML با استفاده از داده‌های غیرمتمرکز از چندین سرور است، بدون انتقال داده‌ها به یک مکان مرکزی. این کار به محافظت از داده‌های حساس کمک می‌کند در حالی که یادگیری و تحلیل به اشتراک گذاشته می‌شود.

• نویسندگان [199] یک چارچوب جمع‌سپاری مبتنی بر FL، بلاک‌چین و فناوری بازمرگذاری ارائه کردند. همه گره‌های بلاک‌چین در جمع‌سپاری شرکت می‌کنند تا یک نسخه پشتیبان کامل داده حفظ شود. با اتخاذ FL، هر کارگر مدل یا داده‌گرادین را برای تجمیع به کلاینت‌ها بازگذاری می‌کند. این رویکرد به کاربران اجازه می‌دهد جمع‌سپاری غیرمتمرکز را با سربار کمتر و امنیت بالاتر پیاده‌سازی کنند، در حالی که قابلیت میزبانی محاسباتی نیز بهبود می‌یابد.

• کار [200] FL و حریم خصوصی محلی تقاضی را برای تسهیل موارد استفاده جمع‌سپاری مطالعه کرد. این رویکرد به برنامه‌های جمع‌سپاری خودرویی اجازه می‌دهد مدل‌های ML را آموزش دهند و وضعیت ترافیک را پیش‌بینی کنند، در حالی که حریم خصوصی حفظ شده و هزینه‌های ارتباطی کاهش می‌یابد.

اخیراً، حس‌سپاری (Crowdsensing) توجه زیادی را به خود جلب کرده و به پارادایمی جذاب برای جمع‌آوری داده‌های مبتنی بر حسگر تبدیل شده است. با این حال، ماهیت متنوع و حساس داده‌های جمع‌آوری‌شده از طریق حس‌سپاری نیازمند مکانیزم‌های قوی حفاظت از حریم خصوصی برای ایمن‌سازی هویت کاربران و اطلاعات شخصی است. پرداختن به این چالش برای آزادسازی پتانسیل کامل حس‌سپاری در حالی که استانداردهای حریم خصوصی رعایت می‌شوند ضروری است.

• در [202] یک چارچوب حس‌سپاری فدره‌ای پیشنهاد شد تا نگرانی‌های حریم خصوصی در چهار مرحله حس‌سپاری (ایجاد وظیفه، تخصیص وظیفه، اجرای وظیفه، و تجمیع داده) تحلیل شود.

• نویسندگان [203] FL را در جمع‌سپاری موبایل ادغام کردند تا سیستمی حفظ‌کننده حریم خصوصی با نام PriFedAvg طراحی کنند، جایی که شرکت‌کنندگان داده‌های حس‌کرده را به‌صورت محلی پردازش کرده و تنها مدل‌های آموزشی رمزگذاری‌شده را بازگذاری می‌کنند.

• مسئله جذب کاربر آگاه از کیفیت در [204] بررسی شد، با استفاده از FL برای پیش‌بینی کیفیت داده‌های حس‌شده از کاربران مختلف، از طریق تحلیل همبستگی بین داده و اطلاعات زمینه. این روش کیفیت داده‌های حس‌شده را نسبت به الگوریتم‌های سنتی بهبود می‌دهد.

• یک رویکرد نوآورانه در [205] برای تشخیص وظایف جعلی بر اساس FL افقی توسعه یافت. دو الگوریتم ML و مجموعه داده‌ها برای شناسایی وظایف جعلی شامل چندین دستگاه تشخیص مستقل و یک موجودیت تجمیع پیاده‌سازی شدند.

D. کیفیت تجربه (QoE)

تکامل خدمات استریمینگ به نرخ داده بالا، تأخیر کم، و QoS خوب نیاز دارد. چندین چالش باید هنگام ارائه یک سرویس خاص برطرف شوند، از جمله تعداد زیاد دستگاه‌ها، شبکه‌های ناهمگون، و محیط‌های غیرقابل کنترل. مفهوم کیفیت تجربه (QoE) تلاش‌های پژوهشی زیادی را برای بهبود و ارائه خدمات قابل اعتماد و ارزش‌افزوده با تجربه کاربری بالا به خود اختصاص داده است [206].

مدل‌های QoE مبتنی بر ML به دلیل حجم کم داده و پروفایل محدود شرکت‌کنندگان دچار بیش‌برازش می‌شوند [207]. یک طرح ML حفظ‌کننده حریم خصوصی مانند FL امکان اشتراک مدل‌های داده QoE بین همه شرکت‌کنندگان را تنها با انتقال پارامترهای مدل فراهم می‌کند.

• نویسندگان [208] FL و یادگیری Round-Robin را به کار گرفتند، جایی که مدل به‌صورت متوالی میان گره‌های همکار آموزش داده می‌شود، تا نشان دهند که دقت بالا بدون اشتراک داده‌های حساس بین شرکت‌کنندگان حاصل می‌شود.

• برای مدیریت روان مدل QoE و دستیابی به دقت بالاتر، کار [209] یک روش تولید داده مصنوعی بیزی مبتنی بر مجموعه برای FL ارائه داد که زمان آموزش را 30٪ و ردپای شبکه در کانال ارتباطی را 60٪ کاهش می‌دهد.

E. امنیت سایبری (Cybersecurity)

امنیت سایبری از تکنیک‌های AI برای ارتقای عملکرد امنیتی و حفاظت بهتر در برابر تهدیدات پیچیده بهره می‌برد [210]. با این حال، معماری ML سنتی به دلیل حجم زیاد داده، ناهمگونی داده، سرعت بالای داده، و چالش‌های عمده در جمع‌آوری هوش سایبری و مجموعه داده‌های حمله از منابع توزیع‌شده، پاسخگوی نیازهای امنیت سایبری نیست. پارادایم FL برای آموزش امن مدل‌ها در وظایف تشخیص ناهنجاری بدون جمع‌آوری داده‌های خام استفاده می‌شود [211].

• یک رویکرد حفظ‌کننده حریم خصوصی در [212] پیشنهاد شد تا از صحت نتایج محاسبات سرور برای هر کاربر پشتیبانی کند، که به همه شرکت‌کنندگان اجازه می‌دهد درستی نتایج بازگردانده‌شده از سرور مرکزی را با سربار قابل قبول تأیید کنند.

• نویسندگان [213] یک چارچوب مبتنی بر FL برای تشخیص URL‌های مخرب در محیط ارائه‌دهنده خدمات امنیتی مدیریت‌شده طراحی کردند. آن‌ها سناریوهای مختلفی را درباره تقسیم داده بین عامل‌ها بررسی کردند و دریافتند که مدل ML فدره‌ای مشارکتی عملکرد طبقه‌بندی URL را در همه سناریوها ارتقا داده و نرخ آن را تا 27٪ بهبود می‌دهد.

• در [214] نویسندگان چارچوب FedDICE را معرفی کردند که FL را در معماری امنیتی مبتنی بر SDN ادغام می‌کند تا یادگیری مشارکتی، تشخیص، و کاهش حملات باحفاظت را در محیط‌های مشارکتی امکان‌پذیر سازد. این رویکرد عملکردی مشابه نتایج یادگیری متمرکز به‌دست می‌آورد.

• کار [215] یک سیستم دفاع تهدید هوشمند مبتنی بر بلاک‌چین FL توسعه داد، که به دنبال ارتقای کامل نحوه عملکرد سیستم‌های هوشمند منفعل است، با هدف طبقه‌بندی هوشمند ترافیک شبکه‌های شهرهای هوشمند مشتق‌شده از IoT صنعتی با روش‌های بازرسی محتوای عمیق برای شناسایی ناهنجاری‌هایی که معمولاً ناشی از حملات پیشرفته مداوم هستند.

F. خلاصه

در این بخش، یک مرور جامع از ادبیات درباره کاربرد FL در لایه‌های کاربرد و انتقال ارائه کردیم. بسیاری از بهبودها و راه‌حل‌های نویدبخش وجود دارند که بر عملکرد انتقال، محاسبات توزیع‌شده، جمع‌سپاری، امنیت سایبری، و QoE تأثیر دارند.

درس‌های آموخته‌شده از این بخش عبارتند از:

• به‌کارگیری FL در هر دو لایه انتقال و کاربرد یک رویکرد هم‌افزایی معرفی می‌کند که نحوه انتقال، پردازش، و استفاده از داده‌ها در سراسر شبکه را ارتقا می‌دهد. این ادغام پتانسیل بهینه‌سازی جنبه‌های فنی انتقال داده و جنبه‌های عملکردی برنامه‌های کاربرمحور را دارد.

• تضمین انتقال امن داده، مدیریت همگام‌سازی، بهینه‌سازی سربار ارتباطی، و رسیدگی به مقیاس‌پذیری از جمله ملاحظات هستند که نیازمند توجه و نوآوری مستمر می‌باشند.

جدول VII مروری بر مشارکت‌های FL در لایه‌های APP و Transport ارائه می‌دهد و مزایا و معایب آن‌ها را برجسته می‌سازد.

VII. کاربردها و حوزه‌های عمودی یادگیری فدره‌ای

در این بخش، مزایای اتخاذ یک طرح FL در سناریوهای شبکه بی‌سیم، شامل رانندگی خودکار، تشخیص ناهنجاری، عملیات صنعتی، مراقبت‌های بهداشتی هوشمند، و سایر کاربردها را بررسی می‌کنیم.

A. رانندگی خودکار

رانندگی خودکار و خودروهای خودران اکنون در میان برجسته‌ترین حوزه‌های پژوهشی قرار دارند [216]. این حوزه شامل کاربرد تکنیک‌های ML و DL است که داده‌ها را انتخاب کرده، اطلاعات را تبدیل می‌کنند، فرآیندها را کنترل کرده و تصمیم‌گیری می‌کنند [217]. با این حال، فرآیند ترتیبی معماری‌های متمرکز بسیار زمان‌بر است و دانش حاصل از مدل‌های تنظیم‌شده

محلی باقی می‌ماند و مورد استفاده قرار نمی‌گیرد. بنابراین، FL به‌عنوان مکانیزمی قدرتمند در نظر گرفته می‌شود که به دستگاه‌ها امکان می‌دهد با محیط خود تعامل کرده و دانش را به‌طور ایمن از سایر دستگاه‌ها کسب کنند [218].

• برای طراحی کنترل‌کننده خودکار خودروهای متصل و خودران (CAV) تحت شرایط عدم قطعیت لینک بی‌سیم و پویایی محیط، کار [219] یک چارچوب DL جدید ارائه کرد: الگوریتم فدرالی پروگزیمال پویا برای فرآیند آموزش، که یک منظم‌ساز (Regularizer) در CAVها معرفی می‌کند تا اثر داده‌های غیر IID و نامتوازن بر همگرایی FL را کاهش دهد.

• در [220] نویسندگان FL را در رانندگی خودکار ادغام کردند تا حریم خصوصی خودروها حفظ شود و دقت مدل بهبود یابد، با نگه‌داشتن داده‌های اصلی در خودرو محلی و تنها اشتراک پارامترهای مدل آموزشی از طریق سرور MEC. نتایج نشان داد که سیستم رانندگی خودکار مبتنی بر FL، 73.7٪ کاهش در خطای آموزش و حدود 5.55٪ بهبود در دقت ایجاد می‌کند.

• برای شبکه‌سازی خودرویی آگاه از حریم خصوصی و کارآمد، نویسندگان [221] یک سیستم FL مبتنی بر بلاک چین خودکار ساختند تا اعتمادپذیری انتها-به-انتها و تأخیر را تضمین کنند. این چارچوب ارتباطات خودروهای خودران را با اجازه دادن به مازول‌های ML محلی روی خودرو برای اشتراک و اعتبارسنجی به‌روزرسانی‌هایشان به‌صورت کاملاً غیرمتمرکز امکان‌پذیر می‌سازد.

• کار [222] یک فرآیند یادگیری تقویتی انتقالی فدرالی آنالین طراحی کرد تا دانش را برای خودروهای خودران در زمان واقعی استخراج کند. در این مدل، همه عامل‌های شرکت‌کننده اقدامات متناظر را با دانش آموخته‌شده توسط دیگران انجام می‌دهند، حتی زمانی که در محیط‌های بسیار متفاوت عمل می‌کنند. نتایج نشان داد که رویکرد پیشنهادی دانش را به‌طور مؤثر آنالین منتقل می‌کند، با سرعت و عملکرد آموزشی بهتر.

• برای به حداقل رساندن مصرف توان در سطح شبکه کاربران خودرویی در حالی که قابلیت اعتماد بالا از نظر تأخیرهای صف‌بندی احتمالی تضمین می‌شود، کار [223] یک طرح نوآورانه برای تخصیص مشترک توان انتقال و منابع با استفاده از FL پیشنهاد کرد، که سربارهای غیرضروری را کاهش می‌دهد.

• نویسندگان [224] یک مفهوم جدید از شبکه خودرویی مبتنی بر FL با نام FVN پیشنهاد کردند، که عملکردی سازگارتر نسبت به شبکه‌های خودرویی سنتی ارائه می‌دهد و برنامه‌های داده/محاسبات‌محور را مدیریت می‌کند. نتایج به‌دست‌آمده نشان داد که چارچوب پیشنهادی دقت بالا و مصرف انرژی کمتر فراهم می‌سازد.

B. تشخیص ناهنجاری

FL به‌طور بالقوه کاربردهای معناداری برای تشخیص حملات مخرب در سیستم‌های ارتباطی موبایل دارد.

• برای مثال، Diot یک سیستم توزیع‌شده خودیادگیرنده خودکار برای تشخیص دستگاه‌های IoT آلوده است. رویکرد طراحی‌شده در [225]، پروفایل‌های رفتاری را به‌طور کارآمد با تکیه بر پروفایل‌های ارتباطی خاص نوع دستگاه، بدون دخالت انسانی یا داده‌های پرسج‌خورده، جمع می‌کند.

• در [226] نویسندگان FL را برای تشخیص ناهنجاری شبکه و تحلیل ترافیک شبکه به‌کار گرفتند تا مشکل کمبود داده را برطرف کرده و حریم خصوصی داده‌ها را حفظ کنند. این شامل طراحی یک DNN چندوظیفه‌ای برای انجام وظایف تشخیص ناهنجاری شبکه، شناسایی ترافیک، و طبقه‌بندی ترافیک است.

• یک معیاری تشخیص ناهنجاری برای تولید هوشمند مبتنی بر IoT صنعتی در [227] ارائه شد. این معیاری ناهنجاری‌ها را برای داده‌های سری زمانی که معمولاً در داخل یک سیستم صنعتی اجرا می‌شوند، تنها با ارسال مدل آموزشی هر لبه به ابر برای به‌روزرسانی جهانی تشخیص می‌دهد. این رویکرد 35٪ صرفه‌جویی در پهنای باند مصرف‌شده در لینک انتقال بین لبه و ابر ایجاد می‌کند.

• در [228] نویسندگان یک چارچوب هوشمند تشخیص نفوذ با استفاده از FL توسعه دادند. ابتدا مدل جهانی LSTM روی سرورها مستقر می‌شود. سپس هر کاربر مدل محلی خود را آموزش داده و پارامترهای آن را به سرور مرکزی بازگردانی می‌کند. در نهایت، سرور مرکزی جمع پارامترهای مدل را انجام داده و دانش جدید را به همه شرکت‌کنندگان توزیع می‌کند. این رویکرد دقت بالاتر و سازگاری بهتر نسبت به روش‌های متداول به‌دست می‌آورد.

C. عملیات صنعتی

عملیات صنعتی به توسعه حوزه‌های بسیاری اشاره دارد، از جمله پردازش تصویر، رباتیک، تولید، کشاورزی، و سایر زمینه‌ها. تکنیک‌های ML و DL برای حل مسائل مختلف صنعتی به‌کار گرفته شده‌اند [229]. با این حال، یادگیری متمرکز سنتی به‌دلیل نگرانی‌های مربوط به حریم خصوصی و مقیاس‌پذیری نیازهای سناریوهای صنعتی را برآورده نمی‌کند. چن‌دین کار با استفاده از FL طراحی و اجرا شده‌اند تا این چالش‌ها را برطرف کنند و نتایج بالقوه‌ای ایجاد نمایند [230].

• نویسندگان [231] یک چارچوب کارآمد و حفظ‌کننده حریم خصوصی (PEFL) FL توسعه دادند تا مسائل چالش‌برانگیز صنعتی در هوش مصنوعی صنعتی را حل کنند. طرح PEFL غیرتعاملی است که از نشت حریم خصوصی از گرادان‌های محلی و پارامترهای مشترک جلوگیری می‌کند، حتی زمانی که یک مهاجم با چندین موجودیت تبانی کند. نتایج مزیت این رویکرد را از نظر دقت و کارایی نشان می‌دهد.

• یک مکانیزم FL قابل‌تأیید (VFL) با حفظ حریم خصوصی برای داده‌های بزرگ در IoT صنعتی در [232] پیشنهاد شد.

Ref	Application	Benefits	Drawbacks
[194], [195]	Transport performance	Enhancing TCP performance while preventing privacy leakage	Must implemented in complex networks to analyze the convergence and throughput fairness
[196], [197]	Cooperative and Distributed Computing	Securely manage distributed and cooperative systems without requiring large computation	Requiring more efficient use of the limited bandwidth, including quantization, compression, or ad hoc channel encoding
[199], [200], [202]–[205]	Crowdsourcing and Crowdsensing	Facilitating crowdsourcing and crowdsensing applications with less overhead, less communication cost and higher security	Need to study the waiting for charging as most crowdsensing tasks have temporal deadlines
[208], [209]	QoE	Enabling a seamless QoE model management without having to use sensitive data	Insufficient performance due to the difficulties in accessing QoE datasets
[212]–[215]	Cybersecurity	Effectively detecting attacks while addressing issues of data sharing	Have to apply the FL strategy when the attackers influence the model training

TABLE VII
SUMMARY OF FL-BASED CONTRIBUTIONS AT TRANSPORT/APP LAYERS.

این چارچوب به‌طور مؤثر امنیت مدل و گرادیان خصوصی را تضمین می‌کند، زیرا به هر شرکت‌کننده اجازه می‌دهد نتایج تجمع‌شده را بر اساس درون‌یابی لاگرانژ (Lagrange interpolation) تأیید کند، و سربار تأیید مستقل از تعداد شرکت‌کنندگان ثابت باقی می‌ماند. مکانیزم VFL در بسیاری از سناریوهای صنعتی به‌کار گرفته می‌شود، به‌دلیل مزایای آن از نظر تأیید و سربار کلی. برای ارائه مجموعه‌ای ساختاریافته از نیازمندی‌ها و جریان‌های کاری در معماری FL صنعتی (IFL)، نویسندگان [233] یک سیستم IFL طراحی کردند که از تبادل دانش در گروه‌های یادگیری FL به‌طور مستمر ارزیابی و به‌روزرسانی‌شده با شباهت داده کافی پشتیبانی می‌کند. طرح پیشنهادی همکاری بهینه شرکای تجاری در مسائل مشترک ML را امکان‌پذیر می‌سازد، از انتقال منفی دانش جلوگیری می‌کند، و بهینه‌سازی منابع دستگاه‌های لبه درگیر را تضمین می‌کند.

نویسندگان [234] معماری جدیدی از دولگوی دیجیتال (DT) توانمندساز IoT صنعتی پیشنهاد کردند، که تغییرات پویا شبکه را به‌طور حساس ثبت می‌کند. طرح پیشنهادی فرکانس تجمع را بر اساس وضعیت کانال تنظیم کرده و عملکرد بهتری از نظر دقت یادگیری، نرخ همگرایی، و صرفه‌جویی انرژی ارائه می‌دهد.

FL راه‌حل‌های کارآمدی برای یادگیری مشارکتی در سیستم‌های چندریات غیرمتمرکز و سیستم‌های خودمختار توزیع‌شده فراهم می‌کند [235]. نویسندگان [236] یک معماری پردازش داده بلادرنگ برای چندریات بر اساس FL تفاضلی پیشنهاد کردند، که در آن یک مدل جهانی به‌صورت تکراری روی ابر آموزش داده شده و به چندین ربات لبه توزیع می‌شود. این معماری در وظایف مختلف شناسایی رباتیک به‌کار گرفته می‌شود و توازن میان عملکرد و حریم خصوصی را برقرار می‌سازد.

D. ارتباطات فوق‌قابلیت اعتماد با تأخیر کم (URLLC)

ارتباطات فوق‌قابلیت اعتماد با تأخیر کم (URLLC) یکی از ستون‌های کلیدی G NR5 است [237]، برای تأخیر بسیار کم (مثلاً 1 میلی‌ثانیه) و قابلیت اعتماد بسیار بالا (مثلاً 99.999%). با پیشرفت‌های اخیر در ML و DL داده‌محور، امکان یادگیری طیف وسیعی از سیاست‌ها برای شبکه‌های بی‌سیم فراهم شده است. با این حال، این روش‌ها نیازمند:

- دوره آموزشی طولانی،
- تعداد زیاد نمونه‌های آموزشی،
- زمان طولانی برای به‌دست آوردن نمونه‌های کافی،
- مجوز دسترسی به داده‌ها هستند.

FL یک روش نویدبخش است که مدل‌های ML را به‌طور ایمن و مشارکتی آموزش می‌دهد و الزامات URLLC را بهبود می‌بخشد، به‌ویژه یادگیری تقویتی فدرال که یکی از تنظیمات توزیع‌شده است و محیط را در میان دستگاه‌های غیرمتمرکز متعدد یاد می‌گیرد بدون آنکه داده‌های خصوصی آن‌ها به اشتراک گذاشته شود.

• یک مدل یادگیری تقویتی عمیق در [238] برای توسعه معماری چندسطحی به‌کار گرفته شد که هوش دستگاه، هوش لبه، و هوش ابری را به‌ترتیب در سطح کاربر، سلول، و شبکه برای URLLC فعال می‌کند. با توجه به ظرفیت محاسباتی محدود هر کاربر و هر سرور MEC، نویسندگان FL را برای بهبود کارایی یادگیری به‌کار گرفتند.

• کار [239] یک چارچوب توزیع‌شده مبتنی بر FL برای تخصیص مشترک توان انتقال و منابع در ارتباطات خودرویی ارائه کرد تا URLLC بهبود یابد. نظریه مقادیر حدی برای مشخص کردن محدودیت‌ها از نظر URLLC به‌کار گرفته شد، با تخمین توزیع دُم به‌صورت محلی بدون اشتراک نمونه‌های طول صف واقعی. این رویکرد مقدار داده‌های مبادله‌شده و سربارهای غیرضروری را کاهش می‌دهد.

• پرداختن به مقیاس‌پذیری URLLC و سازگاری آن با سایر خدمات URLLC/غیر-URLLC یک مشکل بزرگ است. نویسندگان [240] یک راه‌حل دسترسی چندگانه ترکیبی پیشنهاد کردند

تا این مسائل را به‌صورت کارآمد از نظر طیف/انرژی برطرف کنند، با بهره‌گیری از رویکرد ML سلسله‌مراتبی توزیع‌شده برای مدیریت پیش‌دستانه منابع رادیویی در جریان‌های مختلف ترافیک URLLC. نتایج نشان می‌دهد که طرح مبتنی بر FL نرخ داده را 75٪ افزایش داده و قابلیت اعتماد 99.99٪ را برای هر دو نوع ترافیک زمان‌بندی‌شده و زمان‌بندی‌نشده فراهم می‌سازد.

E. اینترنت لمسی (Tactile Internet)

اینترنت لمسی (TI) گام بعدی اینترنت اشیاء است، شامل ارتباط انسان-ماشین و ماشین-ماشین. تمرکز اصلی آن بر ارائه تکنیک‌های تعاملی بلادرنگ با مجموعه‌ای از موارد استفاده مهندسی، اجتماعی، و تجاری است که نیازمند درجه بالایی از قابلیت اعتماد و تأخیر کم هستند [241].

تکنیک‌های AI نقش مهمی در رسیدگی به چالش‌های TI ایفا خواهند کرد [242]، به‌ویژه FL که پتانسیل عظیمی برای بهینه‌سازی انرژی، منابع، و تأخیر انتقال در کاربردهای اینترنت لمسی دارد [243].

نویسندگان [244] از FRL برای برآورده‌سازی الزامات ارتباطات موبایل B5G استفاده کردند، به‌ویژه در مکانیزم‌های دسترسی کانال لایه‌های MAC و PHY که URLLC را در G NR5 برای اینترنت لمسی فعال می‌سازد. FRL یک راه‌حل نوظهور برای مدیریت سناریوهای جدید شبکه بی‌سیم است، زیرا از داده‌های بدون برچسب یاد می‌گیرد و نیاز به فرمول‌بندی فرآیند تصمیم‌گیری مارکوف را برای اتخاذ تصمیمات بهینه، مسیریابی و انتخاب لینک برطرف می‌کند.

F. واقعیت مجازی/افزوده/گسترش‌یافته و متاورس

واقعیت مجازی (VR) یک محیط رایانه‌ای تولیدشده است با صحنه‌ها و اشیای واقع‌گرایانه که به کاربر احساس غوطه‌وری کامل در محیط اطراف می‌دهد. استقرار این فناوری جدید روی شبکه‌های بی‌سیم گامی اساسی برای استقرار انعطاف‌پذیر برنامه‌های فراگیر VR است [245]. یکی از چالش‌های کلیدی در VR، قطع حضور (BIP) است که کاربران را از دنیای مجازی جدا می‌کند. نویسندگان [246] مدلی نوآورانه طراحی کردند که نوع برنامه VR، تأخیر انتقال، کیفیت ویدئوی VR، و آگاهی کاربران از محیط مجازی را به‌طور مشترک در نظر می‌گیرد تا BIP را برای کاربران VR بی‌سیم اندازه‌گیری کند. آن‌ها یک استراتژی FL اتخاذ کردند تا چندین BS مدل خود را به‌طور محلی با داده‌های جمع‌آوری‌شده آموزش دهند و به‌طور مشارکتی یک مدل جهانی بسازند تا مکان و جهت‌گیری همه کاربران را پیش‌بینی کند. این روش نسبت به رویکردهای متمرکز عملکرد بهتری دارد و BIP کاربران را کاهش می‌دهد.

واقعیت افزوده (AR) نسخه‌ای ارتقا یافته از دنیای واقعی است که با عناصر بصری دیجیتال، صدا یا محرک‌های حسی دیگر از طریق فناوری حاصل می‌شود. با هدایت بینایی رایانه‌ای و ابزارهای AI، فناوری AR رشد چشمگیری نشان داده است [247]. با این حال، پهنای‌بند موجود برای انتقال و پردازش حجم عظیم داده‌های تولیدشده بسیار محدود است، که تشخیص و طبقه‌بندی اشیاء را برای AR دشوار می‌سازد. برای حل چالش طبقه‌بندی در برنامه‌های AR حساس به تأخیر که نیازمند نرخ داده بالا هستند، کار [248] چارچوبی پیشنهاد کرد که FL را با رایانش لبه موبایل (MEC) ترکیب می‌کند تا مدل ML بهینه جهانی به‌دست آید. ارزیابی‌ها نشان دادند که این رویکرد به‌طور قابل‌توجهی به تکرارهای آموزشی کمتری نسبت به چارچوب‌های متمرکز سنتی نیاز دارد. برای حل مشکلات حریم خصوصی در AR، نویسندگان [249] یک مدل راهبرد خروجی AR چندکاربره پیشنهاد کردند که از روش یادگیری تقویتی فدرال سلسله‌مراتبی برای تولید و تجمع مدل راهبرد خروجی AR برای چندین کاربر استفاده می‌کند. این چارچوب اطلاعات سناریوهای AR چندکاربره را به‌طور مؤثر یاد می‌گیرد و مقاومت مدل راهبرد خروجی تطبیقی را بهبود می‌بخشد.

واقعیت گسترش‌یافته (XR) به همه محیط‌های واقعی و مجازی و تعاملات انسان-ماشین که توسط فناوری رایانه و دستگاه‌های پوشیدنی تولید می‌شوند اشاره دارد [250]. فناوری‌های XR حجم عظیمی از داده‌های شخصی و دقیق کاربران را جمع‌آوری و پردازش می‌کنند. FL روشی نویدبخش برای مدیریت این چالش‌ها در حالی که هزینه‌ها کاهش یافته و مجموعه‌داده‌های

FedHealth از یادگیری انتقالی برای ایجاد مدل‌های شخصی‌سازی شده برای هر سازمان استفاده می‌کند. این مدل‌های شخصی‌سازی شده به‌طور مستمر با ارسال پارامترهای اصلاح شده مدل جهانی به سازمان‌های مربوطه به‌روزرسانی می‌شوند.

• در [257] نویسندگان یک سیستم مبتنی بر FL توانمندسازی شده با رایانش لبه پیشنهاد کردند تا آموزش مشارکتی مدل حفظ‌کننده حریم خصوصی را در میان شرکت‌کنندگان توزیع شده برای توسعه برنامه‌های بهداشتی تسهیل کنند. نتایج نشان داد که طراحی قرارداد در دو دوره زمانی خودافشاگر است و سود بیشتری برای مالک مدل نسبت به راهبرد یکنواخت باز می‌گردد.

• FL خوشه‌ای در [258] برای توسعه یک سیستم تشخیص خودکار بیماری کووید-19 به کار گرفته شد. این رویکرد به مؤسسات بهداشتی راه دور اجازه می‌دهد از یادگیری مشارکتی بهره‌مند شوند بدون آنکه داده‌های محلی و اطلاعات مرتبط را به اشتراک بگذارند.

H. سیستم‌های توصیه‌گر

سیستم‌های توصیه‌گر در شبکه‌های بی‌سیم نقش مهمی در ارتقای تجربه کاربران، بهینه‌سازی تخصیص منابع شبکه، و بهبود کارایی کلی شبکه دارند [259]. پیاده‌سازی سیستم‌های توصیه‌گر کارآمد در شبکه‌های بی‌سیم نیازمند ترکیبی از تحلیل داده، الگوریتم‌های ML، و پردازش داده بلادرنگ است. این شامل جمع‌آوری و تحلیل رفتار کاربر، شاخص‌های عملکرد شبکه، و داده‌های زمینه‌ای می‌شود [260].

FL اخیراً در سیستم‌های توصیه‌گر به کار گرفته شده است تا حریم خصوصی کاربران حفظ شود و دقت پیش‌بینی افزایش یابد [261]. در تنظیمات FL، سیستم‌های توصیه‌گر مدل‌های توصیه با جمع‌آوری پارامترهای میانی به جای داده‌های خام آموزش می‌دهند.




Fig. 6. Year-wise publications of FL for mobile networks [generated from all cited papers].

VIII. بینش‌ها و مسائل باز

FL توجه زیادی در شبکه‌های ارتباطی بی‌سیم به‌دست آورده است، زیرا روش‌های بهتر و ایمن‌تری برای ارتقای عملیات موبایل فراهم می‌کند. اخیراً پیشرفت‌های قابل توجهی مبتنی بر FL در سیستم‌های بی‌سیم توسعه یافته‌اند که نویدبخش استقرار گسترده در آینده‌ی G6 هستند. با این حال، FL هنوز یک حوزه پژوهشی نوظهور است با چندین مسئله چالش‌برانگیز مانند: خطرات حریم خصوصی و امنیت، کمبود/کیفیت داده، ناهمگونی سیستم، پیچیدگی، و همگرایی [264]. در این بخش، مسائل باز FL را بررسی کرده و خلاصه‌ای از راه‌حل‌های اخیر، بینش‌ها و فرصت‌ها ارائه می‌کنیم.

A. درس‌های آموخته شده

در این آموزش، ما نتایج اخیر و دستاوردهای پژوهشی پیشگام مرتبط با FL را گردآوری، طبقه‌بندی و با دقت تحلیل کردیم. همان‌طور که در شکل 6 نشان داده شده، تعداد

پراکنده حفظ می‌شوند است. نویسندگان [251] روش‌های FL توزیع شده را در شبکه‌های V2X بررسی کردند تا قابلیت طبقه‌بندی کاربران جاده/اشیا را بر اساس داده‌های Lidar افزایش دهند، جایی که اشتراک مدل در تعداد زیادی لایه پیاده‌سازی می‌شود، بسته به کارایی و الزامات پهنای باند.

متاورس به یک فضای مجازی مشترک اشاره دارد که اغلب شامل AR، VR، XR و سایر محیط‌های دیجیتال غوطه‌ور است. این یک جهان دیجیتال به هم پیوسته است که کاربران در آن تعامل، اجتماعی شدن، کار و فعالیت‌های گسترده انجام می‌دهند [252]. به کارگیری FL در متاورس حریم خصوصی داده‌های کاربران را حفظ کرده و نیاز به توان محاسباتی و حافظه بالا روی سرورها را کاهش می‌دهد [253].

G. مراقبت‌های بهداشتی هوشمند

تکنیک‌های ML و DL پتانسیل زیادی برای تسریع پیشرفت مراقبت‌های بهداشتی هوشمند نشان داده‌اند. با این حال، در بسیاری از موقعیت‌های بهداشتی، مقدار محدود داده موجود اجازه ساخت مدل‌های قدرتمند برای بررسی چالش‌های موجود را نمی‌دهد. در این راستا، FL به کار گرفته می‌شود تا مؤسسات پزشکی بتوانند تجربه‌های خود را — و نه داده‌هایشان — با تضمین حریم خصوصی به اشتراک بگذارند، و وظایف شخصی‌سازی شده مراقبت‌های بهداشتی و زیست‌پزشکی را به‌طور ایمن انجام دهند [254]، [255].

• نویسندگان [256] چارچوب FedHealth را با استفاده از FTL توسعه دادند که داده‌ها را از سازمان‌های توزیع شده تجمیع می‌کند تا الگوریتم‌های ML قدرتمند آموزش داده شوند، در حالی که حریم خصوصی مشتری حفظ می‌شود. پس از آموزش اولیه یک مدل جهانی در ابر،

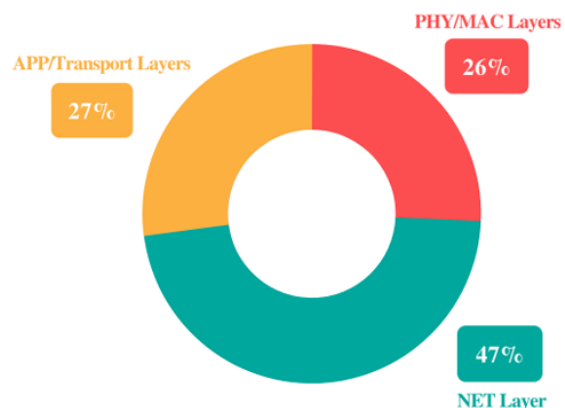


Fig. 7. Proportion of FL-based approaches per network layer [generated from all cited papers].

داده‌های واقعی کاربران منتقل نمی‌شوند، که به‌طور چشمگیری حریم خصوصی کاربران را ارتقا می‌دهد [262].

یک چارچوب سیستم توصیه‌گر حفظ‌کننده حریم خصوصی در [263] پیشنهاد شد که با ادغام معماری FL، الگوریتم توصیه را قادر می‌سازد بدون جمع‌آوری متمرکز داده‌های خصوصی کاربران آموزش داده شده و استنتاج انجام دهد. این رویکرد خطر نشت حریم خصوصی را کاهش می‌دهد، الزامات قانونی و مقرراتی را برآورده می‌سازد، و اجازه می‌دهد الگوریتم‌های توصیه مختلف به کار گرفته شوند.

I. خلاصه

در این بخش، یک مرور جامع از آخرین پژوهش‌های مرتبط با FL در سیستم‌های G6 ارائه کردیم. تمرکز ما بر برجسته‌سازی بهبودهای کلیدی حاصل از اتخاذ FL در مقایسه با ML متمرکز بوده است. یک مرور خلاصه در جدول VIII آمده است.

مشارکت‌های یادگیری FL در شبکه‌های موبایل طی هفت سال گذشته به‌طور پیوسته رشد کرده و به‌طور گسترده در طراحی شبکه به‌کار گرفته شده است (شکل 7). در واقع، FL راه‌حل‌های کارآمد و مؤثری نسبت به تکنیک‌های سنتی AI برای مدیریت مشکلات بی‌سیم در حالی که حریم خصوصی حفظ می‌شود ارائه می‌دهد.

خلاصه درس‌های آموخته‌شده:

• G6 و فراتر از آن نیازمند انعطاف‌پذیری بالا، قابلیت اعتماد، حریم خصوصی، و هوشمندی شبکه هستند. این ویژگی‌های مطلوب به‌طور کارآمد و مؤثر توسط رویکردهای FL فراهم می‌شوند.

• FL پتانسیل شکل‌دهی به سیستم‌های بی‌سیم نسل بعدی را دارد، با ارتقای پشته پروتکل و برآورده‌سازی نیازهای آینده‌ی برنامه‌های داده‌محور. با ادغام FL در لایه‌های مختلف شبکه، سیستم‌های بی‌سیم از ارزش‌های بنیادی مانند پایداری، اعتمادپذیری، عدالت، کاهش سربار ارتباطی، مقاومت بالا و درجه‌ای بی‌سابقه از تنوع بهره‌مند خواهند شد.

• پشتیبانی FL توسط شبکه‌های بی‌سیم پتانسیل انقلاب در صنایع مختلف، از مراقبت‌های بهداشتی و تولید تا شهرهای هوشمند و کشاورزی هوشمند را دارد، زیرا خدمات شخصی‌سازی‌شده نوین، مدیریت کارآمد منابع، و تصمیم‌گیری داده‌محور را امکان‌پذیر می‌سازد.

• FL به‌عنوان رویکردی تحول‌آفرین برای تکامل سیستم‌های ارتباطی بی‌سیم آینده مطرح است. با این حال، چالش‌هایی مانند کارایی ارتباطی، تجمع مد، و امنیت هنوز باید برطرف شوند تا پتانسیل FL در G6 و شبکه‌های بی‌سیم آینده به‌طور کامل بهره‌برداری شود. ادغام FL در چرخه طراحی شبکه‌های آینده قابلیت‌های آن‌ها را از نظر عملکرد، حریم خصوصی، مقاومت، و هوشمندی بازتعریف خواهد کرد.

B. چالش‌های یادگیری فدرال

از طریق مرور نظام‌مند ادبیات موجود، برخی گلوگاه‌های اصلی که پژوهش‌های فعلی FL را تحت سلطه دارند شناسایی کردیم:

1) حریم خصوصی و امنیت: برخلاف طرح‌های غیرمتمرکز، یادگیری فدرال برای ارائه یادگیری ماشینی امن میان عامل‌های یادگیری توزیع‌شده طراحی شده است. با این حال، حریم خصوصی داده همچنان چالش‌برانگیز است به‌دلیل حضور مهاجمان، مانند کلاینت‌های مخرب روی دستگاه یا کاربران مخرب با دسترسی جعبه‌سیاه به مدل [265]. اگرچه داده‌های محلی ممکن است از دستگاه خارج نشوند، یک نفوذگر همچنان می‌تواند حضور یک نقطه داده استفاده‌شده در آموزش را تشخیص دهد [52]. تلاش‌های زیادی برای مقابله با این مسئله با استفاده از یادگیری انتقالی، تجمع امن، و شناسایی حملات انجام شده است [266]، [267].

Ref	Application	Benefits	Drawbacks
[219]–[224]	Autonomous driving	Achieving potential learning across several decentralized vehicles by only sharing local model parameters	Need to limit the increase in the overall delay and avoid the privacy leakage risk
[225]–[228]	Anomaly detection	Improving the scalability of malicious attacks detection for distributed wireless communication networks	The training phase should be optimized in terms of weights communicating and performance
[238]–[240]	URLLC	Decreasing service delay and providing high reliability while preserving user's information	Cannot handle the non-IID training data and a large number of connected devices
[244]	Tactile internet	Achieving intelligent and optimized network control and resource allocation for URLLC requirements	Each device must learn the optimal decision with the help of exploration
[246], [248], [249], [251]	VR/AR/XR Metaverse and	Improving the generation of virtual objects by optimizing the resource management and reducing the overall latency for VR/AR users	The security problems caused by non-visual output along with the conflict between multiple output types
[256]–[258]	Smart healthcare	Allowing organizations to benefit securely from distributed medical experiences	Must explore the performance in varied distributed data to enhance efficiency and flexibility
[260]–[263]	Recommendation system	Training a distributed recommender system while protecting user privacy	The communication between the user and the server leads to increased overhead and latency

TABLE VIII
SUMMARY OF FL-BASED VERTICALS AND APPLICATIONS.

2

(3) انتخاب کلاینت (Client Selection):

کلاینت‌های FL تعداد محدودی از تکرارهای آموزشی را با استفاده از پارامترهای به‌روزرسانی محلی اجرا کرده و تنها به‌روزرسانی‌های مدل را با سرور جمع‌کننده مبادله می‌کنند. تعداد عامل‌ها به‌اندازه کافی بزرگ است و پهنای‌بند موجود برای توزیع به‌روزرسانی مدل محدود می‌باشد. بنابراین، انتخاب بهترین زیرمجموعه از کلاینت‌ها در مرحله آموزش عملی است، زیرا سیاست انتخاب کلاینت برای FL از نظر کارایی آموزش و کیفیت مدل جهانی حیاتی است.

به‌طور آشکار، گروه‌های کلاینت مجموعه‌داده‌های محلی بسیار ناهمگون تولید می‌کنند و توانایی‌های محاسباتی متفاوتی دارند [274]، که بر همگرایی مدل جهانی تأثیر می‌گذارد. چارچوب FL باید مقاوم باشد تا Dropout را طراحی کرده و سناریوهایی را پیش‌بینی کند که تنها تعداد کمی از شرکت‌کنندگان برای یک تکرار آموزشی متصل باقی می‌مانند.

چندین فعالیت پژوهشی برای پر کردن این شکاف انجام شده است:

• در [275] نویسندگان یک چارچوب انتخاب کلاینت طراحی کردند که به‌طور انعطاف‌پذیر مصالحه بین سرعت همگرایی و سوگیری راحل را پوشش می‌دهد. آن‌ها نشان دادند که سوگیری انتخاب کلاینت به سمت کلاینت‌هایی با خطای محلی بالاتر، همگرایی خطا را سریع‌تر می‌سازد.

(Complexity and Convergence) پیچیدگی و همگرایی:

یادگیری فدرال در طول آموزش از پیچیدگی محاسباتی بالایی رنج می‌برد، زیرا اجرای الگوریتم‌های اجماع در محیط‌های عظیم و ناهمگون با سیستم‌های ارتباطی مختل/معیوب انجام می‌شود. این شامل تعداد زیادی دستگاه دستی (Handsets) با داده‌هایی است که توسط توزیع‌های متنوع تولید می‌شوند، که منجر به سربار ارتباطی بالا می‌گردد. هدف FL آموزش مدل‌های باکیفیت با پیچیدگی ارتباطی کمتر و همگرایی سریع‌تر است؛ بنابراین طراحی طرح‌های کارآمد برای غلبه بر این محدودیت حیاتی است.

در [268] دو راه‌حل برای کاهش هزینه‌های ارتباطی Uplink طراحی شد:

- یادگیری یک به‌روزرسانی مستقیم از مجموعه‌ای کاهش‌یافته از متغیرها.
- یادگیری یک به‌روزرسانی کامل مدل و فشرده‌سازی آن قبل از ارسال به سرور.

بر اساس گرادیان نزولی، نویسندگان [269] کران همگرایی FL با مجموعه‌داده‌های غیر IID را تحلیل کردند. سایر پژوهش‌ها برای انتقال Uplink و Downlink پیشنهاد شدند تا زمان همگرایی بهبود یابد [270]–[273].

• Tang و همکاران [276] از همبستگی بین کلاینت‌ها برای دستیابی به همگرایی سریع‌تر و پایدارتر در سناریوهای ناهمگون استفاده کردند.

• در [277] نویسندگان مکانیزم انتخاب کلاینتی پیشنهاد کردند که به سرور اجازه می‌دهد کلاینت‌هایی را انتخاب کند که بر اساس منابع موجودشان بتوانند شرکت کنند. سرور درباره مقدار داده، انرژی، و منابع CPU موردنیاز برای شرکت در هر دور تصمیم می‌گیرد.

• در [278] یک چارچوب انتخاب کلاینت با محدودیت تأخیر برای FL ناهمگون در سیستم‌های حمل‌ونقل هوشمند پیشنهاد شد، با هدف بهبود دقت مدل، سرعت آموزش، و زمان انتقال.

• همچنین، یادگیری تقویتی برای بهبود عملکرد انتخاب کلاینت به‌کار گرفته شد، با دخالت یک عامل RL که سیاست انتخاب کلاینت را یاد می‌گیرد [279].

• یک مدل Multi-Armed Bandit در [280] برای انتخاب کلاینت استفاده شد تا FL ناپایدار را تقویت کند، با سرعت‌بخشیدن به همگرایی مدل، ارتقای دقت مدل، و کاهش مصرف انرژی.

• به‌طور جایگزین، [281] و [282] روش انتخاب کلاینتی بر اساس الگوریتم ژنتیک پیشنهاد کردند که بر اساس هزینه کلاینت و دقت مدل عمل می‌کند.

• در [283] نویسندگان انتخاب کلاینت را به‌عنوان یک بازی ارائه کردند، جایی که کلاینت‌ها علاقه خود را برای شرکت در فرآیند FL ابراز می‌کنند.

(4) انصاف و توزیع نقش (Fairness & Role Distribution):

سیستم‌های FL برای آموزش مدل‌های توزیع‌شده با استفاده از داده‌های محلی غیرمتمرکز و خصوصی طراحی شده‌اند، که نیازمند ارزیابی مقاومت و پایداری آموزش در میان‌مدت/بلندمدت است. بیشتر تکنیک‌های فعلی مدل‌ها را ترکیب کرده و آن‌ها را متناسب با فراوانی نمونه‌های محلی اولویت‌بندی می‌کنند. با این حال، مسئله توزیع نقش بین شرکت‌کنندگان FL همچنان حل‌نشده باقی‌مانده و نیازمند پیاده‌سازی انصاف بالا است. این موضوع از منظر تضمین دقت در میان کلاینت‌ها بررسی شده است [284].

چندین کار پژوهشی رویکردهای مقاوم برای رسیدگی به مسئله انصاف به‌کار گرفته‌اند.

نویسندگان [285]–[287] تلاش کردند تا انصاف کلی را بدون به‌خطر انداختن عملکرد پیش‌بینی بهبود دهند، به‌ترتیب با استفاده از افزایش داده بدون نمونه (Zero-shot data augmentation)، بهینه‌سازی لیابانوف (Lyapunov optimization)، و اعتبار شرکت‌کنندگان (Participants reputation). پژوهش ارائه‌شده در [288] مفهوم میانگین‌گیری منصفانه فدره‌ای (Federated Fair Averaging) را معرفی کرد تا پیش از میانگین‌گیری گرادین‌ها، تعارضات احتمالی میان کلاینت‌ها کاهش یابد. در [282] نویسندگان یک چارچوب FL پیشنهاد کردند که از الگوریتم ژنتیک برای تضمین انصاف و بهبود حجم و ناهمگونی داده‌ها در فرآیند FL استفاده می‌کند. رویکرد دیگری برای انتخاب منصفانه کلاینت در [289] ارائه شد که از یک طرح چندمعیاره پویا برای ارتقای انصاف میان کلاینت‌ها در هر دور فرآیند FL بهره می‌گیرد.

(5) کیفیت داده (Data Quality)

کیفیت داده در FL یک عامل حیاتی است که مستقیماً بر دقت، قابلیت اعتماد، و عملکرد مدل‌های آموزش‌دیده تأثیر می‌گذارد. حفظ کیفیت بالای داده در FL یک چالش چندوجهی است که نیازمند توجه دقیق است:

• ناهمگونی داده‌ها: در دنیای واقعی فرض i.i.d برقرار نیست، زیرا منابع داده ممکن است همبستگی‌های مکانی یا زمانی داشته باشند، که می‌تواند منجر به ناکارآمدی در همگرایی یا دقت و مشکلات جدی در انصاف شود.

• برجسب‌گذاری داده‌ها: برای وظایف یادگیری نظارت‌شده، برجسب‌گذاری ناسازگار میان دستگاه‌ها ممکن است منجر به مدل‌های سوگیرانه و پیش‌بینی‌های نادرست شود.

• داده‌های نامتوازن: مدیریت عدم‌توازن داده در FL ضروری است تا تعمیم‌پذیری و نمایش منصفانه در همه کلاس‌ها تضمین شود.

• تازگی داده‌ها: تضمین تازگی داده‌ها حیاتی است تا روندها، الگوها، تغییرات بلادرنگ و رفتارهای کاربر ثبت شوند. در عین حال، تأخیر شبکه، سربار ارتباطی، و مصرف باتری باید برای ایجاد توازن کارآمد میان تازگی داده و ارتباط مدیریت شوند.

• مقررات داده: برای رعایت مقررات مربوط به مکان ذخیره/پردازش داده، حفاظت، و سایر محدودیت‌ها، سیستم‌های FL باید جنبه‌های قانونی و اخلاقی را در کل زنجیره ارزش داده در نظر بگیرند.

چارچوب معرفی‌شده در [290] FL و بلاک‌چین را ترکیب می‌کند تا کیفیت داده بالا برای وظایف پیچیده ML تضمین شود، در حالی که دقت مدل‌های آموزش‌دیده افزایش می‌یابد. علاوه بر این، استفاده از تکنیک‌های پیش‌پردازش، اعتبارسنجی محلی، و راهبردهای تجمیع سختگیرانه به حفظ کیفیت داده و ایجاد مدل‌های FL مقاوم و قابل‌اعتماد کمک می‌کند.

C. چالش‌های بی‌سیم برای یادگیری فدره‌ای

برای آموزش الگوریتم‌های FL، همه شرکت‌کنندگان باید پارامترهای آموزشی خود را روی یک شبکه مشترک منتقل کنند، که نیازمند مواجهه با چندین مسئله ارتباطی مهم است [291]. در این بخش، مشکلات اصلی مرتبط با پیاده‌سازی FL در محیط‌های بی‌سیم ارائه می‌شوند.

(1) محدودیت‌های منابع (Resource Constraints): دستگاه‌های بی‌سیم معمولاً مجهز به قابلیت‌های سخت‌افزاری و نرم‌افزاری محدود هستند، که می‌تواند کارایی آموزش مدل محلی و کل قابلیت اجرای FL را به‌شدت تحت‌تأثیر قرار دهد. به‌طور خاص، FL ممکن است به‌دلیل جنبه‌های زیر دچار کاهش کارایی شود:

• توان محاسباتی: بیشتر گوشی‌های موبایل و دستگاه‌های IoT توان محاسباتی محدودی دارند، که توانایی آن‌ها برای انجام به‌روزرسانی‌های پیچیده مدل و آموزش محلی سنگین را تحت‌تأثیر قرار می‌دهد. در نتیجه، اصطلاحاً Stragglers با توان پردازشی پایین ممکن است کیفیت آموزش را کاهش داده و کل فرآیند FL را کند کنند. بنابراین طراحی سیاست‌هایی برای مدیریت Stragglers مانند افزونگی راهبردی یا وزن‌دهی به هر کلاینت اهمیت حیاتی دارد.

• محدودیت‌های حافظه: مقدار کم حافظه نصب‌شده روی دستگاه‌ها اندازه مدل‌هایی را که می‌توانند پردازش کنند محدود کرده و زمان پردازش را افزایش می‌دهد. بنابراین تنها آموزش مدل‌های سبک و/یا دقت پایین—متوسط ممکن است پشتیبانی شود.

• زمینه بی‌سیم: انتقال به‌روزرسانی‌های مدل و گرادین‌ها روی شبکه بی‌سیم نیازمند تخصیص کارآمد پهنای‌بند برای مقابله با تغییرپذیری کانال است. دستگاه‌هایی که از زمینه بی‌سیم غیرقابل کنترل/غیرقابل پیش‌بینی رنج می‌برند ممکن است تجربه ارتباطی ضعیفی داشته باشند، که منجر به تأخیرهای نامحدود و سربار ارتباطی بالا می‌شود، به‌ویژه در مدل‌های بزرگ یا به‌روزرسانی‌های مکرر.

• ملاحظات انرژی: اجرای گوشی‌های موبایل و حسگرهای IoT با محدودیت جدی انرژی به‌دلیل عمر باتری محدود مواجه است. در واقع، وظایف آموزشی سنگین ممکن است منجر به تخلیه سریع باتری شوند، که بر مقاومت FL و تجربه کاربر تأثیر می‌گذارد. بنابراین طراحی مکانیزم‌های به‌روزرسانی مدل کم‌مصرف و راهبردهای ارتباطی سبز برای حفظ تجربه یادگیری رضایت‌بخش حیاتی دارد.

محدودیت‌های فوق بر اثربخشی، کارایی، و امکان‌پذیری پیاده‌سازی FL روی سیستم‌های شبکه بی‌سیم تأثیر می‌گذارد. پژوهش‌های متعددی (مانند [292]، [293]) تکنیک‌هایی مانند فشرده‌سازی مدل، راهبردهای بهینه‌سازی فدره‌ای، و الگوریتم‌های یادگیری تطبیقی متناسب با

دستگاه‌های محدود از نظر منابع را بررسی کرده‌اند تا تعادل میان دقت مدل و کارایی منابع برقرار شود و مشارکت مؤثر طیف گسترده‌ای از دستگاه‌ها در اکوسیستم FL امکان‌پذیر گردد.

2) یادگیری فدرال روی بی‌سیم (Federated Learning Over Wireless): لینک‌های بی‌سیم چالش‌های اضافی هنگام انتقال به‌روزرسانی‌های مدل و داده‌ها از/به دستگاه‌های شرکت‌کننده به/از سرور مرکزی در چارچوب FL معرفی می‌کنند. خطاهای نماد (Symbol Errors) ناشی از ماهیت غیرقابل‌اعتماد کانال بی‌سیم بر کیفیت و صحت به‌روزرسانی‌های FL میان کاربران تأثیر می‌گذارد و عملکرد الگوریتم‌های FL و سرعت همگرایی آن‌ها را تحت‌تأثیر قرار می‌دهد.

برای رسیدگی به اتصال غیرقابل‌اعتماد ذاتی در FL، نویسندگان [294]، [295] استفاده از کدگذاری اصلاح خطا، طرح‌های مدولاسیون و کدگذاری تطبیقی، الگوریتم‌های تجمع مقاوم، و انتقال داده افزونه‌ای را پیشنهاد کردند. این رویکردها هدف دارند تا اطمینان حاصل شود که فرآیند FL حتی تحت ارتباطات بی‌سیم معیوب نیز به‌طور مؤثر ادامه یابد.

3) تجمع داده روی هوا (Over-the-Air Data Aggregation): محاسبات روی هوا مزیت مصرف پایین منابع را ارائه می‌دهد، زیرا BS تنها نیاز دارد توابع بارگذاری‌شده توسط کاربران را مدیریت کند، نه داده‌های فردی. اجرای FL با تجمع روی هوا به کاربران اجازه می‌دهد منابع طیفی مشترک داشته باشند، که منجر به ارتقای کارایی ارتباطی می‌شود [296]. با این حال، چندین کار مانند [297]، [298] تأثیر تغییرات زمانی کانال را بر این فرآیند بررسی کرده‌اند.

همگرایی FL با تجمع روی هوا نشان می‌دهد که تداخل ناخواسته تنها اثرات مخرب محدودی دارد و مانع همگرایی الگوریتم یادگیری نمی‌شود. با این حال، مسائل دیگری نیز باید مورد توجه قرار گیرند، مانند اعوجاج مدل ناشی از محوشدگی کانال، تجمع ناکارآمد روی هوا برای مدل‌های محلی آموزش‌دیده با عدم توازن داده قابل توجه، و محدودیت در دسترسی بودن و تأیید مدل‌های محلی فردی.

D. موضوعات داغ و بینش‌ها

در این بخش، یک مرور کلی از موضوعات داغی که هنوز نیازمند توجه برای FL معنادار هستند ارائه می‌کنیم. همچنین چندین جهت‌گیری برای کارهای آینده با علاقه‌مندی بالا در جوامع پژوهشی مختلف ترسیم می‌کنیم.

1) FL و رایانش/شبکه لبه (Edge Computing/Networking): ترکیب FL و رایانش لبه نوید مدیریت حجم عظیم داده‌های جمع‌آوری‌شده به‌طور ایمن از دستگاه‌های موبایل فراگیر را می‌دهد. رایانش لبه به موقعیت‌هایی اشاره دارد که گره‌های کاربر توان محاسباتی و/یا ذخیره‌سازی دارند اما برای هماهنگی یا واگذاری فعالیت‌های محاسباتی سنگین به کمک لبه نیاز دارند. FL مدت‌هاست به‌عنوان یک تطابق عالی برای برنامه‌های مبتنی بر لبه شناخته شده و تلاش‌های پژوهشی زیادی برای کارآمدتر کردن آن انجام شده است [299].

با این حال، تعامل بین FL و رایانش/شبکه لبه به یک میدان باز تبدیل شده است با چندین مسئله برای حل:

- گره‌ها با استفاده از فناوری‌های مختلف دسترسی رادیویی به سرور لبه متصل می‌شوند، که بر تأخیر تحویل به‌روزرسانی‌های مدل تأثیر می‌گذارد.

- کلاینت‌های موبایل ناهمگون با قابلیت‌های متفاوت نیز عملکرد FL را تحت‌تأثیر قرار می‌دهند. بنابراین مجموعه کلاینت‌های شرکت‌کننده در فرآیند FL باید به‌طور راهبردی انتخاب شوند.

- در طول تبادل به‌روزرسانی‌های مدل، چندین کلاینت با داده‌های آموزشی روی دستگاه خود مشارکت می‌کنند، و جلوگیری از ارسال داده‌های جعلی توسط کلاینت‌های مخرب دشوار است، که می‌تواند فرآیند آموزش و مدل یا پارامترهای گرادین دریافتی را آلوده کند.

2) FL برای کاربردهای G6: کاربردهای آینده‌ی G6 انتظار می‌رود حجم عظیمی از داده‌ها تولید و مدیریت کنند، مانند واقعیت گسترش‌یافته (XR)، واقعیت ترکیبی (MR)، تعاملات بی‌سیم

مغز-رایانه، ارتباطات هولوگرامی، اینترنت لمسی، mURLLC، XURLLC، و سایر موارد استفاده که نیازمند QoS بالا، قابلیت اعتماد شگفت‌انگیز و تأخیر بسیار کم هستند [300].

طرح‌های ML فدرال به‌شدت توصیه می‌شوند تا یادگیری بهتر و ارتباط امن میان دستگاه‌های توزیع‌شده حاصل شود [301]. با این حال، نگرانی‌های جدیدی هنگام به‌کارگیری FL برای فناوری‌های نوظهور ایجاد می‌شوند، به‌ویژه تحلیل همگرایی که تحت‌تأثیر تضعیف انتشار بزرگ در باند THz قرار دارد و بهینه‌سازی پارامترها برای توزیع کلید کوانتومی.

3) FL و بلاک‌چین: فناوری بلاک‌چین رمزنگاری را با محاسبات توزیع‌شده ترکیب می‌کند تا حریم خصوصی شبکه‌های غیرمتمرکز را بهبود دهد و نیاز به مرجع مرکزی را کاهش دهد. در [302]، [303] نشان داده شده که پیاده‌سازی FL و بلاک‌چین به خودکارسازی انتقال انرژی کمک می‌کند و به ارائه‌دهندگان انرژی خودمختار اجازه می‌دهد ارزش را به‌طور ایمن مبادله کنند [304].

علاوه بر این، ابزارهای نظریه بازی می‌توانند به FL کمک کنند تا ارتباطات میان شبکه‌های بی‌سیم توزیع‌شده را به‌طور قابل‌توجهی کاهش دهد و مشکلات بنیادی الگوریتم‌های یادگیری توزیع‌شده و حفظ‌کننده حریم خصوصی در مقیاس بزرگ را برطرف کند [305]، [306]. در اینجا، یادگیرندگان فدرال محلی بازیکنان هستند و تجمع گرادین‌های دریافتی در سرور مرکزی اثر بازی میانگین-میدان است. اتخاذ مکانیزم‌های انگیزشی از طریق بلاک‌چین و نظریه بازی به سیستم‌های توزیع‌شده کمک می‌کند تا عادات و ترجیحات کاربران را بررسی کرده، و ارتباط و کارایی موتورهای جستجوی آنلاین را بهبود دهند.

4) تقطیر فدرال (Federated Distillation): با وجود کارایی ارتباطی، FL همچنان نیازمند انتقال مدل‌های گسترده از تعداد زیادی کلاینت از طریق هوا است. محدودیت‌های شناخته‌شده FL عبارتند از:

- کلاینت‌ها باید همان معماری مدل را پیاده‌سازی کنند.

- انتقال وزن‌ها و به‌روزرسانی‌های عظیم مدل هزینه ارتباطی بالایی دارد.

- طرح‌های تجمع مبتنی بر میانگین پارامترها به دلیل انحراف مدل کلاینت‌ها عملکرد ضعیفی دارند.

تقطیر دانش (Knowledge Distillation) به غلبه بر محدودیت‌های تکنیک میانگین‌گیری پارامتر کمک می‌کند [307]. تقطیر فدرال فرآیندی است برای استخراج دانش از یک مدل مرکزی بزرگ به یک مدل کوچک‌تر روی دستگاه‌های لبه [308]. در این فرآیند، دانش میان مدل‌ها منتقل می‌شود، به‌گونه‌ای که هر مدل نقش معلم برای مدل‌های دیگر را ایفا می‌کند. هر مدل دانش خود را با دیگران به اشتراک می‌گذارد، که به مدل‌ها اجازه می‌دهد از یکدیگر یاد بگیرند و عملکردشان را بهبود دهند [309].

این مکانیزم منجر به دقت بالاتر می‌شود زیرا داده‌های بیشتری به‌طور ضمنی برای آموزش استفاده می‌شوند. همچنین حریم خصوصی و امنیت بهبود می‌یابد زیرا داده‌ها به اشتراک گذاشته نمی‌شوند. علاوه بر این، تقطیر فدرال مصرف پهنای‌بند کمتری دارد به‌دلیل آموزش توزیع‌شده. به‌طور مشابه، نویسندگان [310] پیشنهاد کردند دانش در فرآیند FL تقطیر شود، با ایده اصلی مبنی بر مبادله اهداف نرم (Soft Targets) به‌جای انتقال پارامترهای مدل میان سرور و کلاینت‌ها. آن‌ها نشان دادند که راه‌حلشان می‌تواند هم سربار ارتباطی و هم هزینه‌های محاسباتی را کاهش دهد.

5) FL برای ارتباطات معنایی (Semantic Communications): ارتباطات معنایی (SC) یک پارادایم جدید است که انتظار می‌رود بخش عمده‌ای از G6 و فراتر از آن باشد. این رویکرد پردازش و انتقال داده را کارآمدتر می‌سازد، با در نظر گرفتن انتظارات کاربر و نیازهای برنامه، و همچنین معنای داده‌های ارسال‌شده. SC ترکیبی از پردازش زبان طبیعی، AI، و ML است تا یک سیستم ارتباطی قدرتمند و پویا ایجاد کند که قادر به درک زمینه داده‌های پردازش‌شده باشد.

در واقع، SC امکان ساخت شبکه‌های ارتباطی امن‌تر، قابل اعتمادتر، و کم‌مصرف‌تر را فراهم می‌کند. علاوه بر این، ارتباطات معنایی انتظار می‌رود تأخیر و پیچیدگی پردازش داده را کاهش دهد، که منجر به انتقال داده کارآمدتر و تجربه کاربری بهتر می‌شود [311]. به این ترتیب، SC پیش‌بینی می‌شود از برنامه‌ها و خدمات نوآورانه‌ای مانند دستیارهای مجازی هوشمند، ربات‌های هوشمند، و خودروهای خودران پشتیبانی کند.

با این حال، برخی فرآیندهای SC مانند تشخیص معنایی، مدل‌سازی دانش، و هماهنگی منابع بر هستند و ممکن است رفتارهای ناکارآمدی نشان دهند، به‌ویژه برای ارتباط میان یک منبع و مقصد. چارچوب FL این چالش را با آموزش یک مدل مشترک برای پردازش دانش معنایی عمومی بدون افشای داده‌های معنایی محلی از هر سرور لبه برطرف می‌کند.

همکاری سرورهای لبه: سرورهای لبه با تبادل نتایج میانی آموزش مدل همکاری می‌کنند. در [312] از یادگیری ماشینی فدره‌ای برای پشتیبانی از شبکه‌سازی معنایی کارآمد از نظر منابع استفاده شد. راه‌حل پیشنهادی به هر کاربر اجازه می‌دهد وظایف سنگین رمزگذاری و رمزگشایی معنایی را به سرورهای لبه واگذار کند، در حالی که اطلاعات مرتبط با مدل خود را با هماهنگی از طریق نتایج میانی محافظت می‌کند.

6) FL و بهره‌وری انرژی: بهره‌وری انرژی برای ساخت شبکه‌های پایدار G6 و نسل‌های بعدی شبکه‌های موبایل حیاتی است. در راستای این هدف، مصرف انرژی FL در طول فرآیند آموزش [313] باید به‌دقت بهینه‌سازی شود و طرح‌های زیرین باید آگاه از انرژی طراحی شوند. درک شده است که FL نسبت به یادگیری متمرکز سنتی انرژی کارآمدتر است، اما هنوز چندین عملیات انرژی بر وجود دارد که باید برای یادگیری سبز (Green Learning) بازاندیشی شوند [314]:

- ماهیت توزیع شده FL نیازمند منابع محاسباتی بیشتری است، که ممکن است منجر به افزایش مصرف انرژی شود.

- FL ممکن است نیازمند انتقال داده میان دستگاه‌ها/لبه/ابر باشد، که مصرف انرژی را افزایش می‌دهد.

- فرآیند FL معمولاً نیازمند چندین دور انتقال داده و محاسبات است، که مصرف انرژی کلی را بیشتر می‌کند.

در [315] یک چارچوب FL توزیع شده طراحی شد تا مشکل اتصال و تخلیه انرژی برای دستگاه‌های دوردست برطرف شود. این چارچوب برای رایانش لبه موبایل مناسب است که دستگاه‌ها را به‌صورت توزیع شده با استفاده از پروتکل‌های خوشه‌بندی متصل می‌کند. این رویکرد مشکلات سیستم‌های متمرکز را حل کرده و ارتباطی مقیاس‌پذیر، سریع‌تر و انرژی کارآمدتر هنگام تبادل مدل‌های آموزش دیده ارائه می‌دهد.

در آینده نزدیک، انتظار می‌رود FL شبکه‌های عصبی بزرگ یا الگوریتم‌های مشابه را در سطح دستگاه‌های موبایل و گوشی‌های کلاینت اجرا کند. این برای دستگاه‌های محدود از نظر منابع امکان‌پذیر نیست. یکی از چالش‌های اصلی این است که چگونه الگوریتم‌های FL طراحی شوند تا استفاده از منابع محاسباتی و ارتباطی به حداقل برسد. یک دیدگاه بالقوه استفاده کارآمد از کوانتیزاسیون [316] (Quantization)، [317] است، که نشان داده شده مصرف انرژی را به‌طور قابل‌توجهی کاهش می‌دهد. در واقع، نیاز به چارچوب‌های جدید برای ساخت الگوریتم‌های FL سبز وجود دارد که هم کارایی محاسباتی و هم کارایی ارتباطی بالا داشته باشند، در حالی که به منابع و بودجه انرژی کمی نیاز دارند.

IX. نتیجه‌گیری

یادگیری فدره‌ای پتانسیل زیادی در رسیدگی به نگرانی‌های حریم خصوصی و هزینه‌های ارتباطی در بخش‌های مختلف دارد، به‌ویژه در نسل‌های فعلی و آینده شبکه‌های موبایل. این مقاله نقش FL در شبکه‌های ارتباطی بی‌سیم را به‌طور کامل بررسی می‌کند، معماری‌های مختلف ML را مقایسه کرده و اصول، تکنیک‌ها و چارچوب‌های FL را بررسی می‌کند. همچنین آخرین مشارکت‌هایی که از FL برای بهبود ارتباطات و شاخص‌های کلیدی عملکرد (KPIs) در پشته پروتکل استفاده کرده‌اند مرور می‌شود. در نهایت، بینش‌ها و چالش‌های مهمی که با استقرار

راهبردهای FL در G5، G6 و فراتر از آن همراه هستند مورد بحث قرار می‌گیرند. به‌طور کلی، FL یک حوزه پژوهشی حیاتی با پیامدهای گسترده برای آینده است، و این مقاله تحلیل دقیقی از پتانسیل و تأثیر آن ارائه می‌دهد.

جدول اختصارات و سرنام‌ها

Abbreviation	Description
G5	— نسل پنجم شبکه موبایل
G6	— نسل ششم شبکه موبایل
NR (5G)	— رادیوی جدید
RF	— فرکانس رادیویی
AI	— هوش مصنوعی
FL	— یادگیری فدره‌ای
ML	— یادگیری ماشینی
DL	— یادگیری عمیق
FRL	— یادگیری تقویتی فدره‌ای
OSI	— مدل اتصال سیستم‌های باز
PHY	— لایه فیزیکی
NET	— لایه شبکه
MAC	— لایه دسترسی به رسانه
APP	— لایه کاربرد
IoT	— اینترنت اشیاء
CNN	— شبکه عصبی کانولوشنی
NN	— شبکه عصبی
HFL	— یادگیری فدره‌ای افقی
VFL	— یادگیری فدره‌ای عمودی
FTL	— یادگیری انتقالی فدره‌ای
MMVFL	— یادگیری فدره‌ای عمودی چندکلاس
HFCL	— یادگیری ترکیبی فدره‌ای-متمرکز
FedAvg	— میانگین‌گیری فدره‌ای
SimFL	— یادگیری فدره‌ای مبتنی بر شباهت
TFF	— TensorFlow Federated
FATE	— Federated AI Technology Enabler
FedML	— یادگیری ماشینی فدره‌ای

International Conference on Artificial Intelligence in Information and Communication (ICAIC). IEEE, 2019, pp. 102–106.

[5] K. B. Letaief, W. Chen, Y. Shi, J. Zhang, and Y.-J. A. Zhang, “The roadmap to 6g: Ai empowered wireless networks,” IEEE Communications Magazine, vol. 57, no. 8, pp. 84–90, 2019.

[6] M. Chen, U. Challita, W. Saad, C. Yin, and M. Debbah, “Artificial neural networks-based machine learning for wireless networks: A tutorial,” IEEE Communications Surveys & Tutorials, vol. 21, no. 4, pp. 3039–3071, 2019.

[7] M. Chen, U. Challita, W. Saad, C. Yin, and M. Debbah, “Artificial neural networks-based machine learning for wireless networks: A tutorial,” IEEE Communications Surveys Tutorials, vol. 21, no. 4, pp. 3039–3071, 2019.

[8] N. Rastegardoost and B. Jabbari, “A machine learning algorithm for unlicensed lte and wifi spectrum sharing,” in 2018 IEEE International Symposium on Dynamic Spectrum Access Networks (DySPAN). IEEE, 2018, pp. 1–6.

[9] Y.-Y. Liu and S.-J. Yoo, “Dynamic resource allocation using reinforcement learning for lte-u and wifi in the unlicensed spectrum,” in 2017 Ninth International Conference on Ubiquitous and Future Networks (ICUFN). IEEE, 2017, pp. 471–475.

[10] T. Jiang, D. Grace, and P. D. Mitchell, “Efficient exploration in reinforcement learning-based cognitive radio spectrum sharing,” IET communications, vol. 5, no. 10, pp. 1309–1317, 2011.

[11] Z. Zhang, K. Zhang, F. Gao, and S. Zhang, “Spectrum prediction and channel selection for sensing-based spectrum sharing scheme using online learning techniques,” in 2015 IEEE 26th Annual International Symposium on Personal, Indoor, and Mobile Radio Communications (PIMRC), 2015, pp. 355–359.

[12] C. Yang, J. Li, M. Guizani, A. Anpalagan, and M. El-kashlan, “Advanced spectrum sharing in 5g cognitive heterogeneous networks,” IEEE Wireless Communications, vol. 23, no. 2, pp. 94–101, 2016.

[13] Y. Zhang, Y. Gu, M. Pan, and Z. Han, “Distributed matching based spectrum allocation in cognitive radio networks,” in 2014 IEEE Global Communications Conference, 2014, pp. 864–869.

[14] K. Gai and M. Qiu, “Optimal resource allocation using reinforcement learning for iot content-centric services,” Applied Soft Computing, vol. 70, pp. 12–21, 2018.

[15] J. Wang, J. Wang, Y. Wu, J. Wang, H. Zhu, M. Lin, and J. Wang, “A machine learning framework for resource allocation assisted by cloud computing,” IEEE Network, vol. 32, no. 2, pp. 144–151, 2018.

[16] H. Li, H. Gao, T. Lv, and Y. Lu, “Deep q-learning based dynamic resource allocation for self-powered ultra-dense networks,” in 2018 IEEE International Conference on Communications Workshops (ICC Workshops), 2018, pp. 1–6.

[17] B. R. Ray and S. Chowdhury, “Reverse engineering technique (ret) to predict resource allocation in a google cloud system,” in 2018 8th International Conference on Cloud Computing, Data Science & Engineering (Confluence). IEEE, 2018, pp. 688–693.

[18] S. K. Singh and A. Jukan, “Machine-learning-based prediction for resource (re)allocation in optical data center networks,” IEEE/OSA Journal of Optical Communications and Networking, vol. 10, no. 10, pp. D12–D28, 2018.

FedRec — گیرنده مبتنی بر FL

AMC — طبقه‌بندی مدولاسیون خودکار

TCP — پروتکل کنترل انتقال

CSI — اطلاعات وضعیت کانال

RIS — سطوح هوشمند قابل پیکربندی

FED-WG — وزن‌ها و گرادین‌های فدره‌ای

MIMO — چندورودی-چندخروجی

mm-Wave — موج میلی‌متری

SPIM — مدولاسیون شاخص مسیر فضایی

NOMA — دسترسی چندگانه غیرارتوگونال

MTD — دستگاه‌های نوع ماشین

MEC — رایانش لبه چنددسترسی

LSTM — حافظه کوتاه‌مدت بلند

SVM — ماشین بردار پشتیبان

UAV — وسیله هوایی بدون سرنشین

QoE — کیفیت تجربه

HDRL — یادگیری تقویتی فدره‌ای ترکیبی

VR — واقعیت مجازی

AR — واقعیت افزوده

XR — واقعیت گسترش‌یافته

TI — اینترنت لمسی

URLLC — ارتباطات فوق قابل اعتماد با تأخیر کم

TC — طبقه‌بندی ترافیک

مراجع

[1] W. Saad, M. Bennis, and M. Chen, “A vision of 6g wireless systems: Applications, trends, technologies, and open research problems,” IEEE network, vol. 34, no. 3, pp. 134–142, 2019.

[2] W. Jiang, B. Han, M. A. Habibi, and H. D. Schotten, “The road towards 6g: A comprehensive survey,” IEEE Open Journal of the Communications Society, vol. 2, pp. 334–366, 2021.

[3] C. Chaccour, W. Saad, M. Debbah, Z. Han, and H. V. Poor, “Less data, more knowledge: Building next generation semantic communication networks,” arXiv preprint arXiv:2211.14343, 2022.

[4] E. Dahlman, S. Parkvall, J. Peisa, H. Tullberg, H. Murai, and M. Fujioka, “Artificial intelligence in future evolution of mobile communication,” in 2019

- [34] S. Hu, X. Chen, W. Ni, E. Hossain, and X. Wang, "Distributed machine learning for wireless communication networks: Techniques, architectures, and applications," arXiv preprint arXiv:2012.01489, 2020.
- [35] Z. Qin, G. Y. Li, and H. Ye, "Federated learning and wireless communications," arXiv preprint arXiv:2005.05265, 2020.
- [36] M. S. Mollel, A. I. Abubakar, M. Ozturk, S. F. Kaijage, M. Kisangiri, S. Hussain, M. A. Imran, and Q. H. Abbasi, "A survey of machine learning applications to handover management in 5g and beyond," IEEE Access, vol. 9, pp. 45770–45802, 2021.
- [37] Z. Yang, M. Chen, K.-K. Wong, H. V. Poor, and S. Cui, "Federated learning for 6g: Applications, challenges, and opportunities," arXiv preprint arXiv:2101.01338, 2021.
- [38] A. M. Elbir, A. K. Papazafeiropoulos, and S. Chatzinotas, "Federated learning for physical layer design," arXiv preprint arXiv:2102.11777, 2021.
- [39] O. A. Wahab, A. Mourad, H. Otrouk, and T. Taleb, "Federated machine learning: Survey, multi-level classification, desirable criteria and future directions in communication and networking systems," IEEE Communications Surveys & Tutorials, vol. 23, no. 2, pp. 1342–1397, 2021.
- [40] D. C. Nguyen, M. Ding, P. N. Pathirana, A. Seneviratne, J. Li, and H. V. Poor, "Federated learning for internet of things: A comprehensive survey," arXiv preprint arXiv:2104.07914, 2021.
- [41] L. U. Khan, W. Saad, Z. Han, E. Hossain, and C. S. Hong, "Federated learning for internet of things: Recent advances, taxonomy, and open challenges," IEEE Communications Surveys & Tutorials, 2021.
- [42] T. R. Gadekallu, Q.-V. Pham, T. Huynh-The, S. Bhattacharya, P. K. R. Maddikunta, and M. Liyanage, "Federated learning for big data: A survey on opportunities, applications, and future directions," arXiv preprint arXiv:2110.04160, 2021.
- [43] M. Al-Quraan, L. Mohjazi, L. Bariah, A. Centeno, A. Zoha, S. Muhaidat, M. Debbah, and M. A. Imran, "Edge-native intelligence for 6g communications driven by federated learning: A survey of trends and challenges," arXiv preprint arXiv:2111.07392, 2021.
- [44] R. Kontar, N. Shi, X. Yue, S. Chung, E. Byon, M. Chowdhury, J. Jin, W. Kontar, N. Masoud, M. Noueihed et al., "The internet of federated things (ioft): A vision for the future and in-depth survey of data-driven approaches for federated learning," arXiv preprint arXiv:2111.05326, 2021.
- [45] J. Liu, J. Huang, Y. Zhou, X. Li, S. Ji, H. Xiong, and D. Dou, "From distributed machine learning to federated learning: A survey," arXiv preprint arXiv:2104.14362, 2021.
- [46] D. Shome, O. Waqar, and W. U. Khan, "Federated learning and next generation wireless communications: A survey on bidirectional relationship," arXiv preprint arXiv:2110.07649, 2021.
- [47] N. Rodríguez-Barroso, D. J. López, M. Luzón, F. Herrera, and E. Martínez-Camara, "Survey on federated learning threats: concepts, taxonomy on attacks and defences, experimental study and challenges," arXiv preprint arXiv:2201.08135, 2022.
- [19] U. Challita, L. Dong, and W. Saad, "Deep learning for proactive resource allocation in lte-u networks," in European wireless technology conference, 2017.
- [20] W. Jiang and H. D. Schotten, "Multi-antenna fading channel prediction empowered by artificial intelligence," in 2018 IEEE 88th Vehicular Technology Conference (VTC-Fall). IEEE, 2018, pp. 1–6.
- [21] W. Jiang and H. Schotten, "A deep learning method to predict fading channel in multi-antenna systems," in 2020 IEEE 91st Vehicular Technology Conference (VTC2020-Spring). IEEE, 2020, pp. 1–5.
- [22] W. Jiang and H. D. Schotten, "Deep learning for fading channel prediction," IEEE Open Journal of the Communications Society, vol. 1, pp. 320–332, 2020.
- [23] W. Jiang and H. Schotten, "Recurrent neural networks with long short-term memory for fading channel prediction," in 2020 IEEE 91st Vehicular Technology Conference (VTC2020-Spring). IEEE, 2020, pp. 1–5.
- [24] A. Konstantinov and A. Pestryakov, "Fading channel prediction for 5g," in 2019 Systems of Signal Synchronization, Generating and Processing in Telecommunications (SYNCHROINFO). IEEE, 2019, pp. 1–7.
- [25] R. Alvizu, S. Troia, G. Maier, and A. Pattavina, "Matheuristic with machine-learning-based prediction for software-defined mobile metro core networks," Journal of Optical Communications and Networking, vol. 9, p. D19, 09 2017.
- [26] I. Railean, C. Stojulescu, S. Moga, and P. Lenca, "Wimax traffic forecasting based on neural networks in wavelet domain," in 2010 Fourth International Conference on Research Challenges in Information Science (RCIS). 2010, pp. 443–452.
- [27] S. Suthaharan, "Big data classification: Problems and challenges in network intrusion prediction with machine learning," ACM SIGMETRICS Performance Evaluation Review, vol. 41, no. 4, pp. 70–73, 2014.
- [28] F. Kong, J. Li, B. Jiang, T. Zhang, and H. Song, "Big data-driven machine learning-enabled traffic flow prediction," Transactions on Emerging Telecommunications Technologies, vol. 30, no. 9, p. e3482, 2019.
- [29] J. Verbaeken, M. Wolting, J. Katzy, J. Kloppenburg, T. Verbelen, and J. S. Rellermeyer, "A survey on distributed machine learning," ACM Computing Surveys (CSUR), vol. 53, no. 2, pp. 1–33, 2020.
- [30] N. Kato, B. Mao, F. Tang, Y. Kawamoto, and J. Liu, "Ten challenges in advancing machine learning technologies toward 6g," IEEE Wireless Communications, vol. 27, no. 3, pp. 96–103, 2020.
- [31] D. Shome, O. Waqar, and W. U. Khan, "Federated learning and next generation wireless communications: A survey on bidirectional relationship," Transactions on Emerging Telecommunications Technologies, vol. 33, no. 7, p. e4458, 2022.
- [32] W. Y. B. Lim, N. C. Luong, D. T. Hoang, Y. Jiao, Y.-C. Liang, Q. Yang, D. Niyato, and C. Miao, "Federated learning in mobile edge networks: A comprehensive survey," IEEE Communications Surveys & Tutorials, vol. 22, no. 3, pp. 2031–2063, 2020.
- [33] S. Niknam, H. S. Dhillon, and J. H. Reed, "Federated learning for wireless communications: Motivation, opportunities, and challenges," IEEE Communications Magazine, vol. 58, no. 6, pp. 46–51, 2020.

- [63] M. Murshed, C. Murphy, D. Hou, N. Khan, G. Ananthanarayanan, and F. Hussain, "Machine learning at the network edge: A survey," arXiv preprint arXiv:1908.00080, 2019.
- [64] S. Abdulrahman, H. Tout, H. Ould-Slimane, A. Mourad, C. Talhi, and M. Guizani, "A survey on federated learning: The journey from centralized to distributed on-site learning and beyond," IEEE Internet of Things Journal, vol. 8, no. 7, pp. 5476–5497, 2021.
- [65] J. Konecny, H. B. McMahan, D. Ramage, and P. Richtarik, "Federated optimization: Distributed machine learning for on-device intelligence," arXiv preprint arXiv:1610.02527, 2016.
- [66] P. Kairouz, H. B. McMahan, B. Avent, A. Bellet, M. Bennis, A. N. Bhagoji, K. Bonawitz, Z. Charles, G. Cormode, R. Cummings, R. G. L. D'Oliveira, S. E. Rouayheb, D. Evans, J. Gardner, Z. Garrett, A. Gascón, B. Ghazi, P. B. Gibbons, M. Gruteser, Z. Harchaoui, C. He, L. He, Z. Huo, B. Hutchinson, J. Hsu, M. Jaggi, T. Javidi, G. Joshi, M. Khodak, J. Konecny, A. Korolova, F. Koushanfar, S. Koyejo, T. Lepoint, Y. Liu, P. Mittal, M. Mohri, R. Nock, A. Özgür, R. Pagh, M. Raykova, H. Qi, D. Ramage, R. Raskar, D. Song, W. Song, S. U. Stich, Z. Sun, A. T. Suresh, F. Tramèr, P. Vepakomma, J. Wang, L. Xiong, Z. Xu, Q. Yang, F. X. Yu, H. Yu, and S. Zhao, "Advances and open problems in federated learning," CoRR, vol. abs/1912.04977, 2019. [Online]. Available: <http://arxiv.org/abs/1912.04977>
- [67] C. Zhang, Y. Xie, H. Bai, B. Yu, W. Li, and Y. Gao, "A survey on federated learning," Knowledge-Based Systems, vol. 216, p. 106775, 2021.
- [68] V. Mothukuri, R. M. Parizi, S. Pouriyeh, Y. Huang, A. Dehghanianha, and G. Srivastava, "A survey on security and privacy of federated learning," Future Generation Computer Systems, vol. 115, pp. 619–640, 2021.
- [69] Q. Yang, Y. Liu, T. Chen, and Y. Tong, "Federated machine learning: Concept and applications," ACM Transactions on Intelligent Systems and Technology (TIST), vol. 10, no. 2, pp. 1–19, 2019.
- [70] L. Li, Y. Fan, M. Tse, and K.-Y. Lin, "A review of applications in federated learning," Computers & Industrial Engineering, p. 106854, 2020.
- [71] P. Kairouz, H. B. McMahan, B. Avent, A. Bellet, M. Bennis, A. N. Bhagoji, K. Bonawitz, Z. Charles, G. Cormode, R. Cummings et al., "Advances and open problems in federated learning," arXiv preprint arXiv:1912.04977, 2019.
- [72] D. Leroy, A. Coucke, T. Lavril, T. Gisselbrecht, and J. Dureau, "Federated learning for keyword spotting," in ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2019, pp. 6341–6345.
- [73] Y. Liu, Y. Kang, C. Xing, T. Chen, and Q. Yang, "A secure federated transfer learning framework," IEEE Intelligent Systems, vol. 35, no. 4, pp. 70–82, 2020.
- [74] B. Liu, L. Wang, and M. Liu, "Lifelong federated reinforcement learning: a learning architecture for navigation in cloud robotic systems," IEEE Robotics and Automation Letters, vol. 4, no. 4, pp. 4555–4562, 2019.
- [75] S. Feng and H. Yu, "Multi-participant multi-class vertical federated learning," arXiv preprint arXiv:2001.11154, 2020.
- [76] T.-D. Cao, T. Truong-Huu, H. Tran, and K. Tran, "A federated learning framework for privacy-preserving and parallel training," arXiv preprint arXiv:2001.09782, 2020.
- [48] S. Banabilah, M. Aloqaily, E. Alsayed, N. Malik, and Y. Jararweh, "Federated learning review: Fundamentals, enabling technologies, and future applications," Information Processing & Management, vol. 59, no. 6, p. 103061, 2022.
- [49] S. Agrawal, S. Sarkar, O. Aouedi, G. Yenduri, K. Piamrat, M. Alazab, S. Bhattacharya, P. K. R. Maddikunta, and T. R. Gadekallu, "Federated learning for intrusion detection system: Concepts, challenges and future directions," Computer Communications, 2022.
- [50] B. Ghimire and D. B. Rawat, "Recent advances on federated learning for cybersecurity and cybersecurity for federated learning for internet of things," IEEE Internet of Things Journal, 2022.
- [51] S. Pandya, G. Srivastava, R. Jhaveri, M. R. Babu, S. Bhattacharya, P. K. R. Maddikunta, S. Mastorakis, M. J. Piran, and T. R. Gadekallu, "Federated learning for smart cities: A comprehensive survey," Sustainable Energy Technologies and Assessments, vol. 55, p. 102987, 2023.
- [52] J. Wen, Z. Zhang, Y. Lan, Z. Cui, J. Cai, and W. Zhang, "A survey on federated learning: challenges and applications," International Journal of Machine Learning and Cybernetics, vol. 14, no. 2, pp. 513–535, 2023.
- [53] M. Al-Quraan, L. Mohjazi, L. Bariah, A. Centeno, A. Zoha, K. Arshad, K. Assaleh, S. Muhaidat, M. Debbah, and M. A. Imran, "Edge-native intelligence for 6g communications driven by federated learning: A survey of trends and challenges," IEEE Transactions on Emerging Topics in Computational Intelligence, 2023.
- [54] Z. Zhao, Y. Mao, Y. Liu, L. Song, Y. Ouyang, X. Chen, and W. Ding, "Towards efficient communications in federated learning: A contemporary survey," Journal of the Franklin Institute, 2023.
- [55] R. Boutaba, M. A. Salahuddin, N. Limam, S. Ayoubi, N. Shahriar, F. Estrada-Solano, and O. M. Caicedo, "A comprehensive survey on machine learning for networking: evolution, applications and research opportunities," Journal of Internet Services and Applications, vol. 9, no. 1, pp. 1–99, 2018.
- [56] X.-D. Zhang, "Machine learning," in A Matrix Algebra Approach to Artificial Intelligence. Springer, 2020, pp. 223–440.
- [57] J. Jagannath, N. Polosky, A. Jagannath, F. Restuccia, and T. Melodia, "Machine learning for wireless communications in the internet of things: A comprehensive survey," Ad Hoc Networks, vol. 93, p. 101913, 2019.
- [58] D. Gunduz, P. de Kerret, N. D. Sidiropoulos, D. Gesbert, C. R. Murthy, and M. van der Schaar, "Machine learning in the air," IEEE Journal on Selected Areas in Communications, vol. 37, no. 10, pp. 2184–2199, 2019.
- [59] X. Ma, Y. Zhou, L. Wang, and M. Miao, "Privacy-preserving byzantine robust federated learning," Computer Standards & Interfaces, vol. 80, p. 103561, 2022.
- [60] Q. Yang, Y. Liu, Y. Cheng, Y. Kang, T. Chen, and H. Yu, Federated Learning. IEEE, 2019.
- [61] V. Sze, Y.-H. Chen, J. Emer, A. Suleiman, and Z. Zhang, "Hardware for machine learning: Challenges and opportunities," in 2017 IEEE Custom Integrated Circuits Conference (CICC). IEEE, 2017, pp. 1–8.
- [62] B. A. y Arcas, "Decentralized machine learning," in 2018 IEEE International Conference on Big Data (Big Data). IEEE, 2018, pp. 1–1.

- [93] Z. Qin, H. Ye, G. Y. Li, and B.-H. F. Juang, "Deep learning in physical layer communications," *IEEE Wireless Communications*, vol. 26, no. 2, pp. 93–99, 2019.
- [94] T. O'shea and J. Hoydis, "An introduction to deep learning for the physical layer," *IEEE Transactions on Cognitive Communications and Networking*, vol. 3, no. 4, pp. 563–575, 2017.
- [95] N. Farsad, N. Shlezinger, A. J. Goldsmith, and Y. C. Eldar, "Data-driven symbol detection via model-based machine learning," *arXiv preprint arXiv:2002.07806*, 2020.
- [96] —, "Data-driven symbol detection via model-based machine learning," 2020.
- [97] M. B. Mashhadi, N. Shlezinger, Y. C. Eldar, and D. Gunduz, "Fedrec: Federated learning of universal receivers over fading channels," *arXiv preprint arXiv:2011.07271*, 2020.
- [98] J. Shi, H. Zhao, M. Wang, and Q. Tian, "Signal recognition based on federated learning," in *IEEE INFOCOM 2020-IEEE Conference on Computer Communications Workshops (INFOCOM WKSHPS)*. IEEE, 2020, pp. 1105–1110.
- [99] Y. Wang, G. Gui, H. Gacanin, B. Adebisi, H. Sari, and F. Adachi, "Federated learning for automatic modulation classification under class imbalance and varying noise condition," *IEEE Transactions on Cognitive Communications and Networking*, 2021.
- [100] O. O. Oyerinde and S. H. Mneney, "Review of channel estimation for wireless communication systems," *IETE Technical review*, vol. 29, no. 4, pp. 282–298, 2012.
- [101] P. Dong, H. Zhang, G. Y. Li, I. S. Gaspar, and N. NaderiAlizadeh, "Deep cnn-based channel estimation for mmwave massive mimo systems," *IEEE Journal of Selected Topics in Signal Processing*, vol. 13, no. 5, pp. 989–1000, 2019.
- [102] A. M. Elbir, A. Papazafeiropoulos, P. Kourtessis, and S. Chatzino tas, "Deep channel learning for large intelligent surfaces aided mm wave massive mimo systems," *IEEE Wireless Communications Letters*, vol. 9, no. 9, pp. 1447–1451, 2020.
- [103] A. M. Elbir and S. Coleri, "Federated learning for channel estimation in conventional and irs-assisted massive mimo," *arXiv preprint arXiv:2008.10846*, 2020.
- [104] D. Xue, P. Han, Y. Liu, Z. Sha, Y. Liu, and L. Guo, "Low-cost free-space-optical communication system with federated learning-based channel prediction," in *2020 Asia Communications and Photonics Conference (ACP) and International Conference on Information Photonics and Optical Communications (IPOC)*. IEEE, 2020, pp. 1–3.
- [105] E. Onggosanusi, M. S. Rahman, L. Guo, Y. Kwak, H. Noh, Y. Kim, S. Faxer, M. Harrison, M. Frenne, S. Grant et al., "Modular and high resolution channel state information and beam management for 5g new radio," *IEEE Communications Magazine*, vol. 56, no. 3, pp. 48–55, 2018.
- [106] C. Luo, J. Ji, Q. Wang, X. Chen, and P. Li, "Channel state information prediction for 5g wireless communications: A deep learning approach," *IEEE Transactions on Network Science and Engineering*, vol. 7, no. 1, pp. 227–236, 2018.
- [107] W. Hou, J. Sun, G. Gui, T. Ohtsuki, A. M. Elbir, H. Gacanin, and H. Sari, "Federated learning for dl-csi prediction in fdd massive mimo systems," *IEEE Wireless Communications Letters*, 2021.
- [108] F. Pase, M. Giordani, and M. Zorzi, "On the convergence time of federated learning over wireless networks under imperfect csi," *arXiv preprint arXiv:2104.00331*, 2021.
- [77] Q. Wu, K. He, and X. Chen, "Personalized federated learning for intelligent iot applications: A cloud-edge based framework," *IEEE Open Journal of the Computer Society*, vol. 1, pp. 35–44, 2020.
- [78] A. Huang, Y. Liu, T. Chen, Y. Zhou, Q. Sun, H. Chai, and Q. Yang, "Starfl: Hybrid federated learning architecture for smart urban computing," *ACM Transactions on Intelligent Systems and Technology (TIST)*, vol. 12, no. 4, pp. 1–23, 2021.
- [79] A. M. Elbir, S. Coleri, and K. V. Mishra, "Hybrid federated and centralized learning," *arXiv preprint arXiv:2011.06892*, 2020.
- [80] M. Chen, H. V. Poor, W. Saad, and S. Cui, "Wireless communications for collaborative federated learning," *IEEE Communications Magazine*, vol. 58, no. 12, pp. 48–54, 2020.
- [81] M. Aledhari, R. Razzak, R. M. Parizi, and F. Saeed, "Federated learning: A survey on enabling technologies, protocols, and applications," *IEEE Access*, vol. 8, pp. 140699–140725, 2020.
- [82] Q. Li, Z. Wen, Z. Wu, S. Hu, N. Wang, and B. He, "A survey on federated learning systems: vision, hype and reality for data privacy and protection," *arXiv preprint arXiv:1907.09693*, 2019.
- [83] B. McMahan, E. Moore, D. Ramage, S. Hampson, and B. A. y Arcas, "Communication-efficient learning of deep networks from decentralized data," in *Artificial Intelligence and Statistics*. PMLR, 2017, pp. 1273–1282.
- [84] T. Li, A. K. Sahu, M. Zaheer, M. Sanjabi, A. Talwalkar, and V. Smith, "Federated optimization in heterogeneous networks," *arXiv preprint arXiv:1812.06127*, 2018.
- [85] S. Ji, S. Pan, G. Long, X. Li, J. Jiang, and Z. Huang, "Learning private neural language modeling with attentive aggregation," in *2019 International Joint Conference on Neural Networks (IJCNN)*. IEEE, 2019, pp. 1–8.
- [86] Q. Li, Z. Wen, and B. He, "Practical federated gradient boosting decision trees," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 34, no. 04, 2020, pp. 4642–4649.
- [87] T. Ryffel, A. Trask, M. Dahl, B. Wagner, J. Mancuso, D. Rueckert, and J. Passerat-Palmbach, "A generic framework for privacy preserving deep learning," *arXiv preprint arXiv:1811.04017*, 2018.
- [88] S. Caldas, P. Wu, T. Li, J. Konecny, H. B. McMahan, V. Smith, and A. Talwalkar, "LEAF: A benchmark for federated settings," *CoRR*, vol. abs/1812.01097, 2018. [Online]. Available: <http://arxiv.org/abs/1812.01097>
- [89] Y. Ma, D. Yu, T. Wu, and H. Wang, "Paddlepaddle: An open-source deep learning platform from industrial practice," *Frontiers of Data and Computing*, vol. 1, no. 1, pp. 105–115, 2019.
- [90] WeBank, "Fate: An industrial grade federated learning framework," <https://www.fedai.org>, 2018. 27
- [91] H. Ludwig, N. Baracaldo, G. Thomas, Y. Zhou, A. Anwar, S. Rajamoni, Y. Ong, J. Radhakrishnan, A. Verma, M. Sinn et al., "Ibm federated learning: an enterprise framework white paper v0.1," *arXiv preprint arXiv:2007.10987*, 2020.
- [92] C. He, S. Li, J. So, X. Zeng, M. Zhang, H. Wang, X. Wang, P. Vepakomma, A. Singh, H. Qiu et al., "Fedml: A research library and benchmark for federated machine learning," *arXiv preprint arXiv:2007.13518*, 2020.

- 2020 IEEE Conference on Communications and Network Security (CNS). IEEE, 2020, pp. 1–9.
- [125] L. Zhang, M. Xiao, G. Wu, M. Alam, Y.-C. Liang, and S. Li, “A survey of advanced techniques for spectrum sharing in 5g networks,” *IEEE Wireless Communications*, vol. 24, no. 5, pp. 44–51, 2017.
- [126] L. Liang, H. Ye, and G. Y. Li, “Spectrum sharing in vehicular networks based on multi-agent reinforcement learning,” *IEEE Journal on Selected Areas in Communications*, vol. 37, no. 10, pp. 2282–2292, 2019.
- [127] S. Valenti, D. Rossi, A. Dainotti, A. Pescap’e, A. Finamore, and M. Mellia, “Reviewing traffic classification,” in *Data Traffic Monitoring and Analysis*. Springer, 2013, pp. 123–147.
- [128] H. Mun and Y. Lee, “Internet traffic classification with federated learning,” *Electronics*, vol. 10, no. 1, p. 27, 2021.
- [129] U. Majeed, L. U. Khan, and C. S. Hong, “Cross-silo horizontal federated learning for flow-based time-related-features oriented traffic classification,” in *2020 21st Asia-Pacific Network Operations and Management Symposium (APNOMS)*. IEEE, 2020, pp. 389–392.
- [130] Y. Peng, M. He, and Y. Wang, “A federated semi-supervised learning approach for network traffic classification,” *arXiv preprint arXiv:2107.03933*, 2021.
- [131] M. Nazir, A. Sabah, S. Sarwar, A. Yaseen, and A. Jurcut, “Power and resource allocation in wireless communication network,” *Wireless Personal Communications*, pp. 1–24, 2021.
- [132] L. Ale, N. Zhang, H. Wu, D. Chen, and T. Han, “Online proactive caching in mobile edge computing using bidirectional deep recurrent neural network,” *IEEE Internet of Things Journal*, vol. 6, no. 3, pp. 5520–5530, 2019.
- [133] R. Dong, C. She, W. Hardjawana, Y. Li, and B. Vucetic, “Deep learning for hybrid 5g services in mobile edge computing systems: Learn from a digital twin,” *IEEE Transactions on Wireless Communications*, vol. 18, no. 10, pp. 4692–4707, 2019.
- [134] S. Wang, M. Chen, C. Yin, W. Saad, C. S. Hong, S. Cui, and H. V. Poor, “Federated learning for task and resource allocation in wireless high altitude balloon networks,” *IEEE Internet of Things Journal*, 2021, 28.
- [135] M. Yan, B. Chen, G. Feng, and S. Qin, “Federated cooperation and augmentation for power allocation in decentralized wireless networks,” *IEEE Access*, vol. 8, pp. 48088–48100, 2020.
- [136] R. Ali, Y. B. Zikria, S. Garg, A. K. Bashir, M. S. Obaidat, and H. S. Kim, “A federated reinforcement learning framework for incumbent technologies in beyond 5g networks,” *IEEE Network*, vol. 35, no. 4, pp. 152–159, 2021.
- [137] F. Foukalas, “Federated-learning-driven radio access networks,” *IEEE Wireless Communications*, 2022.
- [138] D. Lopez-Perez, A. De Domenico, N. Piovesan, G. Xinli, H. Bao, S. Qitao, and M. Debbah, “A survey on 5g radio access network energy efficiency: Massive mimo, lean carrier design, sleep modes, and machine learning,” *IEEE Communications Surveys & Tutorials*, vol. 24, no. 1, pp. 653–697, 2022.
- [139] Z. Mahrez, M. B. Driss, E. Sabir, W. Saad, and E. Driouch, “Benchmarking of anomaly detection techniques in o-ran for handover optimization,” in 2023
- [109] L. Dai, R. Jiao, F. Adachi, H. V. Poor, and L. Hanzo, “Deep learning for wireless communications: An emerging interdisciplinary paradigm,” *IEEE Wireless Communications*, vol. 27, no. 4, pp. 133–139, 2020.
- [110] A. M. Elbir and S. Coleri, “Federated learning for hybrid beamforming in mm-wave massive mimo,” *IEEE Communications Letters*, vol. 24, no. 12, pp. 2795–2799, 2020.
- [111] I. Chafaa, R. Negrel, E. V. Belmega, and M. Debbah, “Federated channel-beam mapping: from sub-6ghz to mmwave,” in *IEEE WCNC 2021 workshop: distributed machine learning*, 2021.
- [112] R. W. Heath, N. Gonzalez-Prelcic, S. Rangan, W. Roh, and A. M. Sayeed, “An overview of signal processing techniques for millimeter wave mimo systems,” *IEEE journal of selected topics in signal processing*, vol. 10, no. 3, pp. 436–453, 2016.
- [113] A. M. Elbir, S. Coleri, and K. V. Mishra, “Federated dropout learning for hybrid beamforming with spatial path index modulation in multi user mmwave-mimo systems,” *arXiv preprint arXiv:2102.07450*, 2021.
- [114] Z. Wang, L. Liu, and S. Cui, “Intelligent reflecting surface assisted massive mimo communications,” in *2020 IEEE 21st International Workshop on Signal Processing Advances in Wireless Communications (SPAWC)*. IEEE, 2020, pp. 1–5.
- [115] D. Ma, L. Li, H. Ren, D. Wang, X. Li, and Z. Han, “Distributed rate optimization for intelligent reflecting surface with federated learning,” in *2020 IEEE International Conference on Communications Workshops (ICC Workshops)*. IEEE, 2020, pp. 1–6.
- [116] L. Li, D. Ma, H. Ren, D. Wang, X. Tang, W. Liang, and T. Bai, “Enhanced reconfigurable intelligent surface assisted mmwave communication: A federated learning approach,” *China Communications*, vol. 17, no. 10, pp. 115–128, 2020.
- [117] Z. Liu and I. Elhanany, “RL-mac: a reinforcement learning based mac protocol for wireless sensor networks,” *International Journal of Sensor Networks*, vol. 1, no. 3-4, pp. 117–124, 2006.
- [118] M. Qiao, H. Zhao, S. Huang, L. Zhou, and S. Wang, “An intelligent mac protocol selection method based on machine learning in wireless sensor networks,” *KSI Transactions on Internet and Information Systems (TIIS)*, vol. 12, no. 11, pp. 5425–5448, 2018.
- [119] H. B. Pasandi and T. Nadeem, “Mac protocol design optimization using deep learning,” in *2020 International Conference on Artificial Intelligence in Information and Communication (ICAIC)*. IEEE, 2020, pp. 709–715.
- [120] M. M. Amiri and D. Gunduz, “Machine learning at the wireless edge: Distributed stochastic gradient descent over-the-air,” *IEEE Transactions on Signal Processing*, vol. 68, pp. 2155–2169, 2020. [121] O. Habachi, M.-A. Adjif, and J.-P. Cances, “Fast uplink grant for noma: A federated learning based approach,” in *International Symposium on Ubiquitous Networking*. Springer, 2019, pp. 96–109.
- [122] R. Zhong, X. Liu, Y. Liu, Y. Chen, and Z. Han, “Mobile reconfigurable intelligent surfaces for noma networks: Federated learning approaches,” *arXiv preprint arXiv:2105.09462*, 2021.
- [123] M. Troglia, J. Melcher, Y. Zheng, D. Anthony, A. Yang, and T. Yang, “Fair: Federated incumbent detection in cbrs band,” in *2019 IEEE International Symposium on Dynamic Spectrum Access Networks (DySPAN)*. IEEE, 2019, pp. 1–6.
- [124] N. Wang, J. Le, W. Li, L. Jiao, Z. Li, and K. Zeng, “Privacy protection and efficient incumbent detection in spectrum sharing based on federated learning,” in

- [154] L. U. Khan, I. Yaqoob, N. H. Tran, Z. Han, and C. S. Hong, "Network slicing: Recent advances, taxonomy, requirements, and open research challenges," *IEEE Access*, vol. 8, pp. 36009–36028, 2020.
- [155] S. A. Kazmi, L. U. Khan, N. H. Tran, and C. S. Hong, *Network slicing for 5G and beyond networks*. Springer, 2019, vol. 1.
- [156] W. Wu, C. Zhou, M. Li, H. Wu, H. Zhou, N. Zhang, W. Zhuang et al., "Ai-native network slicing for 6g networks," *arXiv preprint arXiv:2105.08576*, 2021.
- [157] L. U. Khan, S. R. Pandey, N. H. Tran, W. Saad, Z. Han, M. N. Nguyen, and C. S. Hong, "Federated learning for edge networks: Resource optimization and incentive mechanism," *IEEE Communications Magazine*, vol. 58, no. 10, pp. 88–93, 2020.
- [158] X. Wang, Y. Han, C. Wang, Q. Zhao, X. Chen, and M. Chen, "In-edge ai: Intelligentizing mobile edge computing, caching and communication by federated learning," *IEEE Network*, vol. 33, no. 5, pp. 156–165, 2019.
- [159] S. Messaoud, A. Bradai, O. B. Ahmed, P. T. A. Quang, M. Atri, and M. S. Hossain, "Deep federated q-learning-based network slicing for industrial iot," *IEEE Transactions on Industrial Informatics*, vol. 17, no. 8, pp. 5572–5582, 2020.
- [160] B. Brik and A. Ksentini, "On predicting service-oriented network slices performances in 5g: A federated learning approach," in *2020 IEEE 45th Conference on Local Computer Networks (LCN)*. IEEE, 2020, pp. 164–171.
- [161] Y.-J. Liu, G. Feng, Y. Sun, S. Qin, and Y.-C. Liang, "Device association for ran slicing based on hybrid federated deep reinforcement learning," *IEEE Transactions on Vehicular Technology*, vol. 69, no. 12, pp. 15731–15745, 2020.
- [162] Y. Li, A. Huang, Y. Xiao, X. Ge, S. Sun, and H.-C. Chao, "Federated orchestration for network slicing of bandwidth and computational resource," *arXiv preprint arXiv:2002.02451*, 2020.
- [163] S. Sendra, A. Rego, J. Lloret, J. M. Jimenez, and O. Romero, "Including artificial intelligence in a routing protocol using software defined networks," in *2017 IEEE International Conference on Communications Workshops (ICC Workshops)*. IEEE, 2017, pp. 670–674.
- [164] H. Yao, T. Mai, C. Jiang, L. Kuang, and S. Guo, "Ai routers & network mind: A hybrid machine learning paradigm for packet routing," *IEEE Computational Intelligence Magazine*, vol. 14, no. 4, pp. 21–30, 2019.
- [165] A. Sacco, F. Esposito, and G. Marchetto, "A federated learning approach to routing in challenged sdn-enabled edge networks," in *2020 6th IEEE Conference on Network Softwarization (NetSoft)*. IEEE, 2020, pp. 150–154.
- [166] Y. Cao, S. Maghsudi, and T. Ohtsuki, "Mobility-aware routing and caching: A federated learning assisted approach," *arXiv preprint arXiv:2102.10743*, 2021.
- [167] M. Wilbur, C. Samal, J. P. Talusan, K. Yasumoto, and A. Dubey, "Time-dependent decentralized routing using federated learning," in *2020 IEEE 23rd International Symposium on Real-Time Distributed Computing (ISORC)*. IEEE, 2020, pp. 56–64.
- [168] U. Majeed, S. S. Hassan, and C. S. Hong, "Cross-silo model-based secure federated transfer learning for flow-based traffic classification," in *2021 International Conference on Information Networking (ICOIN)*. IEEE, 2021, pp. 588–593.
- [169] A. Yazdinejad, R. M. Parizi, A. Dehghantanha, and H. Karimipour, "Federated learning for drone authentication," *Ad Hoc Networks*, vol. 120, p. 102574, 2021.
- International Wireless Communications and Mobile Computing (IWCMC). IEEE, 2023, pp. 119–125.
- [140] A. Abouaomar, A. Taik, A. Filali, and S. Cherkaoui, "Federated learning for ran slicing in beyond 5g networks," *arXiv preprint arXiv:2206.11328*, 2022.
- [141] S. Manzoor, A. N. Mian, A. Zoha, and M. A. Imran, "Federated learning empowered mobility-aware proactive content offloading framework for fog radio access networks," *Future Generation Computer Systems*, vol. 133, pp. 307–319, 2022.
- [142] H. Zhang, H. Zhou, and M. Erol-Kantarci, "Federated deep reinforcement learning for resource allocation in o-ran slicing," in *GLOBECOM 2022-2022 IEEE Global Communications Conference*. IEEE, 2022, pp. 958–963.
- [143] M. Luca, G. Barlacchi, B. Lepri, and L. Pappalardo, "Deep learning for human mobility: a survey on data and models," *arXiv preprint arXiv:2012.02825*, 2020.
- [144] J. Feng, Y. Li, C. Zhang, F. Sun, F. Meng, A. Guo, and D. Jin, "Deep move: Predicting human mobility with attentional recurrent networks," in *Proceedings of the 2018 world wide web conference*, 2018, pp. 1459–1468.
- [145] T. Anagnostopoulos, C. Anagnostopoulos, and S. Hadjiefthymiades, "Mobility prediction based on machine learning," in *2011 IEEE 12th International Conference on Mobile Data Management*, vol. 2. IEEE, 2011, pp. 27–30.
- [146] A. Li, S. Wang, W. Li, S. Liu, and S. Zhang, "Predicting human mobility with federated learning," in *Proceedings of the 28th International Conference on Advances in Geographic Information Systems*, 2020, pp. 441–444.
- [147] J. Feng, C. Rong, F. Sun, D. Guo, and Y. Li, "Pmf: A privacy preserving human mobility prediction framework via federated learning," *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, vol. 4, no. 1, pp. 1–21, 2020.
- [148] K. Sozinov, V. Vlassov, and S. Girdzijauskas, "Human activity recognition using federated learning," in *2018 IEEE Intl Conf on Parallel & Distributed Processing with Applications, Ubiquitous Computing & Communications, Big Data & Cloud Computing, Social Computing & Networking, Sustainable Computing & Communications (ISPA/IUCC/BDCloud/SocialCom/SustainCom)*. IEEE, 2018, pp. 1103–1111.
- [149] J. Wu, Q. Liu, Z. Huang, Y. Ning, H. Wang, E. Chen, J. Yi, and B. Zhou, "Hierarchical personalized federated learning for user modeling," in *Proceedings of the Web Conference 2021*, 2021, pp. 957–968.
- [150] A. Bourdoux, A. N. Barreto, B. van Liempd, C. de Lima, D. Dardari, D. Belot, E.-S. Lohan, G. Seco-Granados, H. Sarieddeen, H. Wymeersch et al., "6g white paper on localization and sensing," *arXiv preprint arXiv:2006.01779*, 2020.
- [151] F. Yin, Z. Lin, Q. Kong, Y. Xu, D. Li, S. Theodoridis, and S. R. Cui, "Fedloc: Federated learning framework for data-driven cooperative localization and location data processing," *IEEE Open Journal of Signal Processing*, vol. 1, pp. 187–215, 2020.
- [152] B. S. Ciftler, A. Albaseer, N. Lasla, and M. Abdallah, "Federated learning for localization: A privacy-preserving crowdsourcing method," *arXiv preprint arXiv:2001.01911*, 2020.
- [153] Z. Xiao, X. Xu, H. Xing, F. Song, X. Wang, and B. Zhao, "A federated learning system with enhanced feature extraction for human activity recognition," *Knowledge-Based Systems*, p. 107338, 2021.

- [184] A. A. Khuwaja, Y. Chen, N. Zhao, M.-S. Alouini, and P. Dobbins, "A survey of channel modeling for uav communications," *IEEE Communications Surveys & Tutorials*, vol. 20, no. 4, pp. 2804–2821, 2018.
- [185] V. Hassija, V. Chamola, A. Agrawal, A. Goyal, N. C. Luong, D. Niyato, F. R. Yu, and M. Guizani, "Fast, reliable, and secure drone communication: A comprehensive survey," *arXiv preprint arXiv:2105.01347*, 2021.
- [186] P. S. Bithas, E. T. Michailidis, N. Nomikos, D. Vouyioukas, and A. G. Kanatas, "A survey on machine-learning techniques for uav based communications," *Sensors*, vol. 19, no. 23, p. 5170, 2019.
- [187] B. Brik, A. Ksentini, and M. Bouaziz, "Federated learning for uavs enabled wireless networks: Use cases, challenges, and open problems," *IEEE Access*, vol. 8, pp. 53841–53849, 2020.
- [188] K. Sentz and S. Ferson, "Combination of evidence in dempster-shafer theory," *..*, 2002.
- [189] M. C. Domingo, "Securing underwater wireless communication networks," *IEEE Wireless Communications*, vol. 18, no. 1, pp. 22–28, 2011.
- [190] N. Victor, M. Alazab, S. Bhattacharya, S. Magnusson, P. K. R. Maddikunta, K. Ramana, T. R. Gadekallu et al., "Federated learning for iout: Concepts, applications, challenges and opportunities," *arXiv preprint arXiv:2207.13976*, 2022.
- [191] G. Zhu, D. Liu, Y. Du, C. You, J. Zhang, and K. Huang, "Toward an intelligent edge: Wireless communication meets machine learning," *IEEE communications magazine*, vol. 58, no. 1, pp. 19–25, 2020.
- [192] P. Habibi, M. Farhoudi, S. Kazemian, S. Khorsandi, and A. Leon Garcia, "Fog computing: a comprehensive architectural survey," *IEEE Access*, vol. 8, pp. 69105–69133, 2020.
- [193] A. Renda, P. Ducange, F. Marcelloni, D. Sabella, M. C. Filippou, G. Nardini, G. Stea, A. Viridis, D. Micheli, D. Rapone et al., "Federated learning of explainable ai models in 6g systems: Towards secure and automated vehicle networking," *Information*, vol. 13, no. 8, p. 395, 2022.
- [194] S. R. Pokhrel and J. Choi, "Improving tcp performance over wifi for internet of vehicles: A federated learning approach," *IEEE Transactions on Vehicular Technology*, vol. 69, no. 6, pp. 6798–6802, 2020.
- [195] S. R. Pokhrel and S. Singh, "Compound tcp performance for industry 4.0 wifi: A cognitive federated learning approach," *IEEE Transactions on Industrial Informatics*, vol. 17, no. 3, pp. 2143–2151, 2020.
- [196] P. K. Sharma, J. H. Park, and K. Cho, "Blockchain and federated learning-based distributed computing defence framework for sustainable society," *Sustainable Cities and Society*, vol. 59, p. 102220, 2020.
- [197] S. Savazzi, M. Nicoli, and V. Rampa, "Federated learning with cooperating devices: A consensus approach for massive iot networks," *IEEE Internet of Things Journal*, vol. 7, no. 5, pp. 4641–4654, 2020.
- [198] K. Wazny, "“crowdsourcing” ten years in: A review," *Journal of global health*, vol. 7, no. 2, 2017.
- [199] Z. Li, J. Liu, J. Hao, H. Wang, and M. Xian, "Crowdsf: A secure crowd computing framework based on blockchain and federated learning," *Electronics*, vol. 9, no. 5, p. 773, 2020.
- [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1570870521001165>
- [170] W. Y. B. Lim, J. Huang, Z. Xiong, J. Kang, D. Niyato, X.-S. Hua, C. Leung, and C. Miao, "Towards federated learning in uav-enabled internet of vehicles: A multi-dimensional contract-matching approach," *IEEE Transactions on Intelligent Transportation Systems*, 2021.
- [171] S. Wang, S. Hosseinalipour, M. Gorlatova, C. G. Brinton, and M. Chiang, "Uav-assisted online machine learning over multi-tiered networks: A hierarchical nested personalized federated learning approach," *arXiv preprint arXiv:2106.15734*, 2021.
- [172] Y. Wang, Z. Su, N. Zhang, and A. Benslimane, "Learning in the air: Secure federated learning for uav-assisted crowdsensing," *IEEE Transactions on network science and engineering*, 2020.
- [173] T. Zeng, O. Semiari, M. Mozaffari, M. Chen, W. Saad, and M. Bennis, "Federated learning in the sky: Joint power allocation and scheduling with uav swarms," in *ICC 2020-2020 IEEE International Conference on Communications (ICC)*. IEEE, 2020, pp. 1–6.
- [174] H. Zhang and L. Hanzo, "Federated learning assisted multi-uav networks," *IEEE Transactions on Vehicular Technology*, vol. 69, no. 11, pp. 14104–14109, 2020.
- [175] N. I. Mowla, N. H. Tran, I. Doh, and K. Chae, "Federated learning based cognitive detection of jamming attack in flying ad-hoc network," *IEEE Access*, vol. 8, pp. 4338–4350, 2019.
- [176] D. Kwon, J. Jeon, S. Park, J. Kim, and S. Cho, "Multiagent ddpg-based deep learning for smart ocean federated learning iot networks," *IEEE Internet of Things Journal*, vol. 7, no. 10, pp. 9895–9903, 2020. 29
- [177] H. Zhao, F. Ji, Q. Guan, Q. Li, S. Wang, H. Dong, and M. Wen, "Federated meta learning enhanced acoustic radio cooperative framework for ocean of things underwater acoustic communications," *arXiv preprint arXiv:2105.13296*, 2021.
- [178] C. Fang, Y. Guo, N. Wang, and A. Ju, "Highly efficient federated learning with strong privacy preservation in cloud computing," *Computers & Security*, vol. 96, p. 101889, 2020.
- [179] X. Zhang, M. Hu, J. Xia, T. Wei, M. Chen, and S. Hu, "Efficient federated learning for cloud-based aiot applications," *IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems*, 2020.
- [180] L. Liu, J. Zhang, S. Song, and K. B. Letaief, "Client-edge-cloud hierarchical federated learning," in *ICC 2020-2020 IEEE International Conference on Communications (ICC)*. IEEE, 2020, pp. 1–6.
- [181] Z. Zhao, C. Feng, H. H. Yang, and X. Luo, "Federated-learning enabled intelligent fog radio access networks: Fundamental theory, key techniques, and future trends," *IEEE wireless communications*, vol. 27, no. 2, pp. 22–28, 2020.
- [182] Y. Wu, Y. Jiang, M. Bennis, F. Zheng, X. Gao, and X. You, "Content popularity prediction in fog radio access networks: A federated learning based approach," in *ICC 2020-2020 IEEE International Conference on Communications (ICC)*. IEEE, 2020, pp. 1–6.
- [183] Y. Qu, L. Gao, T. H. Luan, Y. Xiang, S. Yu, B. Li, and G. Zheng, "Decentralized privacy using blockchain-enabled federated learning in fog computing," *IEEE Internet of Things Journal*, vol. 7, no. 6, pp. 5171–5183, 2020.

- [215] K. Demertzis, "Blockchain federated learning for threat defense," arXiv preprint arXiv:2102.12746, 2021.
- [216] M. Hengstler, E. Enkel, and S. Duelli, "Applied artificial intelligence and trust—the case of autonomous vehicles and medical assistance devices," *Technological Forecasting and Social Change*, vol. 105, pp. 105–120, 2016.
- [217] A. E. Sallab, M. Abdou, E. Perot, and S. Yogamani, "Deep reinforcement learning framework for autonomous driving," *Electronic Imaging*, vol. 2017, no. 19, pp. 70–76, 2017.
- [218] A. M. Elbir, B. Soner, and S. Coleri, "Federated learning in vehicular networks," arXiv preprint arXiv:2006.01412, 2020.
- [219] T. Zeng, O. Semiari, M. Chen, W. Saad, and M. Bennis, "Federated learning on the road: Autonomous controller design for connected and autonomous vehicles," arXiv preprint arXiv:2102.03401, 2021.
- [220] Y. Li, X. Tao, X. Zhang, J. Liu, and J. Xu, "Privacy-preserved federated learning for autonomous driving," *IEEE Transactions on Intelligent Transportation Systems*, 2021.
- [221] S. R. Pokhrel and J. Choi, "Federated learning with blockchain for autonomous vehicles: Analysis and design challenges," *IEEE Transactions on Communications*, vol. 68, no. 8, pp. 4734–4746, 2020.
- [222] X. Liang, Y. Liu, T. Chen, M. Liu, and Q. Yang, "Federated transfer reinforcement learning for autonomous driving," arXiv preprint arXiv:1910.06001, 2019.
- [223] S. Samarakoon, M. Bennis, W. Saad, and M. Debbah, "Federated learning for ultra-reliable low-latency v2v communications," in 2018 IEEE Global Communications Conference (GLOBECOM). IEEE, 2018, pp. 1–7. 30
- [224] J. Posner, L. Tseng, M. Aloqaily, and Y. Jararweh, "Federated learning in vehicular networks: opportunities and solutions," *IEEE Network*, vol. 35, no. 2, pp. 152–159, 2021.
- [225] T. D. Nguyen, S. Marchal, M. Miettinen, H. Fereidooni, N. Asokan, and A.-R. Sadeghi, "D²-iot: A federated self-learning anomaly detection system for iot," in 2019 IEEE 39th International Conference on Distributed Computing Systems (ICDCS). IEEE, 2019, pp. 756–767.
- [226] Y. Zhao, J. Chen, D. Wu, J. Teng, and S. Yu, "Multi-task network anomaly detection using federated learning," in Proceedings of the tenth international symposium on information and communication technology, 2019, pp. 273–279.
- [227] T. T. Huong, T. P. Bac, D. M. Long, T. D. Luong, N. M. Dan, B. D. Thang, K. P. Tran et al., "Detecting cyberattacks using anomaly detection in industrial control systems: A federated learning approach," *Computers in Industry*, vol. 132, p. 103509, 2021.
- [228] R. Zhao, Y. Yin, Y. Shi, and Z. Xue, "Intelligent intrusion detection based on federated learning aided long short-term memory," *Physical Communication*, vol. 42, p. 101157, 2020.
- [229] W. Zellinger, V. Wieser, M. Kumar, D. Brunner, N. Shepeleva, R. Gálvez, J. Langer, L. Fischer, and B. Moser, "Beyond federated learning: On confidentiality-critical machine learning applications in industry," *Procedia Computer Science*, vol. 180, pp. 734–743, 2021.
- [230] Y. Zhao, J. Zhao, M. Yang, T. Wang, N. Wang, L. Lyu, D. Niyato, and K.-Y. Lam, "Local differential privacy-based federated learning for internet of things," *IEEE Internet of Things Journal*, vol. 8, no. 11, pp. 8836–8853, 2020.
- [231] A. Capponi, C. Fiandrino, B. Kantarci, L. Foschini, D. Kliazovich, and P. Bouvry, "A survey on mobile crowdsensing systems: Challenges, solutions, and opportunities," *IEEE communications surveys & tutorials*, vol. 21, no. 3, pp. 2419–2465, 2019.
- [232] L. Wang, H. Yu, and X. Han, "Federated crowdsensing: Framework and challenges," arXiv preprint arXiv:2011.03208, 2020.
- [233] B. Zhao, X. Liu, and W.-n. Chen, "When crowdsensing meets federated learning: Privacy-preserving mobile crowdsensing system," arXiv preprint arXiv:2102.10109, 2021.
- [234] W. Zhang, Z. Li, and X. Chen, "Quality-aware user recruitment based on federated learning in mobile crowd sensing," *Tsinghua Science and Technology*, vol. 26, no. 6, pp. 869–877, 2021.
- [235] Z. Chen, M. Simsek, and B. Kantarci, "Federated learning-based risk-aware decision to mitigate fake task impacts on crowdsensing platforms," arXiv preprint arXiv:2101.01266, 2021.
- [236] K. Bouraqia, E. Sabir, M. Sadik, and L. Ladid, "Quality of experience for streaming services: measurements, challenges and insights," *IEEE Access*, vol. 8, pp. 13341–13361, 2020.
- [237] S. Aroussi and A. Mellouk, "Survey on machine learning-based qos qos correlation models," in 2014 International Conference on Computing, Management and Telecommunications (ComManTel). IEEE, 2014, pp. 200–204.
- [238] S. Ickin, K. Vandikas, and M. Fiedler, "Privacy preserving qos modeling using collaborative learning," in Proceedings of the 4th Internet QoS Workshop on QoS-Based Analysis and Management of Data Communication Networks, 2019, pp. 13–18.
- [239] S. Ickin, K. Vandikas, F. Moradi, J. Taghia, and W. Hu, "Ensemble based synthetic data synthesis for federated qos modeling," in 2020 6th IEEE Conference on Network Softwarization (NetSoft). IEEE, 2020, pp. 72–76.
- [240] N. Wirkuttis and H. Klein, "Artificial intelligence in cybersecurity," *Cyber, Intelligence, and Security*, vol. 1, no. 1, pp. 103–119, 2017.
- [241] V. Rey, P. M. S. Sánchez, A. H. Celdrán, and G. Bovet, "Federated learning for malware detection in iot devices," *Computer Networks*, vol. 204, p. 108693, 2022.
- [242] G. Xu, H. Li, S. Liu, K. Yang, and X. Lin, "Verifynet: Secure and verifiable federated learning," *IEEE Transactions on Information Forensics and Security*, vol. 15, pp. 911–926, 2019.
- [243] E. Khramtsova, C. Hammerschmidt, S. Lagrää, and R. State, "Federated learning for cyber security: Soc collaboration for malicious url detection," in 2020 IEEE 40th International Conference on Distributed Computing Systems (ICDCS). IEEE, 2020, pp. 1316–1321.
- [244] C. Thapa, K. K. Karmakar, A. H. Celdrán, S. Camtepe, V. Varadharajan, and S. Nepal, "Feddice: A ransomware spread detection in a distributed integrated clinical environment using federated learning and sdn based mitigation," arXiv preprint arXiv:2106.05434, 2021.

- [244] R. Ali, Y. B. Zikria, A. K. Bashir, S. Garg, and H. S. Kim, "Ullc for 5g and beyond: Requirements, enabling incumbent technologies and network intelligence," *IEEE Access*, vol. 9, pp. 67064–67095, 2021.
- [245] E. Bastug, M. Bennis, M. M'edard, and M. Debbah, "Toward interconnected virtual reality: Opportunities, challenges, and enablers," *IEEE Communications Magazine*, vol. 55, no. 6, pp. 110–117, 2017.
- [246] M. Chen, O. Semiari, W. Saad, X. Liu, and C. Yin, "Federated echo state learning for minimizing breaks in presence in wireless virtual reality networks," *IEEE Transactions on Wireless Communications*, vol. 19, no. 1, pp. 177–191, 2019.
- [247] Y. Chen, Q. Wang, H. Chen, X. Song, H. Tang, and M. Tian, "An overview of augmented reality technology," in *Journal of Physics: Conference Series*, vol. 1237, no. 2. IOP Publishing, 2019, p. 022082.
- [248] D. Chen, L. J. Xie, B. Kim, L. Wang, C. S. Hong, L.-C. Wang, and Z. Han, "Federated learning based mobile edge computing for augmented reality applications," in *2020 international conference on computing, networking and communications (ICNC)*. IEEE, 2020, pp. 767–773.
- [249] F. Wang, Y. Liu, J. Liu, A. Argyriou, L. Wang, and Z. Xu, "Output security for multi-user augmented reality using federated reinforcement learning," , .
- [250] J. Ratcliffe, F. Soave, N. Bryan-Kinns, L. Tokarchuk, and I. Farkhatdinov, "Extended reality (xr) remote research: a survey of drawbacks and opportunities," in *Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems*, 2021, pp. 1–13.
- [251] L. Barbieri, S. Savazzi, M. Brambilla, and M. Nicoli, "Decentralized federated learning for extended sensing in 6g connected vehicles," *Vehicular Communications*, p. 100396, 2021.
- [252] M. Chehimi, O. Hashash, and W. Saad, "The roadmap to a quantum enabled wireless metaverse: Beyond the classical limits," in *2023 Fifth International Conference on Advances in Computational Tools for Engineering Applications (ACTEA)*. IEEE, 2023, pp. 7–12.
- [253] Y. Chen, S. Huang, W. Gan, G. Huang, and Y. Wu, "Federated learning for metaverse: A survey," *arXiv preprint arXiv:2303.17987*, 2023.
- [254] D. C. Nguyen, Q.-V. Pham, P. N. Pathirana, M. Ding, A. Seneviratne, Z. Lin, O. Dobre, and W.-J. Hwang, "Federated learning for smart healthcare: A survey," *ACM Computing Surveys (CSUR)*, vol. 55, no. 3, pp. 1–37, 2022.
- [255] J. Xu, B. S. Glicksberg, C. Su, P. Walker, J. Bian, and F. Wang, "Federated learning for healthcare informatics," *Journal of Healthcare Informatics Research*, vol. 5, no. 1, pp. 1–19, 2021.
- [256] Y. Chen, X. Qin, J. Wang, C. Yu, and W. Gao, "Fedhealth: A federated transfer learning framework for wearable healthcare," *IEEE Intelligent Systems*, vol. 35, no. 4, pp. 83–93, 2020.
- [257] W. Y. B. Lim, S. Garg, Z. Xiong, D. Niyato, C. Leung, C. Miao, and M. Guizani, "Dynamic contract design for federated learning in smart healthcare applications," *IEEE Internet of Things Journal*, 2020.
- [258] A. Qayyum, K. Ahmad, M. A. Ahsan, A. Al-Fuqaha, and J. Qadir, "Collaborative federated learning for healthcare: Multi-modal covid 19 diagnosis at the edge," *arXiv preprint arXiv:2101.07511*, 2021.
- [230] S. Savazzi, M. Nicoli, M. Bennis, S. Kianoush, and L. Barbieri, "Opportunities of federated learning in connected, cooperative, and automated industrial systems," *IEEE Communications Magazine*, vol. 59, no. 2, pp. 16–21, 2021.
- [231] M. Hao, H. Li, X. Luo, G. Xu, H. Yang, and S. Liu, "Efficient and privacy-enhanced federated learning for industrial artificial intelligence," *IEEE Transactions on Industrial Informatics*, vol. 16, no. 10, pp. 6532–6542, 2019.
- [232] A. Fu, X. Zhang, N. Xiong, Y. Gao, H. Wang, and J. Zhang, "Vfl: A verifiable federated learning with privacy-preserving for big data in industrial iot," *IEEE Transactions on Industrial Informatics*, 2020.
- [233] T. Hiessl, D. Schall, J. Kemnitz, and S. Schulte, "Industrial federated learning—requirements and system design," in *International Conference on Practical Applications of Agents and Multi-Agent Systems*. Springer, 2020, pp. 42–53.
- [234] W. Sun, S. Lei, L. Wang, Z. Liu, and Y. Zhang, "Adaptive federated learning and digital twin for industrial internet of things," *IEEE Transactions on Industrial Informatics*, vol. 17, no. 8, pp. 5605–5614, 2020.
- [235] Y. Xianjia, J. P. Queralta, J. Heikkonen, and T. Westerlund, "Federated learning in robotic and autonomous systems," *arXiv preprint arXiv:2104.10141*, 2021.
- [236] W. Zhou, Y. Li, S. Chen, and B. Ding, "Real-time data processing architecture for multi-robots based on differential federated learning," in *2018 IEEE SmartWorld, Ubiquitous Intelligence & Computing, Advanced & Trusted Computing, Scalable Computing & Communications, Cloud & Big Data Computing, Internet of People and Smart City Innovation (SmartWorld/SCALCOM/UIC/ATC/CBDCom/IOP/SCI)*. IEEE, 2018, pp. 462–471.
- [237] J. Park, S. Samarakoon, H. Shiri, M. K. Abdel-Aziz, T. Nishio, A. Elgabri, and M. Bennis, "Extreme 5g: Vision, challenges, and key enablers," *arXiv preprint arXiv:2001.09683*, 2020.
- [238] C. She, R. Dong, Z. Gu, Z. Hou, Y. Li, W. Hardjawana, C. Yang, L. Song, and B. Vucetic, "Deep learning for ultra-reliable and low latency communications in 6g networks," *IEEE Network*, vol. 34, no. 5, pp. 219–225, 2020.
- [239] S. Samarakoon, M. Bennis, W. Saad, and M. Debbah, "Distributed federated learning for ultra-reliable low-latency vehicular communications," *IEEE Transactions on Communications*, vol. 68, no. 2, pp. 1146–1159, 2019.
- [240] A. Azari, M. Ozger, and C. Cavdar, "Risk-aware resource allocation for 5g: Challenges and strategies with machine learning," *IEEE Communications Magazine*, vol. 57, no. 3, pp. 42–48, 2019.
- [241] M. Simsek, A. Aijaz, M. Dohler, J. Sachs, and G. Fettweis, "5g-enabled tactile internet," *IEEE Journal on Selected Areas in Communications*, vol. 34, no. 3, pp. 460–473, 2016.
- [242] N. Promwongsa, A. Ebrahimzadeh, D. Naboulsi, S. Kianpisheh, F. Belqasmi, R. Glioth, N. Crespi, and O. Alfandi, "A comprehensive survey of the tactile internet: State-of-the-art and research directions," *IEEE Communications Surveys & Tutorials*, 2020.
- [243] M. Mukherjee, M. Guo, J. Lloret, and Q. Zhang, "Leveraging intelligent computation offloading with fog/edge computing for tactile internet: Advantages and limitations," *IEEE Network*, vol. 34, no. 5, pp. 322–329, 2020.

Journal of King Saud University Computer and Information Sciences, vol. 34, no. 9, pp. 7445–7458, 2022.

[275] Y. J. Cho, J. Wang, and G. Joshi, “Client selection in federated learning: Convergence analysis and power-of-choice selection strategies,” arXiv preprint arXiv:2010.01243, 2020.

[276] M. Tang, X. Ning, Y. Wang, Y. Wang, and Y. Chen, “Fedgp: Correlation-based active client selection for heterogeneous federated learning,” arXiv preprint arXiv:2103.13822, 2021.

[277] T. Nishio and R. Yonetani, “Client selection for federated learning with heterogeneous resources in mobile edge,” in ICC 2019-2019 IEEE International Conference on Communications (ICC). IEEE, 2019, pp. 1–7.

[278] W. Zhang, Y. Chen, Y. Jiang, and J. Liu, “Delay-constrained client selection for heterogeneous federated learning in intelligent transportation systems,” IEEE Transactions on Network Science and Engineering, 2023.

[279] Z. Cheng, X. Fan, N. Chen, M. Liwang, L. Huang, and X. Wang, “Learning-based client selection for multiple federated learning services with constrained monetary budgets,” ICT Express, 2023.

[280] F. Shi, W. Lin, L. Fan, X. Lai, and X. Wang, “Efficient client selection based on contextual combinatorial multi-arm bandits,” IEEE Transactions on Wireless Communications, 2023.

[281] D. Kang and C. W. Ahn, “Ga approach to optimize training client set in federated learning,” IEEE Access, 2023.

[282] M. Chahoud, H. Sami, A. Mourad, S. Otoum, H. Otok, J. Bentahar, and M. Guizani, “On-demand-fl: A dynamic and efficient multi-criteria federated learning client deployment scheme,” IEEE Internet of Things Journal, 2023.

[283] X. Tang, Y. Wang, R. Huang, G. Chen, and L. Wang, “Stackelberg game based resource allocation algorithm for federated learning in mec systems,” in 2023 6th World Conference on Computing and Communication Technologies (WCCCT). IEEE, 2023, pp. 7–12.

[284] U. Michieli and M. Ozay, “Are all users treated fairly in federated learning systems?” in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021, pp. 2318–2322.

[285] W. Hao, M. El-Khamy, J. Lee, J. Zhang, K. J. Liang, C. Chen, and L. C. Duke, “Towards fair federated learning with zero-shot data augmentation,” in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021, pp. 3310–3319.

[286] T. Huang, W. Lin, W. Wu, L. He, K. Li, and A. Y. Zomaya, “An efficiency-boosting client selection scheme for federated learning with fairness guarantee,” IEEE Transactions on Parallel and Distributed Systems, vol. 32, no. 7, pp. 1552–1564, 2020.

[287] L. Lyu, X. Xu, Q. Wang, and H. Yu, “Collaborative fairness in federated learning,” in Federated Learning. Springer, 2020, pp. 189–204.

[288] Z. Wang, X. Fan, J. Qi, C. Wen, C. Wang, and R. Yu, “Federated learning with fair averaging,” arXiv preprint arXiv:2104.14937, 2021.

[289] W. He, H. Yao, T. Mai, F. Wang, and M. Guizani, “Three-stage stackelberg game enabled clustered federated learning in heterogeneous uav swarms,” IEEE Transactions on Vehicular Technology, 2023.

[259] Y. Fu, Y. Zhang, Q. Zhu, H.-n. Dai, M. Li, and T. Q. Quek, “A new vision of wireless edge caching networks (wecns): Issues, technologies, and open research trends,” IEEE Network, 2023.

[260] L. Gashi, A. Luma, H. Snopce, and Y. Januzaj, “A secure recommender system model for service placement in wireless networks,” International Journal of Interactive Mobile Technologies, vol. 17, no. 11, 2023.

[261] M. Vaishnavi and S. Vemuru, “The three-tier architecture of federated learning for recommendation systems,” in 2023 7th International Conference on Computing Methodologies and Communication (ICCMC). IEEE, 2023, pp. 1529–1533.

[262] L. Yang, B. Tan, V. W. Zheng, K. Chen, and Q. Yang, “Federated recommendation systems,” Federated Learning: Privacy and Incentive, pp. 225–239, 2020.

[263] J. Qin, B. Liu, and J. Qian, “A novel privacy-preserved recommender system framework based on federated learning,” in 2021 The 4th International Conference on Software Engineering and Information Management, 2021, pp. 82–88.

[264] W. Huang, M. Ye, and B. Du, “Learn from others and be yourself in heterogeneous federated learning,” in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022, pp. 10143–10153.

[265] L. Lyu, H. Yu, and Q. Yang, “Threats to federated learning: A survey,” arXiv preprint arXiv:2003.02133, 2020.

[266] H. Fereidooni, S. Marchal, M. Miettinen, A. Mirhoseini, H. Mollering, T. D. Nguyen, P. Rieger, A.-R. Sadeghi, T. Schneider, H. Yalame et al., “Safelearn: secure aggregation for private federated learning,” in 2021 IEEE Security and Privacy Workshops (SPW). IEEE, 2021, pp. 56–62.

[267] Q. Zhang, B. Gu, C. Deng, and H. Huang, “Secure bilevel asynchronous vertical federated learning with backward updating,” arXiv preprint arXiv:2103.00958, 2021.

[268] J. Konecny, H. B. McMahan, F. X. Yu, P. Richtarik, A. T. Suresh, and D. Bacon, “Federated learning: Strategies for improving communication efficiency,” arXiv preprint arXiv:1610.05492, 2016.

[269] S. Wang, T. Tuor, T. Salonidis, K. K. Leung, C. Makaya, T. He, and K. Chan, “Adaptive federated learning in resource constrained edge computing systems,” IEEE Journal on Selected Areas in Communications, vol. 37, no. 6, pp. 1205–1221, 2019.

[270] F. Haddadpour and M. Mahdavi, “On the convergence of local descent methods in federated learning,” arXiv preprint arXiv:1910.14425, 2019.

[271] C. T. Dinh, N. H. Tran, M. N. Nguyen, C. S. Hong, W. Bao, A. Y. Zomaya, and V. Gramoli, “Federated learning over wireless networks: Convergence analysis and resource allocation,” IEEE/ACM Transactions on Networking, vol. 29, no. 1, pp. 398–409, 2020.

[272] X. Wei and C. Shen, “Federated learning over noisy channels: Convergence analysis and design examples,” arXiv preprint arXiv:2101.02198, 2021.

[273] M. Chen, N. Shlezinger, H. V. Poor, Y. C. Eldar, and S. Cui, “Communication-efficient federated learning,” Proceedings of the National Academy of Sciences, vol. 118, no. 17, 2021.

[274] M. Ahmadi, A. Taghavireshidizadeh, D. Javaheri, A. Masoumian, S. J. Ghouschi, and Y. Pourasad, “Dqre-scnnet: a novel hybrid approach for selecting users in federated learning with deep-q-reinforcement learning based on spectral clustering,”

[306] A. Mehrjou, "Federated learning as a mean-field game," arXiv preprint arXiv:2107.03770, 2021.

[307] E. Jeong, S. Oh, H. Kim, J. Park, M. Bennis, and S.-L. Kim, "Communication-efficient on-device machine learning: Federated distillation and augmentation under non-iid private data," arXiv preprint arXiv:1811.11479, 2018.

[308] A. Mora, I. Tenison, P. Bellavista, and I. Rish, "Knowledge distillation for federated learning: a practical guide," arXiv preprint arXiv:2211.04742, 2022.

[309] M. Chen, D. Gunduz, K. Huang, W. Saad, M. Bennis, A. V. Feljan, and H. V. Poor, "Distributed learning in wireless networks: Recent progress and future challenges," IEEE Journal on Selected Areas in Communications, vol. 39, no. 12, pp. 3579–3605, 2021.

[310] H. Q. Le, J. H. Shin, M. N. Nguyen, and C. S. Hong, "Distilling knowledge in federated learning," in 2021 22nd Asia-Pacific Network Operations and Management Symposium (APNOMS). IEEE, 2021, pp. 196–201.

[311] W. Yang, H. Du, Z. Q. Liew, W. Y. B. Lim, Z. Xiong, D. Niyato, X. Chi, X. S. Shen, and C. Miao, "Semantic communications for future internet: Fundamentals, applications, and challenges," IEEE Communications Surveys & Tutorials, 2022.

[312] G. Shi, Y. Xiao, Y. Li, and X. Xie, "From semantic communication to semantic-aware networking: Model, architecture, and open problems," IEEE Communications Magazine, vol. 59, no. 8, pp. 44–50, 2021. 32

[313] D. Shi, L. Li, R. Chen, P. Prakash, M. Pan, and Y. Fang, "Toward energy-efficient federated learning over 5g+ mobile devices," IEEE Wireless Communications, vol. 29, no. 5, pp. 44–51, 2022.

[314] Z. Yang, M. Chen, W. Saad, C. S. Hong, and M. Shikh-Bahaei, "Energy efficient federated learning over wireless communication networks," IEEE Transactions on Wireless Communications, vol. 20, no. 3, pp. 1935–1949, 2020.

[315] S. A. Khowaja, K. Dev, P. Khowaja, and P. Bellavista, "Toward energy efficient distributed federated learning for 6g networks," IEEE Wireless Communications, vol. 28, no. 6, pp. 34–40, 2022.

[316] M. Kim, W. Saad, M. Mozaffari, and M. Debbah, "Green, quantized federated learning over wireless networks: An energy-efficient design," IEEE Transactions on Wireless Communications, 2023.

[317] —, "On the tradeoff between energy, precision, and accuracy in federated quantized neural networks," in ICC 2022-IEEE International Conference on Communications. IEEE, 2022, pp. 2194–2199.

Maryam Ben Driss (Student Member, IEEE) received the B.Sc. degree in Computer Science in 2018 and the M.Sc. degree in Big Data and Data Science in 2020 from the University of Hassan II, Faculty of Sciences Ben M'Sik, Casablanca, Morocco. She is currently pursuing her Ph.D. degree at the National Higher School of Electricity and Mechanics (ENSEM) in Casablanca. Her research interests include Artificial Intelligence, Federated Learning, Machine Learning, Deep Learning, Cellular Networks, 5G, 6G and beyond.

Essaid Sabir (Senior Member, IEEE) received the Ph.D. degree (Hons.) in networking and computer engineering from Avignon University, France, in 2010. He has been a non-tenure-track Assistant Professor at Avignon University, from 2009 to 2012. He has been a Professor at Hassan II university of Casablanca until late 2022, where he was leading the NEST research Group. He is a professor with the department of computer science, Université du Qu'ébec à Montréal. His research interests

[290] A. Peyvandi, B. Majidi, S. Peyvandi, and J. C. Patra, "Privacy preserving federated learning for scalable and high data quality computational-intelligence-as-a-service in society 5.0," Multimedia tools and applications, vol. 81, no. 18, pp. 25029–25050, 2022.

[291] P. Singh, M. K. Singh, R. Singh, and N. Singh, "Federated learning: Challenges, methods, and future directions," in Federated Learning for IoT Applications. Springer, 2022, pp. 199–214.

[292] J. Konecny, B. McMahan, and D. Ramage, "Federated optimization: Distributed optimization beyond the datacenter," arXiv preprint arXiv:1511.03575, 2015.

[293] M. Chen, Z. Yang, W. Saad, C. Yin, H. V. Poor, and S. Cui, "A joint learning and communications framework for federated learning over wireless networks," IEEE Transactions on Wireless Communications, vol. 20, no. 1, pp. 269–283, 2020.

[294] H. H. Yang, Z. Liu, T. Q. Quek, and H. V. Poor, "Scheduling policies for federated learning in wireless networks," IEEE transactions on communications, vol. 68, no. 1, pp. 317–333, 2019.

[295] M. Chen, H. V. Poor, W. Saad, and S. Cui, "Convergence time optimization for federated learning over wireless networks," IEEE Transactions on Wireless Communications, vol. 20, no. 4, pp. 2457–2471, 2020.

[296] B. Xiao, X. Yu, W. Ni, X. Wang, and H. V. Poor, "Over-the-air federated learning: Status quo, open challenges, and future directions," arXiv preprint arXiv:2307.00974, 2023.

[297] H. Y. Oksuz, F. Molinari, H. Sprekeler, and J. Raisch, "Federated learning in wireless networks via over-the-air computations," arXiv preprint arXiv:2305.04630, 2023.

[298] B. Tegin and T. M. Duman, "Federated learning with over-the-air aggregation over time-varying channels," IEEE Transactions on Wireless Communications, 2023.

[299] F. Malandrino and C. F. Chiasserini, "Federated learning at the network edge: When not all nodes are created equal," arXiv preprint arXiv:2101.01995, 2021.

[300] A. Z. Tan, H. Yu, L. Cui, and Q. Yang, "Towards personalized federated learning," IEEE Transactions on Neural Networks and Learning Systems, 2022.

[301] L. Barbieri, S. Savazzi, M. Brambilla, and M. Nicoli, "Decentralized federated learning for extended sensing in 6g connected vehicles," Vehicular Communications, vol. 33, p. 100396, 2022.

[302] S. K. Singh, L. T. Yang, and J. H. Park, "Fusionfedblock: Fusion of blockchain and federated learning to preserve privacy in industry 5.0," Information Fusion, vol. 90, pp. 233–240, 2023.

[303] Y. Qu, M. P. Uddin, C. Gan, Y. Xiang, L. Gao, and J. Yearwood, "Blockchain-enabled federated learning: A survey," ACM Computing Surveys, vol. 55, no. 4, pp. 1–35, 2022.

[304] H. Kim, J. Park, M. Bennis, and S.-L. Kim, "Blockchain-enabled on-device federated learning," IEEE Communications Letters, vol. 24, no. 6, pp. 1279–1283, 2019.

[305] C. Ma, J. Li, M. Ding, L. Shi, T. Wang, Z. Han, and H. V. Poor, "When federated learning meets blockchain: A new distributed learning paradigm," arXiv preprint arXiv:2009.09338, 2020.

Associate Professor. She has authored or co-authored many journal and conference papers. Her research interests include network performance evaluation, traffic engineering, and quality of service management in optical and wireless networks.

Walid Saad (Fellow Member, IEEE) received his Ph.D. degree from the University of Oslo in 2010. He is a Professor at the Department of Electrical and Computer Engineering at Virginia Tech where he leads the Network Science, Wireless, and Security (NEWS) laboratory. His research interests include wireless networks, machine learning, game theory, cybersecurity, unmanned aerial vehicles, semantic communications, and cyber-physical systems. He was the author/co-author of eleven conferences' best paper awards and the 2015 and 2022 IEEE ComSoc Fred W. Ellersick Prize

include 5G/6G, wireless networks, IoT, AI/ML, and game theory. His work has been awarded in four international conferences. To bridge the gap between academia and industry, he founded the International Conference on Ubiquitous Networking (UNet) and co-founded the WINCOM conference series. He serves as a guest editor for many journals. He organized numerous events and played executive roles for other major events.

Halima Elbiaze (Senior Member, IEEE) received the B.S. degree in applied mathematics from the University of MV, Morocco, in 1996, the M.Sc. degree in telecommunication systems from the University of Versailles, in 1998, and the Ph.D. degree in computer science from Institut National des T 'el ' ecommunications, Paris, France, in 2002. Since 2003, she has been with the Department of Computer Science, Universit 'e du Qu ' ebec ' a Montr ' eal, QC, Canada, where she is currently an